


# SciScope 科技文献智能分析报告

面向科技文献智能分析的科研智能体构建

赛题交付物一：数据分析报告    支撑交付物二：科研智能体系统

## SCISCOPE EVIDENCE PATHWAY



## WHAT THE JURY CAN VERIFY

|                                           |                                       |                                             |                                            |
|-------------------------------------------|---------------------------------------|---------------------------------------------|--------------------------------------------|
| <b>数据真实性</b><br>6 源公开采集，可<br>复现 raw JSONL | <b>分析完整性</b><br>分布、关键词、作者<br>网络覆盖赛题要求 | <b>图谱与趋势基础</b><br>503,598 条候选合作<br>边与热点演化矩阵 | <b>系统转化价值</b><br>数据资产直接进入<br>RAG、推荐、趋势 API |
|-------------------------------------------|---------------------------------------|---------------------------------------------|--------------------------------------------|

|                                                                   |                                                                             |
|-------------------------------------------------------------------|-----------------------------------------------------------------------------|
| <b>交付物一：数据分析报告</b><br>已展示 5 万级文献分布、关键词演化、作者合作社区、<br>数据质量审计与智能体映射。 | <b>交付物二：科研智能体系统</b><br>后端/前端/本地模型接口已具备基础链路，下一步以均<br>衡数据和正文证据增强 RAG 与 Agent。 |
|-------------------------------------------------------------------|-----------------------------------------------------------------------------|

|             |                                                             |
|-------------|-------------------------------------------------------------|
| <b>评审定位</b> | 面向赛题验收的数据分析报告，证明数据规模、分析深度和系统转化能力                            |
| <b>当前证据</b> | 50,498 条 raw records，49,067 条去重语料，13 张报告图表，503,598 条作者合作候选边 |
| <b>后续增强</b> | 补齐正文证据、均衡 2022-2025 年份分布、完善 DOI/venue/URL/chunk 等 RAG 字段    |

# 目录

|          |                       |           |
|----------|-----------------------|-----------|
| <b>1</b> | <b>报告定位与交付边界</b>      | <b>2</b>  |
| 1.1      | 当前分析阶段 . . . . .      | 2         |
| 1.2      | 报告读者 . . . . .        | 2         |
| <b>2</b> | <b>数据底座与采集状态</b>      | <b>3</b>  |
| 2.1      | 多源采集状态 . . . . .      | 3         |
| 2.2      | 字段完整度基线 . . . . .     | 4         |
| 2.3      | 标准化 Schema . . . . .  | 4         |
| <b>3</b> | <b>文献分布分析</b>         | <b>5</b>  |
| 3.1      | 近五年年份分布 . . . . .     | 5         |
| 3.2      | 领域分布 . . . . .        | 5         |
| 3.3      | 来源偏差说明 . . . . .      | 7         |
| <b>4</b> | <b>关键词演化与热点趋势</b>     | <b>8</b>  |
| 4.1      | 关键词处理策略 . . . . .     | 8         |
| 4.2      | 当前图表 . . . . .        | 8         |
| 4.3      | 热点预测口径 . . . . .      | 8         |
| <b>5</b> | <b>作者合作网络分析</b>       | <b>11</b> |
| 5.1      | 网络构建 . . . . .        | 11        |
| 5.2      | 核心指标 . . . . .        | 11        |
| 5.3      | 合作社区与高频合作关系 . . . . . | 11        |
| <b>6</b> | <b>数据质量与可信度审计</b>     | <b>13</b> |
| 6.1      | 当前质量观察 . . . . .      | 13        |
| 6.2      | 质量矩阵 . . . . .        | 13        |
| <b>7</b> | <b>从分析报告到科研智能体</b>    | <b>14</b> |
| 7.1      | 资产映射 . . . . .        | 14        |
| 7.2      | 演示叙事 . . . . .        | 14        |
| <b>8</b> | <b>数据层补强与下一步路线</b>    | <b>15</b> |
| 8.1      | 数据层缺口 . . . . .       | 15        |
| 8.2      | 执行优先级 . . . . .       | 15        |
| 8.3      | 最终报告验收清单 . . . . .    | 15        |

# 1 报告定位与交付边界

核心定位

本报告是 SciScope 项目面向赛题交付的独立数据分析报告, 目标是回答“公开科技文献数据本身揭示了什么”。它与系统设计 PDF 并列: 设计 PDF 解释智能体架构和工程路线, 本报告沉淀文献分布、关键词演化、作者合作网络、趋势预测和可复现分析结论。

## 1.1 当前分析阶段

当前版本已经从报告底座推进到 5 万级数据分析版本。分析资产覆盖 50,498 条 raw records、49,067 条去重语料记录、40,137 条近五年智能体语料记录, 并生成文献分布、关键词演化、作者合作网络和数据质量审计图表。

| 交付维度 | 当前已有内容                                        | 下一轮增强内容                             |
|------|-----------------------------------------------|-------------------------------------|
| 数据来源 | OpenAlex、arXiv、PubMed、PMC、Cross-ref、DOAJ 六源采集 | Semantic Scholar、CORE 等 API-key 增强源 |
| 数据规模 | 50,498 条 raw records 与 49,067 条去重语料记录         | DOI/title/year 深度去重与字段补全            |
| 分析主题 | 分布、关键词、作者网络、质量审计、智能体映射                        | 动态主题模型、趋势预测、图谱社区发现                  |
| 报告产物 | 多章节 LaTeX、可编译 PDF、13 张图表资产                    | 评审版摘要页与前端联动展示                       |

## 1.2 报告读者

- **评委:** 需要快速看见数据真实、分析深入、结论可解释。
- **科研用户:** 需要理解某一领域文献热点、演化路径和关键合作网络。
- **系统开发者:** 需要把报告中的统计资产复用到 RAG、推荐、趋势和知识图谱模块。

## 2 数据底座与采集状态

### 当前数据基线

当前本地已完成 6 个公共来源的近五年科技文献采集与标准化, 共形成 50,498 条 raw records。基于统一 schema 进一步生成跨源去重后的正式语料 `papers_corpus_50k.json`, 当前包含 49,067 条记录, 其中 40,137 条落在 2022–2026 近五年分析窗口内。

### 2.1 多源采集状态

| 来源       | 当前记录数 | 主要价值                   | 后续用途               |
|----------|-------|------------------------|--------------------|
| OpenAlex | 8,500 | 综合学术元数据、主题、引用、开放知识库 id | 主干语料、领域分布、引用与主题分析  |
| arXiv    | 8,496 | 计算机与交叉学科预印本、摘要质量高      | AI/CS 热点、快速演化主题识别  |
| PubMed   | 8,500 | 生物医学文献元数据与摘要           | 医学方向关键词演化、领域对比     |
| PMC      | 8,002 | 开放全文与正文片段增强            | RAG 证据、全文片段检索、医学深读 |
| Crossref | 8,500 | DOI 与期刊出版元数据覆盖广        | DOI 去重、出版源补全、跨源校验  |
| DOAJ     | 8,500 | 开放期刊文章与开放获取元数据         | OA 覆盖、开放科学视角、摘要补充  |




图 1 当前 6 个公开来源的 50,498 条 raw records 采集规模。

2.2 字段完整度基线

| 来源       | 标题    | 摘要/摘要索引 | 作者    | 年份    | 正文片段  |
|----------|-------|---------|-------|-------|-------|
| OpenAlex | 8,499 | 8,500   | 8,480 | 8,498 | 0     |
| arXiv    | 8,496 | 8,496   | 8,496 | 8,496 | 0     |
| PubMed   | 8,500 | 8,334   | 8,492 | 8,500 | 0     |
| PMC      | 8,002 | 4,746   | 7,982 | 8,002 | 4,542 |
| Crossref | 8,500 | 165     | 8,459 | 8,500 | 0     |
| DOAJ     | 8,499 | 8,364   | 8,490 | 8,490 | 0     |




图 2 按来源统计的关键字段完整度矩阵。

2.3 标准化 Schema

当前分析字段: paper\_id, title, abstract, authors, year, keywords, field, full\_text

RAG/Agent 增强字段: doi, venue, url, citation\_count, author\_ids, institutions, text\_source, chunk\_count

这个 schema 是分析报告与科研智能体系统之间的共同接口。报告侧依赖它生成统计图表和洞察, 智能体侧依赖它构建检索证据、推荐解释、趋势 API 和知识图谱。下一轮数据层工作会把 DOI、正文来源、引用数、机构与 chunk 级字段补齐, 为 RAG 和 Agent 工具调用铺底。

### 3 文献分布分析

#### 分析目标

文献分布分析回答三个问题：文献在时间上如何集中，在计算机、生物医学、材料科学三大领域中如何分布，以及不同公开来源是否存在明显年份偏置。

#### 3.1 近五年年份分布

年份分布采用 2022–2026 作为近五年分析窗口。原始数据中保留了少量历史年份和未来年份噪声，但趋势图只展示当前赛题口径内的有效年份，避免被异常元数据拉宽时间轴。

- 近五年总量趋势线：观察 2022–2026 的研究增长和数据覆盖断点。
- 领域-年份热力图：比较计算机、生物医学、材料科学在近五年的年度结构变化。
- 来源-年份热力图：识别某些来源在近五年窗口内的年份偏置。




图 3 2022–2026 近五年文献年份分布。

当前分析资产包含 50,498 条 raw records; 其中 41,435 条落在 2022–2026 分析窗口内。正式智能体语料经跨源去重后包含 49,067 条记录, 其中 40,137 条为近五年记录。

#### 3.2 领域分布

当前采集 query 已覆盖 AI/CS、生物医学、材料科学三条主线。报告采用 field\_seed 作为赛题领域口径, 避免不同数据库原始学科标签粒度不一致造成统计偏移。

| 领域    | 当前统计口径                       |
|-------|------------------------------|
| 计算机科学 | LLM、RAG、知识图谱、图神经网络、信息检索、推荐系统 |
| 生物医学  | 药物发现、生物医学 NLP、临床知识、蛋白设计、公共卫生 |
| 材料科学  | 材料发现、电池材料、催化剂、材料信息学、能源材料     |




图 4 2022–2026 来源-年份覆盖热力图。




图 5 三大赛题领域的文献规模分布。




图 6 2022–2026 三大领域年度覆盖热力图。

### 3.3 来源偏差说明

不同公开源天然有不同偏置: arXiv 更偏预印本和计算机科学, PubMed/PMC 更偏生物医学, Crossref 覆盖广但摘要缺失较多, DOAJ 更偏开放期刊。报告中必须把偏差作为方法说明写出来, 否则趋势结论容易被误解为真实学科增长。

## 4 关键词演化与热点趋势

分析目标

关键词演化是本赛题最容易形成“洞见感”的部分。最终报告不只列 Top-K 关键词, 而要展示关键词如何出现、升温、迁移、分化, 并说明这些变化如何驱动智能体的热点预测和论文推荐。

### 4.1 关键词处理策略

1. 统一大小写、连字符、复数和同义词, 例如 retrieval-augmented generation 与 retrieval augmented generation 归并。
2. 从标题、摘要、数据库关键词、OpenAlex concepts、arXiv categories 中构建候选词。
3. 使用领域词表过滤高频泛词, 例如 study, method, model。
4. 为每个关键词生成年度频次、增长率、突增分数和代表论文。

### 4.2 当前图表




图 7 2022–2026 近五年窗口内的高频关键词。

| 分析项       | 当前口径                           | 评委看到的价值    |
|-----------|--------------------------------|------------|
| 关键词 Top-K | 全局高频关键词与领域高频关键词                | 快速理解数据主题结构 |
| 关键词年度热力图  | 行为关键词，列为年份，值为频次或标准化热度          | 发现主题升温与降温  |
| 关键词升温榜    | 比较 2024–2026 与 2022–2023 的窗口差异 | 显示趋势预测能力   |
| 主题河流图     | 展示主题簇在年份上的占比变化                 | 形成故事化趋势展示  |

### 4.3 热点预测口径

趋势预测不应直接声称“未来一定热门”。更稳妥的表达是：




图 8 2022–2026 高频关键词年度热度矩阵。每一行按自身最大值归一化，用于观察主题升温 and 迁移。




图 9 2022–2026 关键词升温候选榜。

基于近年频次增长、跨领域扩散、代表论文质量、作者合作密度和引用信号, 将候选方向分成“强上升”“稳定增长”“早期萌芽”“可能噪声”四类。当前 PDF 已给出关键词升温候选榜, 后续系统侧将其接入趋势 API 与自然语言解释。

## 5 作者合作网络分析

### 分析目标

作者合作网络用于识别核心研究者、跨领域连接者和合作团簇。它是知识图谱查询和论文推荐解释的重要依据，也是数据分析报告中最能体现“科研智能体”差异化的图分析部分。

### 5.1 网络构建

- **节点**: 作者, 后续可扩展为机构、国家、领域、关键词。
- **边**: 两位作者共同出现在同一篇论文中。
- **边权**: 合作次数、近年合作次数、代表论文质量。
- **节点属性**: 论文数、领域分布、活跃年份、中心性、社区编号。

### 5.2 核心指标

| 指标                | 含义            | 报告解释方式       |
|-------------------|---------------|--------------|
| Degree            | 作者直接合作人数      | 识别高合作度作者     |
| Betweenness       | 作者连接不同团簇的桥梁能力 | 识别跨领域连接者     |
| Community         | 合作社区编号        | 发现研究团队与方向群落  |
| Temporal Activity | 作者按年份的活跃情况    | 判断作者是否仍处于活跃期 |

### 5.3 合作社区与高频合作关系




图 10 2022–2026 作者合作网络规模漏斗。

作者合作边由论文作者列表两两组合得到。为避免一篇大团队论文生成过多虚高边，静态报告图仅纳入作者数不超过 12 的论文，并对每篇论文内的合作关系使用分数化权重。当前作者社区图使用 25,000 条高权重合作边构建核心图，既保留 50 万级候选边的规模依据，又避免 PDF 静态图退化成不可读的全量网络。




图 11 2022–2026 近五年作者合作社区气泡图。




图 12 2022–2026 近五年高频作者合作关系。

## 6 数据质量与可信度审计

为什么要单独写质量审计

科研文献分析最怕“图很好看，但数据口径不可信”。本报告必须把缺失、重复、来源偏差、字段映射和后续修正策略写清楚，这样数据分析和智能体回答才有可信基础。

### 6.1 当前质量观察

- 六源已形成 50,498 条 raw records, 标准化后生成 49,067 条跨源去重正式语料。
- arXiv、OpenAlex、DOAJ、PubMed 摘要覆盖较好, 可直接进入摘要级 RAG。
- PMC 当前提供 4,542 条正文片段, 是全文增强和证据链构建的主要来源。
- Crossref 摘要覆盖较低, 但 DOI、出版源和作者元数据覆盖好, 更适合跨源校验与去重。
- 年份图表统一过滤到 2022–2026, 避免历史记录和未来年份噪声影响近五年趋势判断。
- Semantic Scholar 与 CORE 已预留代码入口, 但需要 API key 或更高配额。

### 6.2 质量矩阵




图 13 摘要与全文覆盖率对比。该图用于明确摘要级分析和全文级 RAG 的证据边界。

| 风险    | 表现                           | 处理策略                                  |
|-------|------------------------------|---------------------------------------|
| 跨源重复  | 同一 DOI 或标题在多个来源出现            | DOI 优先去重, 标题 + 年份作为次级键                |
| 摘要缺失  | Crossref 和部分 PMC summary 无摘要 | 使用 OpenAlex/DOAJ/PubMed 补全, 或降级为元数据证据 |
| 领域偏差  | 来源和 query 对领域分布有影响           | 报告中保留来源分布图, 趋势按来源归一化                  |
| 作者歧义  | 同名作者或缩写作者难以区分                | 后续引入 ORCID、机构和论文上下文消歧                 |
| 关键词噪声 | 高频泛词影响趋势判断                   | 领域词表、停用词、短语归并和人工审计                    |

## 7 从分析报告到科研智能体

报告不是静态终点

本报告中的每个统计资产都应被科研智能体复用。文献分布进入 Dashboard, 关键词演化进入 Trends, 作者合作网络进入 Graph, 代表论文和证据片段进入 Ask 与 Recommend。

### 7.1 资产映射

| 报告资产    | 系统模块            | 智能体能力                |
|---------|-----------------|----------------------|
| 年份与领域分布 | Overview        | 回答“这个领域近几年发展如何”      |
| 关键词年度矩阵 | Trends          | 识别热点、解释趋势、生成综述线索     |
| 作者合作图   | Graph           | 查询作者关系、发现合作团簇和桥梁作者   |
| 主题模型结果  | Ask / Recommend | 主题约束检索、相似论文推荐、研究方向扩展 |
| 质量审计表   | Evidence        | 在回答中暴露置信度和数据来源限制     |

### 7.2 演示叙事

最终演示可以采用一条研究问题贯穿：

“Retrieval-Augmented Generation 在生物医学和材料科学中的研究趋势是否正在上升？关键论文、核心作者和潜在交叉机会是什么？”

演示流程：先在数据报告中展示趋势证据，再进入系统前端进行自然语言追问，随后打开作者网络与推荐结果，最后由智能体生成带证据引用的研究机会总结。

## 8 数据层补强与下一步路线

今晚优先级

当前已经跨过约 5 万篇公开论文数据资产基线。下一阶段重点不是继续堆总量, 而是修正年份偏置、提升正文证据覆盖、补齐 RAG/Agent 所需字段, 让后续问答、推荐、趋势和图谱模块建立在更可靠的数据底座上。

### 8.1 数据层缺口

| 缺口       | 当前数值  | 下一步动作                                      |
|----------|-------|--------------------------------------------|
| 2022 年记录 | 1,472 | 年份过滤回补, 目标接近 8k-10k                        |
| 2023 年记录 | 1,690 | 年份过滤回补, 避免继续扩大 2026 偏置                     |
| 2024 年记录 | 2,416 | 分来源、分领域回补                                  |
| 2025 年记录 | 4,915 | 补足到与其他年份同一量级                               |
| 正文片段记录   | 4,542 | PMC/CORE/开放全文增强, 阶段目标 15k                  |
| RAG 增强字段 | 未完全落表 | DOI、venue、URL、引用数、text provenance、chunk 字段 |

### 8.2 执行优先级

- 跑 `make data-layer-audit`, 固化年份、正文、字段覆盖缺口。
- 建立 2022-2025 年份均衡回补批次, 暂停继续追加 2026-heavy 数据。
- 扩展正文与证据片段来源, 先把 `full-text/evidence records` 推向 15k。
- 升级 `canonical schema`, 显式落 `doi`, `venue`, `url`, `citation_count`, `text_source`, `chunk_count`。
- 在稳定数据层上构建 RAG chunks、FTS/vector index、趋势模型、推荐特征和图谱资产。

### 8.3 最终报告验收清单

| 验收项   | 标准                        |
|-------|---------------------------|
| 可复现   | 一条命令生成数据统计表、图表资产和 PDF     |
| 可解释   | 每个结论注明数据来源、统计口径和不确定性      |
| 有洞见   | 不停留在数量统计, 给出趋势、迁移、合作和机会判断 |
| 能联动系统 | 报告图表对应系统接口和前端交互模块         |
| 适合评审  | 前几页能快速呈现数据真实度、分析深度和产品价值   |