

SciScope 科技文献智能分析报告

面向科技文献智能分析的科研智能体构建

5 万级公开科技文献数据资产 · 分布分析 · 关键词演化 · 作者合作网络

RAW RECORDS

50,498

6 个公开来源

DEDUP CORPUS

49,067

可进入智能体语料

RECENT WINDOW

40,137

2022-2026 去重语料

REPORT FIGURES

13

分布 / 关键词 / 作者网络

AUTHOR GRAPH

503,598

加权候选合作边

DATA GAP

10,458

正文片段距 15k 目标

REPRODUCIBLE DATA FLOW

Raw JSONL

公开源采集

Clean Corpus

去重 / 标准化

Analysis Assets

表格 / 图表

RAG Assets

chunks / index

Agent Tools

问答 / 推荐 / 趋势

当前结论

已形成 5 万级文献分析报告底座；领域、年份、关键词、作者合作网络均可由 Makefile 复现。

今晚主线

均衡 2022-2025 年份分布，增加正文证据，补齐 DOI、venue、URL、text provenance 与 chunk 字段。

文档性质

赛题交付物中的数据分析报告

当前版本

5 万级分析版: 50,498 条 raw records, 49,067 条去重语料记录

后续演进

继续补齐正文、均衡年份分布、增强 RAG 字段与 Agent 索引资产

设计约束

黑白、可复现、章节化 LaTeX、多文件编译

生成位置: output/pdf/sciscope_data_report/sciscope_data_report.pdf

目录

1	报告定位与交付边界	2
1.1	当前分析阶段	2
1.2	报告读者	2
2	数据底座与采集状态	3
2.1	多源采集状态	3
2.2	字段完整度基线	4
2.3	标准化 Schema	4
3	文献分布分析	5
3.1	近五年年份分布	5
3.2	领域分布	5
3.3	来源偏差说明	7
4	关键词演化与热点趋势	8
4.1	关键词处理策略	8
4.2	当前图表	8
4.3	热点预测口径	8
5	作者合作网络分析	11
5.1	网络构建	11
5.2	核心指标	11
5.3	合作社区与高频合作关系	11
6	数据质量与可信度审计	13
6.1	当前质量观察	13
6.2	质量矩阵	13
7	从分析报告到科研智能体	14
7.1	资产映射	14
7.2	演示叙事	14
8	数据层补强与下一步路线	15
8.1	数据层缺口	15
8.2	执行优先级	15
8.3	最终报告验收清单	15

1 报告定位与交付边界

核心定位

本报告是 SciScope 项目面向赛题交付的独立数据分析报告, 目标是回答“公开科技文献数据本身揭示了什么”。它与系统设计 PDF 并列: 设计 PDF 解释智能体架构和工程路线, 本报告沉淀文献分布、关键词演化、作者合作网络、趋势预测和可复现分析结论。

1.1 当前分析阶段

当前版本已经从报告底座推进到 5 万级数据分析版本。分析资产覆盖 50,498 条 raw records、49,067 条去重语料记录、40,137 条近五年智能体语料记录, 并生成文献分布、关键词演化、作者合作网络和数据质量审计图表。

交付维度	当前已有内容	下一轮增强内容
数据来源	OpenAlex、arXiv、PubMed、PMC、Cross-ref、DOAJ 六源采集	Semantic Scholar、CORE 等 API-key 增强源
数据规模	50,498 条 raw records 与 49,067 条去重语料记录	DOI/title/year 深度去重与字段补全
分析主题	分布、关键词、作者网络、质量审计、智能体映射	动态主题模型、趋势预测、图谱社区发现
报告产物	多章节 LaTeX、可编译 PDF、13 张图表资产	评审版摘要页与前端联动展示

1.2 报告读者

- **评委:** 需要快速看见数据真实、分析深入、结论可解释。
- **科研用户:** 需要理解某一领域文献热点、演化路径和关键合作网络。
- **系统开发者:** 需要把报告中的统计资产复用到 RAG、推荐、趋势和知识图谱模块。

2 数据底座与采集状态

当前数据基线

当前本地已完成 6 个公共来源的近五年科技文献采集与标准化, 共形成 50,498 条 raw records。基于统一 schema 进一步生成跨源去重后的正式语料 `papers_corpus_50k.json`, 当前包含 49,067 条记录, 其中 40,137 条落在 2022–2026 近五年分析窗口内。

2.1 多源采集状态

来源	当前记录数	主要价值	后续用途
OpenAlex	8,500	综合学术元数据、主题、引用、开放知识库 id	主干语料、领域分布、引用与主题分析
arXiv	8,496	计算机与交叉学科预印本、摘要质量高	AI/CS 热点、快速演化主题识别
PubMed	8,500	生物医学文献元数据与摘要	医学方向关键词演化、领域对比
PMC	8,002	开放全文与正文片段增强	RAG 证据、全文片段检索、医学深读
Crossref	8,500	DOI 与期刊出版元数据覆盖广	DOI 去重、出版源补全、跨源校验
DOAJ	8,500	开放期刊文章与开放获取元数据	OA 覆盖、开放科学视角、摘要补充




图 1 当前 6 个公开来源的 50,498 条 raw records 采集规模。

2.2 字段完整度基线

来源	标题	摘要/摘要索引	作者	年份	正文片段
OpenAlex	8,499	8,500	8,480	8,498	0
arXiv	8,496	8,496	8,496	8,496	0
PubMed	8,500	8,334	8,492	8,500	0
PMC	8,002	4,746	7,982	8,002	4,542
Crossref	8,500	165	8,459	8,500	0
DOAJ	8,499	8,364	8,490	8,490	0




图 2 按来源统计的关键字段完整度矩阵。

2.3 标准化 Schema

当前分析字段: paper_id, title, abstract, authors, year, keywords, field, full_text

RAG/Agent 增强字段: doi, venue, url, citation_count, author_ids, institutions, text_source, chunk_count

这个 schema 是分析报告与科研智能体系统之间的共同接口。报告侧依赖它生成统计图表和洞察, 智能体侧依赖它构建检索证据、推荐解释、趋势 API 和知识图谱。下一轮数据层工作会把 DOI、正文来源、引用数、机构与 chunk 级字段补齐, 为 RAG 和 Agent 工具调用铺底。

3 文献分布分析

分析目标

文献分布分析回答三个问题：文献在时间上如何集中，在计算机、生物医学、材料科学三大领域中如何分布，以及不同公开来源是否存在明显年份偏置。

3.1 近五年年份分布

年份分布采用 2022–2026 作为近五年分析窗口。原始数据中保留了少量历史年份和未来年份噪声，但趋势图只展示当前赛题口径内的有效年份，避免被异常元数据拉宽时间轴。

- 近五年总量趋势线：观察 2022–2026 的研究增长和数据覆盖断点。
- 领域-年份热力图：比较计算机、生物医学、材料科学在近五年的年度结构变化。
- 来源-年份热力图：识别某些来源在近五年窗口内的年份偏置。




图 3 2022–2026 近五年文献年份分布。

当前分析资产包含 50,498 条 raw records; 其中 41,435 条落在 2022–2026 分析窗口内。正式智能体语料经跨源去重后包含 49,067 条记录, 其中 40,137 条为近五年记录。

3.2 领域分布

当前采集 query 已覆盖 AI/CS、生物医学、材料科学三条主线。报告采用 field_seed 作为赛题领域口径, 避免不同数据库原始学科标签粒度不一致造成统计偏移。

领域	当前统计口径
计算机科学	LLM、RAG、知识图谱、图神经网络、信息检索、推荐系统
生物医学	药物发现、生物医学 NLP、临床知识、蛋白设计、公共卫生
材料科学	材料发现、电池材料、催化剂、材料信息学、能源材料




图 4 2022–2026 来源-年份覆盖热力图。




图 5 三大赛题领域的文献规模分布。




图 6 2022–2026 三大领域年度覆盖热力图。

3.3 来源偏差说明

不同公开源天然有不同偏置: arXiv 更偏预印本和计算机科学, PubMed/PMC 更偏生物医学, Crossref 覆盖广但摘要缺失较多, DOAJ 更偏开放期刊。报告中必须把偏差作为方法说明写出来, 否则趋势结论容易被误解为真实学科增长。

4 关键词演化与热点趋势

分析目标

关键词演化是本赛题最容易形成“洞见感”的部分。最终报告不只列 Top-K 关键词, 而要展示关键词如何出现、升温、迁移、分化, 并说明这些变化如何驱动智能体的热点预测和论文推荐。

4.1 关键词处理策略

1. 统一大小写、连字符、复数和同义词, 例如 retrieval-augmented generation 与 retrieval augmented generation 归并。
2. 从标题、摘要、数据库关键词、OpenAlex concepts、arXiv categories 中构建候选词。
3. 使用领域词表过滤高频泛词, 例如 study, method, model。
4. 为每个关键词生成年度频次、增长率、突增分数和代表论文。

4.2 当前图表




图 7 2022–2026 近五年窗口内的高频关键词。

分析项	当前口径	评委看到的价值
关键词 Top-K	全局高频关键词与领域高频关键词	快速理解数据主题结构
关键词年度热力图	行为关键词，列为年份，值为频次或标准化热度	发现主题升温与降温
关键词升温榜	比较 2024–2026 与 2022–2023 的窗口差异	显示趋势预测能力
主题河流图	展示主题簇在年份上的占比变化	形成故事化趋势展示

4.3 热点预测口径

趋势预测不应直接声称“未来一定热门”。更稳妥的表达是：




图 8 2022–2026 高频关键词年度热度矩阵。每一行按自身最大值归一化，用于观察主题升温 and 迁移。




图 9 2022–2026 关键词升温候选榜。

基于近年频次增长、跨领域扩散、代表论文质量、作者合作密度和引用信号, 将候选方向分成“强上升”“稳定增长”“早期萌芽”“可能噪声”四类。当前 PDF 已给出关键词升温候选榜, 后续系统侧将其接入趋势 API 与自然语言解释。

5 作者合作网络分析

分析目标

作者合作网络用于识别核心研究者、跨领域连接者和合作团簇。它是知识图谱查询和论文推荐解释的重要依据，也是数据分析报告中最能体现“科研智能体”差异化的图分析部分。

5.1 网络构建

- **节点**: 作者, 后续可扩展为机构、国家、领域、关键词。
- **边**: 两位作者共同出现在同一篇论文中。
- **边权**: 合作次数、近年合作次数、代表论文质量。
- **节点属性**: 论文数、领域分布、活跃年份、中心性、社区编号。

5.2 核心指标

指标	含义	报告解释方式
Degree	作者直接合作人数	识别高合作度作者
Betweenness	作者连接不同团簇的桥梁能力	识别跨领域连接者
Community	合作社区编号	发现研究团队与方向群落
Temporal Activity	作者按年份的活跃情况	判断作者是否仍处于活跃期

5.3 合作社区与高频合作关系




图 10 2022–2026 作者合作网络规模漏斗。

作者合作边由论文作者列表两两组合得到。为避免一篇大团队论文生成过多虚高边，静态报告图仅纳入作者数不超过 12 的论文，并对每篇论文内的合作关系使用分数化权重。当前作者社区图使用 25,000 条高权重合作边构建核心图，既保留 50 万级候选边的规模依据，又避免 PDF 静态图退化成不可读的全量网络。




图 11 2022–2026 近五年作者合作社区气泡图。




图 12 2022–2026 近五年高频作者合作关系。

6 数据质量与可信度审计

为什么要单独写质量审计

科研文献分析最怕“图很好看，但数据口径不可信”。本报告必须把缺失、重复、来源偏差、字段映射和后续修正策略写清楚，这样数据分析和智能体回答才有可信基础。

6.1 当前质量观察

- 六源已形成 50,498 条 raw records, 标准化后生成 49,067 条跨源去重正式语料。
- arXiv、OpenAlex、DOAJ、PubMed 摘要覆盖较好, 可直接进入摘要级 RAG。
- PMC 当前提供 4,542 条正文片段, 是全文增强和证据链构建的主要来源。
- Crossref 摘要覆盖较低, 但 DOI、出版源和作者元数据覆盖好, 更适合跨源校验与去重。
- 年份图表统一过滤到 2022–2026, 避免历史记录和未来年份噪声影响近五年趋势判断。
- Semantic Scholar 与 CORE 已预留代码入口, 但需要 API key 或更高配额。

6.2 质量矩阵




图 13 摘要与全文覆盖率对比。该图用于明确摘要级分析和全文级 RAG 的证据边界。

风险	表现	处理策略
跨源重复	同一 DOI 或标题在多个来源出现	DOI 优先去重, 标题 + 年份作为次级键
摘要缺失	Crossref 和部分 PMC summary 无摘要	使用 OpenAlex/DOAJ/PubMed 补全, 或降级为元数据证据
领域偏差	来源和 query 对领域分布有影响	报告中保留来源分布图, 趋势按来源归一化
作者歧义	同名作者或缩写作者难以区分	后续引入 ORCID、机构和论文上下文消歧
关键词噪声	高频泛词影响趋势判断	领域词表、停用词、短语归并和人工审计

7 从分析报告到科研智能体

报告不是静态终点

本报告中的每个统计资产都应被科研智能体复用。文献分布进入 Dashboard, 关键词演化进入 Trends, 作者合作网络进入 Graph, 代表论文和证据片段进入 Ask 与 Recommend。

7.1 资产映射

报告资产	系统模块	智能体能力
年份与领域分布	Overview	回答“这个领域近几年发展如何”
关键词年度矩阵	Trends	识别热点、解释趋势、生成综述线索
作者合作图	Graph	查询作者关系、发现合作团簇和桥梁作者
主题模型结果	Ask / Recommend	主题约束检索、相似论文推荐、研究方向扩展
质量审计表	Evidence	在回答中暴露置信度和数据来源限制

7.2 演示叙事

最终演示可以采用一条研究问题贯穿：

“Retrieval-Augmented Generation 在生物医学和材料科学中的研究趋势是否正在上升？关键论文、核心作者和潜在交叉机会是什么？”

演示流程：先在数据报告中展示趋势证据，再进入系统前端进行自然语言追问，随后打开作者网络与推荐结果，最后由智能体生成带证据引用的研究机会总结。

8 数据层补强与下一步路线

今晚优先级

当前已经跨过约 5 万篇公开论文数据资产基线。下一阶段重点不是继续堆总量, 而是修正年份偏置、提升正文证据覆盖、补齐 RAG/Agent 所需字段, 让后续问答、推荐、趋势和图谱模块建立在更可靠的数据底座上。

8.1 数据层缺口

缺口	当前数值	下一步动作
2022 年记录	1,472	年份过滤回补, 目标接近 8k-10k
2023 年记录	1,690	年份过滤回补, 避免继续扩大 2026 偏置
2024 年记录	2,416	分来源、分领域回补
2025 年记录	4,915	补足到与其他年份同一量级
正文片段记录	4,542	PMC/CORE/开放全文增强, 阶段目标 15k
RAG 增强字段	未完全落表	DOI、venue、URL、引用数、text provenance、chunk 字段

8.2 执行优先级

- 跑 make data-layer-audit, 固化年份、正文、字段覆盖缺口。
- 建立 2022-2025 年份均衡回补批次, 暂停继续追加 2026-heavy 数据。
- 扩展正文与证据片段来源, 先把 full-text/evidence records 推向 15k。
- 升级 canonical schema, 显式落 doi, venue, url, citation_count, text_source, chunk_count。
- 在稳定数据层上构建 RAG chunks、FTS/vector index、趋势模型、推荐特征和图谱资产。

8.3 最终报告验收清单

验收项	标准
可复现	一条命令生成数据统计表、图表资产和 PDF
可解释	每个结论注明数据来源、统计口径和不确定性
有洞见	不停留在数量统计, 给出趋势、迁移、合作和机会判断
能联动系统	报告图表对应系统接口和前端交互模块
适合评审	前几页能快速呈现数据真实度、分析深度和产品价值