


SciScope 科技文献数据分析报告

近五年公开科技文献的分布、主题演化与合作网络

ANALYTIC FRAMEWORK



MAIN FINDINGS

年份覆盖均衡 2022-2026 各年均 超过 30,000 条	领域结构清晰 计算机、生物医学、 材料三线可比较	热点正在分化 LLM、RAG、知识 图谱等主题升温	合作网络可解释 分数计数降低长 作者名单偏差
---	---------------------------------------	--	-------------------------------------

报告主线

本报告以数据分析为核心, 依次呈现数据覆盖、文献分布、关键词和主题演化、作者合作网络以及结论可信度边界。
所有结论均限定在公开数据、近五年窗口和当前字段完整度之内。

分析对象	公开科技文献元数据、摘要、作者、关键词、年份、来源及部分正文片段
核心窗口	2022-2026 年, 覆盖计算机科学、生物医学、材料科学三类方向
报告目标	识别数据覆盖结构、热点主题变化、作者合作格局与结论可信边界

目录

1 核心发现	3
1.1 可直接采用的结论	3
2 研究问题与分析口径	4
2.1 研究问题	4
2.2 分析窗口	4
2.3 统计原则	4
3 数据覆盖与字段质量	5
3.1 来源结构	5
3.2 字段完整度	5
3.3 数据质量初判	6
4 文献分布分析	7
4.1 年份分布	7
4.2 领域分布	7
4.3 来源偏差	7
5 关键词演化与热点趋势	9
5.1 处理口径	9
5.2 高频与升温主题	9
5.3 热点分层	12
5.4 趋势表达原则	12
6 作者合作网络分析	13
6.1 网络构建口径	13
6.2 网络指标	13
6.3 合作社区与高频合作	13
6.4 核心作者与桥接作者候选	15
7 数据质量与结论可信度	16
7.1 主要质量观察	16
7.2 摘要与正文覆盖	16
7.3 可信度分层	17
8 综合发现与研究启示	18
8.1 发现一: 近五年数据覆盖较均衡	18
8.2 发现二: 热点主题呈现“平台化 + 场景化”双重特征	18

8.3	发现三: 合作网络集中与分散并存	18
8.4	发现四: 材料科学需要归一化解读	18
8.5	研究启示	18
9	结论、局限与后续数据建议	19
9.1	主要结论	19
9.2	局限	19
9.3	后续数据建议	19
9.4	最终判断	20

1 核心发现

分析摘要

本报告围绕近五年公开科技文献展开数据分析。当前样本覆盖 6 个公开来源、169,324 条原始记录和 160,488 条跨源去重语料, 其中 151,556 条位于 2022–2026 年主分析窗口。整体上, 年份覆盖已经较均衡, 领域结构以计算机科学和生物医学为主, 材料科学样本相对较少; 因此主题变化和领域比较均采用归一化口径辅助解释。

分析问题	主要发现
数据规模与覆盖	数据规模超过 5 万篇基线, 2022–2026 每年均超过 30,000 条分析记录, 可支撑近五年趋势观察。
领域结构	计算机科学 75,493 条、生物医学 64,858 条、材料科学 28,096 条; 材料科学占比较低, 需要避免只用绝对频次判断热度。
热点主题	retrieval augmented generation、large language model、prompt engineering、vision language model、knowledge graph 等方向在融合术语信号、归一化趋势和主题模型中同时出现。
作者合作	作者合作网络规模大但分布不均, 分数计数后仍能识别出高合作度作者、桥接作者和稳定社区。
质量边界	摘要覆盖率为 83.22%, 正文片段覆盖率为 8.40%; 摘要级结论可信度较高, 全文级深读仍受来源差异影响。

1.1 可直接采用的结论

- **规模结论:** 当前数据已经满足近五年、多来源、多领域的统计分析需要。
- **趋势结论:** LLM、RAG、prompt engineering、vision language model 等主题具有明确上升信号; 这些结论来自显式关键词、题名摘要术语和主题模型的交叉支持, 但仍应表述为候选趋势而非确定预测。
- **网络结论:** 作者合作网络显示出明显社区结构, 适合用于识别合作团簇和跨领域连接者。
- **质量结论:** 来源偏差、关键词噪声和作者同名问题会影响细粒度排名, 因此核心结论应以趋势和结构为主, 少做单点绝对判断。

2 研究问题与分析口径

报告定位

本报告是一份以数据分析为中心的科技文献观察报告，关注公开文献数据本身呈现出的结构、变化和限制。报告不把数据处理过程作为叙事重点，而是围绕“覆盖是否均衡、主题如何演化、合作网络如何组织、哪些结论可信”四个问题展开。

2.1 研究问题

问题	分析对象	解释重点
数据覆盖是否充分	来源、年份、领域、字段完整度	判断样本是否适合做近五年趋势观察。
研究热点如何变化	融合术语年度占比、动量分数、主题模型	区分稳定主题、快速升温主题和可能噪声。
合作网络如何组织	作者合作边、中心性、社区结构	识别核心作者、桥接作者与合作团簇。
结论边界在哪里	摘要、正文、关键词、作者字段覆盖	明确哪些结论可信，哪些只作为候选信号。

2.2 分析窗口

报告采用 2022–2026 年作为主分析窗口。该窗口与赛题给出的近五年文献场景一致，同时能覆盖大语言模型、检索增强生成、知识图谱和材料信息学等方向的快速变化期。少量历史记录、未来年份和来源异常不直接删除，但只进入质量审计，不进入趋势图的主口径。

2.3 统计原则

- 来源比较看覆盖结构，不把某个来源的增长直接解释为整个学科的增长。
- 关键词趋势同时看显式关键词和题名摘要术语信号，避免年度总量变化或关键词字段滞后造成误判。
- 作者合作网络采用分数权重和长作者名单过滤，降低大型团队论文对网络密度的放大效应。
- 主题模型只作为结构验证，不把单一模型输出当作唯一事实。

3 数据覆盖与字段质量

当前数据基线

本轮数据覆盖 OpenAlex、arXiv、PubMed、PMC、Crossref 和 DOAJ 六个公开来源, 共形成 169,324 条原始记录。标准化后进入分析层的记录为 168,447 条, 跨源去重后保留 160,488 条正式语料, 其中 151,556 条位于 2022–2026 年主分析窗口。

3.1 来源结构

来源	记录数	数据特征	分析价值
OpenAlex	41,477	综合学术元数据覆盖较广	适合支撑总体分布和跨领域比较
arXiv	29,760	预印本多, 计算机科学和交叉方向集中	适合观察快速升温的新兴主题
PubMed	28,163	生物医学摘要和出版信息较完整	适合医学方向主题演化分析
PMC	29,227	开放全文片段较多	适合补充正文级证据和深度文本分析
Crossref	28,500	DOI 和出版元数据覆盖广	适合跨源校验和出版来源分析
DOAJ	11,320	开放期刊文章集中	适合观察开放获取文献结构




图 1 六个公开来源的标准化分析记录规模。OpenAlex 规模最大, DOAJ 规模最小, 后续跨来源比较需注意来源结构差异。

3.2 字段完整度

标题、作者和年份字段整体完整度较高, 是分布统计和作者网络分析的主要基础。摘要覆盖率为 83.22%, 可以支撑摘要级主题和趋势分析。正文片段覆盖率为 8.40%, 适合做高质量证据补充, 但暂不适合把全文级结论推广到全部来源。

来源	标题	摘要	作者	年份	正文片段
OpenAlex	41,475	41,472	41,415	41,475	55
arXiv	29,760	29,760	29,760	29,760	36
PubMed	28,163	27,547	28,131	28,162	17
PMC	29,227	15,938	29,121	29,226	13,925
Crossref	28,500	14,311	28,044	27,280	0
DOAJ	11,319	11,155	11,310	11,310	121




图 2 各来源关键字段完整度矩阵。颜色越深表示覆盖越高；Crossref 的摘要和关键词覆盖相对较弱，PMC 的正文片段优势明显。

3.3 数据质量初判

- 数据总量和近五年年份覆盖已经足以支撑宏观分布、主题趋势和作者网络分析。
- 摘要覆盖显著高于正文覆盖, 因此关键词和主题结论主要以题名、摘要和作者关键词为依据。
- 来源之间存在天然偏向: arXiv 偏预印本和计算机科学, PubMed/PMC 偏生物医学, Crossref 偏出版元数据, DOAJ 偏开放期刊。
- 材料科学样本量低于计算机科学和生物医学, 对材料方向的热点解释应更多依赖归一化占比和代表性论文, 少做绝对规模比较。

4 文献分布分析

分析目标

文献分布分析用于判断样本是否适合开展趋势研究。这里重点观察三个维度：年份覆盖是否均衡，三大领域是否具备可比性，不同来源是否带来明显结构偏差。

4.1 年份分布

2022–2026 年是本报告的主分析窗口。五个年份均超过 30,000 条分析记录：2022 年 31,038 条、2023 年 30,320 条、2024 年 30,767 条、2025 年 32,980 条、2026 年 34,277 条。整体看，年份覆盖没有明显断层，可以支持年度趋势和主题动量分析。




图 3 2022–2026 年文献数量分布。年度规模较均衡，2025–2026 年略高，有利于观察近年热点变化。

4.2 领域分布

按赛题三大领域口径统计，计算机科学 75,493 条、生物医学 64,858 条、材料科学 28,096 条。计算机科学和生物医学构成主要样本基础，材料科学占比较低但仍具备趋势观察价值。由于领域规模不均衡，报告在比较热点时优先使用年度归一化占比，避免大领域天然占优。

领域	主要观察方向
计算机科学	大语言模型、检索增强生成、知识图谱、图神经网络、信息检索、推荐系统
生物医学	药物发现、生物医学文本挖掘、临床知识、蛋白设计、公共卫生
材料科学	材料发现、电池材料、催化剂、材料信息学、能源材料

4.3 来源偏差

来源偏差是本报告解释趋势时必须保留的前提。arXiv 对快速发表和计算机方向更敏感，PubMed/PMC 更集中于生物医学，Crossref 的出版元数据更广但摘要和关键词较弱，DOAJ 体现开放期刊样本。因而本报告不会把单一来源的增长直接等同于学科整体增长，而是结合来源分布、领域分布和归一化趋势共同判断。




图 4 来源-年份覆盖热力图。不同来源在年份上的覆盖节奏不同，因此跨来源结论需要同时报告来源结构。




图 5 三大领域文献规模分布。计算机科学和生物医学占比较高，材料科学样本较少。




图 6 三大领域年度覆盖热力图。各领域在近五年内均有持续记录，但规模差异需要在解释热点时纳入考虑。

5 关键词演化与热点趋势

分析目标

关键词和主题演化用于识别近五年科技文献中的热点变化。本章不只展示高频词，还关注年度归一化占比、近期动量和主题模型是否给出一致证据，以区分真实升温 and 样本规模变化造成的表现增长。

5.1 处理口径

1. 对大小写、连字符、复数和常见同义表达进行归并，例如 retrieval-augmented generation、RAG 与 retrieval augmented generation 视为同一方向。
2. 同时使用显式关键词和题名摘要中的受控术语信号，避免新近论文因关键词尚未完整入库而被低估。
3. 过滤 study、method、model 等泛词，避免高频但低信息量的词主导结论。
4. 对每个主题词同时计算融合文档数、显式关键词支持数、文本术语支持数、年度占比和近期动量。

从整体结果看，retrieval augmented generation、large language model、prompt engineering、vision language model、knowledge graph 等方向同时具有较高频次和较强近期动量。它们不仅出现在词频统计中，也能在年度归一化趋势和主题模型中得到支持，因而比单纯高频词更适合作为热点候选。

2026 年需要单独解释：截至 2026 年 6 月 21 日，该年度尚未结束，且新近论文的关键词和索引记录存在更新滞后。报告主图已使用显式关键词与题名摘要术语的融合信号进行修正：2026 年融合信号比单看显式关键词增加约 22.7%。因此 2026 年不再被简单视为“关键词缺失”，但仍只作为未完整年度的早期信号，不与完整年度作机械对比。

5.2 高频与升温主题




图 7 2022–2026 年高频融合主题词。融合信号同时吸收显式关键词和题名摘要术语，用于降低关键词字段滞后的影响。




图 8 融合主题词年度热度矩阵。每一行按自身最大值归一化；2026 年为截至 6 月 21 日的未完整年度，只作为早期信号。




图 9 融合主题词近期动量。该指标比较 2024–2025 与 2022–2023 的相对变化，不把 2026 年末完整数据纳入完整年度动量。




图 10 代表性融合主题词年度归一化文档占比。归一化后仍持续上升的主题更可能反映真实研究关注变化。




图 11 主题模型年度占比。主题模型用于检查热点词是否对应稳定的语义结构，而不是孤立词频波动。

5.3 热点分层

候选方向	数据信号	解释边界
RAG	融合信号覆盖 5,579 篇候选文档，其中 628 篇具有显式关键词支持，题名摘要信号在近年明显增强	强上升信号，但需要注意计算机和医学方向样本共同推动。
LLM	融合信号覆盖 17,600 篇候选文档，其中 2,081 篇具有显式关键词支持，与 prompt engineering、multimodal learning 共同升温	稳定增长信号，需区分通用模型热度和具体科研应用。
Knowledge graph	融合信号覆盖 8,288 篇候选文档，显式关键词和题名摘要均提供支持，作者合作社区中也能观察到相关团簇	稳定主题结构，更适合解释知识组织和跨学科连接。
Materials informatics	materials informatics、battery、catalyst discovery 等术语在材料方向具有持续信号，但更多依赖题名摘要识别	样本规模低于计算机和生物医学，应优先看归一化趋势。

5.4 趋势表达原则

本报告将热点判断表述为“上升信号”“稳定增长”“早期萌芽”或“可能噪声”，不使用确定性预测。一个方向只有在频次、年度占比、主题模型和代表论文多个证据同时支持时，才进入强上升候选。

6 作者合作网络分析

分析目标

作者合作网络用于观察科研协作的组织方式。相比简单统计高产作者，网络分析更关注作者之间如何连接、哪些作者处在社区内部核心位置、哪些作者连接不同主题或领域。

6.1 网络构建口径

- **节点**: 作者姓名。
- **边**: 两位作者共同出现在同一篇论文中。
- **边权**: 同时考虑共同论文次数和分数化合作强度。
- **过滤**: 正文主图排除作者数超过 12 的论文, 避免大型团队论文生成过多两两合作边。

在全量候选网络中，作者合作边超过千万级。为了让静态报告图可解释，本章只展示近五年窗口内的核心合作结构，并采用分数计数降低长作者名单造成的网络虚高。中心性和社区发现用于识别候选核心作者和桥接作者，不作为未经消歧的最终权威排名。

6.2 网络指标

指标	含义	解释方式
Degree	作者直接合作人数	识别合作范围较广的作者。
Betweenness	作者连接不同团簇的桥梁能力	识别跨主题或跨领域连接者。
Community	网络社区划分结果	观察研究团队、主题群落和合作圈层。
Temporal Activity	作者活跃年份分布	判断节点是否仍处于近年活跃状态。

6.3 合作社区与高频合作




图 12 作者合作网络规模漏斗。从近五年论文到核心合作图逐步压缩，以保证网络图具有可读性。




图 13 作者合作社区气泡图。气泡位置表示主导领域，大小综合反映社区论文数和合作强度；浅色气泡用于保证社区标签可读。




图 14 近五年高频作者合作关系。分数化权重用于降低长作者名单论文的影响。

6.4 核心作者与桥接作者候选

作者	论文数	合作者数	网络解释
Yangqiu Song	44	121	计算机科学方向高合作度节点, 与多个知识表示和文本分析主题相连。
Halil Kilicoglu	36	65	生物医学文本挖掘社区中的稳定节点, 合作关系集中但清晰。
Karin Verspoor	35	294	生物医学文本挖掘方向连接度较高, 具备桥接作者特征。
Rui Zhang	214	1,754	高产高连接节点, 需要警惕同名作者聚合。
Kai Wang	138	901	合作范围较广, 同样需要结合机构和论文主题进一步复核。

上述作者应理解为“候选核心/桥接节点”。由于当前作者消歧主要依赖姓名标准化, 中文名、缩写名和同名作者可能被合并, 因而作者排名不宜被解释为精确个人影响力排名。

7 数据质量与结论可信度

质量审计目的

数据分析报告的可信度取决于统计口径是否清楚、字段缺失是否透明、来源偏差是否被纳入解释。本章将质量问题转化为结论边界,明确哪些发现可以直接采用,哪些只能作为候选信号。

7.1 主要质量观察

- 六个公开来源共形成 169,324 条原始记录,去重后保留 160,488 条正式语料,重复记录比例可控。
- 标题、作者、年份字段完整度较高,适合开展文献分布和作者合作网络分析。
- 摘要覆盖率为 83.22%,可支撑主题、融合术语和趋势分析。
- 正文片段覆盖率为 8.40%,且高度集中于开放全文来源,因此全文级结论只作为补充证据。
- 2022–2026 五个年份均超过 30,000 条分析记录,年份覆盖均衡性较好。
- 少量异常年份和来源缺失不会进入主趋势图,但保留为质量说明。

7.2 摘要与正文覆盖




图 15 摘要与正文片段覆盖率对比。摘要覆盖较高,正文片段覆盖较低且来源集中,因此全文级分析需要单独标注证据范围。

风险	表现	处理方式
跨源重复	同一论文可能出现在多个来源中	优先使用 DOI 去重, 再用标题和年份辅助合并。
摘要缺失	部分出版元数据来源摘要不足	相关论文保留在分布统计中, 但不作为主题解释的核心证据。
领域偏差	来源和检索主题会影响领域分布	使用来源分布图和领域分布图共同解释。
作者歧义	同名作者或缩写作者难以完全区分	作者榜单只作为候选核心节点, 不作精确个人排名。
关键词噪声	泛词、缩写和分类词可能进入高频榜	通过停用词、同义词归并、题名摘要交叉验证和年度归一化降低影响。
新近关键词滞后	2026 年显式关键词信号弱于完整年度	使用题名摘要术语补偿, 同时将 2026 年标记为未完整年度。
超长作者名单	大团队论文会放大合作边数量	正文主图采用长作者名单过滤和分数化边权。

7.3 可信度分层

层级	可采用结论	边界说明
高可信	来源规模、年份覆盖、领域分布、摘要覆盖、融合术语年度归一化趋势	来自大样本统计, 口径稳定, 可复核。
中可信	热点主题、作者合作社区、桥接作者候选、主题年度占比	受主题模型选择和作者消歧影响, 适合做结构性解释。
候选信号	未来研究机会、跨领域扩散、潜在合作者	需要代表论文和人工复核支持, 不宜写成确定预测。
暂不强写	精确机构网络、单个作者影响力排名、全文级跨来源比较	当前机构字段和正文覆盖尚不均衡。

8 综合发现与研究启示

综合判断

结合分布、关键词、主题和作者网络四类证据，当前数据呈现出一个清晰结构：计算机科学和生物医学贡献主要样本规模，材料科学样本较小但具备跨领域潜力；LLM、RAG、知识图谱等主题处于明显活跃期；作者合作网络中既有稳定社区，也存在需要消歧复核的高连接节点。

8.1 发现一：近五年数据覆盖较均衡

2022–2026 年每年均超过 30,000 条分析记录，没有明显年份断点。该特点使年度趋势、融合术语动量和主题占比具备较好的比较基础。相比继续追求总量扩张，当前更重要的是控制来源偏差和字段完整度差异。

8.2 发现二：热点主题呈现“平台化 + 场景化”双重特征

LLM 和 RAG 代表平台型方法快速升温，prompt engineering、vision language model 和 knowledge graph 则体现出方法向具体科研场景迁移的趋势。生物医学和材料科学中的相关主题虽然规模不同，但都能观察到方法迁移信号，说明跨领域应用是后续值得关注的方向。

8.3 发现三：合作网络集中与分散并存

作者网络既存在高连接度节点，也存在多个领域内部社区。高连接作者不一定等于真实单个研究者影响力最高，因为同名和缩写会带来聚合风险；但这些节点适合作为人工复核入口，帮助识别跨主题桥接者和稳定合作团簇。

8.4 发现四：材料科学需要归一化解读

材料科学样本量低于计算机科学和生物医学，直接比较绝对词频会低估部分材料方向主题。对于 battery、catalyst、materials discovery 等方向，更合理的解释方式是观察领域内占比、近年动量和代表论文，而不是只看全局排行。

8.5 研究启示

启示	数据依据
热点识别应使用多证据交叉	显式关键词、题名摘要术语、年度占比、近期动量和主题模型需要共同支持。
跨领域机会主要出现在方法迁移处	LLM、RAG、知识图谱等方法在不同领域中出现相似上升信号。
合作网络适合发现候选桥接者	中心性和社区结构能提示跨团簇连接，但需要作者消歧复核。
全文覆盖决定深度分析边界	摘要级趋势可信度较高，全文级细粒度解释仍需扩大正文覆盖。

9 结论、局限与后续数据建议

总体结论

当前数据已经能够支撑一份以近五年科技文献为对象的结构化分析报告。最可靠的结论集中在来源规模、年份覆盖、领域结构、摘要级主题趋势和作者合作社区;需要谨慎解释的部分集中在全文级比较、单个作者影响力和未来趋势预测。

9.1 主要结论

- 数据规模充分:** 160,488 条去重语料和 151,556 条近五年语料为分布分析和趋势分析提供了稳定基础。
- 年份覆盖均衡:** 2022–2026 各年均超过 30,000 条记录, 年度趋势具有可比性。
- 领域结构不完全均衡:** 计算机科学和生物医学样本较多, 材料科学样本较少, 需要归一化解释。
- 热点主题有明显上升信号:** LLM、RAG、prompt engineering、vision language model、knowledge graph 等方向在多个统计口径下均较活跃。
- 作者合作网络具有社区结构:** 分数计数后仍能观察到核心合作社区和桥接作者候选, 但作者消歧仍是限制。

9.2 局限

局限	影响	报告处理方式
来源偏差	不同来源覆盖领域和年份节奏不同	所有趋势结论同时参考来源和领域分布。
正文覆盖不足	全文级深读不能代表全部语料	全文片段只作为补充证据, 不替代摘要级统计。
作者同名问题	高连接作者可能由同名聚合造成	作者排名表述为候选节点, 不作绝对权威判断。
关键词噪声	泛词和缩写可能干扰热点榜	采用归并、过滤、题名摘要术语和归一化趋势交叉验证。
主题模型不唯一	不同模型可能给出不同主题边界	主题模型作为结构验证, 不作为唯一结论来源。

9.3 后续数据建议

方向	建议
正文覆盖	优先提升开放全文和可访问正文片段覆盖, 使全文级主题解释更均衡。
字段补全	补充期刊、机构、引用量和标准化作者标识, 支撑更细粒度的影响力分析。
作者消歧	对高连接作者和桥接作者进行机构、主题和署名上下文复核。
关键词治理	持续维护同义词、缩写、领域停用词和题名摘要术语表, 降低关键词噪声。
趋势验证	使用代表论文和跨来源一致性检验上升主题, 避免单一来源波动造成误判。

9.4 最终判断

本报告最稳健的价值不在于给出单个“最热门词”或“最权威作者”，而在于建立一套可解释的数据分析框架：先确认来源和年份覆盖，再用融合术语和归一化趋势识别主题变化，再用作者网络解释合作结构，最后用质量审计限定结论边界。基于这一框架，LLM、RAG、知识图谱及其跨领域应用可以作为当前最值得关注的上升方向。