

数据分析报告

近五年公开科技文献的
分布、主题演化与合作网络

CORPUS AT A GLANCE / 核心规模

168,447

IN THIS REPORT

文献分布 · 关键词演化 · 作者合作网络 · 数据质量边界

目录

1 核心发现	3
1.1 可直接采用的结论	3
2 研究问题与分析口径	4
2.1 研究问题	4
2.2 分析窗口	4
2.3 统计原则	4
2.4 提交与复现边界	4
3 数据覆盖与字段质量	5
3.1 来源结构	5
3.2 字段完整度	5
3.3 数据质量初判	6
4 文献分布分析	7
4.1 年份分布	7
4.2 领域分布	7
4.3 来源偏差	7
5 关键词演化与热点趋势	10
5.1 处理口径	10
5.2 高频与升温主题	10
5.3 热点分层	16
5.4 趋势判定口径	16
6 作者合作网络分析	16
6.1 网络构建口径	16
6.2 网络指标	17
6.3 合作社区与高频合作	17
6.4 核心作者与桥接作者候选	20
6.5 参数敏感性	20
7 数据质量与结论可信度	21
7.1 主要质量观察	21
7.2 摘要与正文覆盖	21
7.3 网络稳健性检查	22
7.4 可信度分层	22
8 应用价值与技术创新	23

8.1	社会效益	23
8.2	经济效益	23
8.3	技术创新	24
9	数据资产到智能体的映射	25
9.1	资产映射表	25
9.2	可进入智能体的稳定结论	25
9.3	进入回答时的边界模板	25
10	结论、局限与后续数据建议	26
10.1	主要结论	26
10.2	局限	26
10.3	后续数据建议	26
10.4	最终判断	26
11	数据来源与参考文献	28
11.1	数据来源	28
11.2	分析方法来源	28

1 核心发现

分析摘要

本报告围绕公开科技文献构建近五年的可复核分析闭环。样本覆盖 6 个公开来源 + 讯飞交付包、174,890 条原始记录和 174,013 条分析语料, 其中 160,908 条位于 2022–2026 年主分析窗口; 报告先给出覆盖与偏差, 再给出趋势、主题和网络结论, 最后限定结论边界。**口径说明:**2026-08-14 讯飞交付包 5,566 篇预印本 PDF(bioRxiv/medRxiv/arXiv) 已并入全量分析管线重算 (趋势/图谱/主题均含讯飞增量), 运行时 PostgreSQL 同步为 papers=164,730、chunk_embeddings=413,971。

从社会效益看, 本报告把分散、多源、多语言的科技文献信号转化为可复核的热点监测和科研治理证据; 从经济效益看, 它可降低人工检索、筛读、查新和年度情报报告的重复成本; 从技术创新看, 它用融合术语、归一化趋势、生命周期、共现网络、主题模型和质量审计构成多证据闭环, 避免只凭单一词频榜判断热点。所有结论均限定在公开数据、字段完整度和 2026 年末完整年度 (YTD) 边界内。

分析问题	主要发现
数据规模与覆盖	分析语料达到 174,013 条 (含讯飞交付包 5,566 条), 2022–2026 每年均超过 30,000 条分析记录, 可支撑近五年趋势观察。
领域结构	计算机科学 75,493 条、生物医学 69,794 条 (含讯飞预印本增量 4,936)、材料科学 28,096 条; 材料科学占比较低, 需要避免只用绝对频次判断热度。
热点主题	retrieval augmented generation、large language model、prompt engineering、vision language model、knowledge graph 等方向在融合术语、归一化趋势、共现结构和主题模型中同时出现。
作者合作	作者合作网络包含 10,513,964 条候选合作边; 分数计数后仍能识别高合作度作者、桥接作者和稳定社区。
质量边界	合并语料摘要覆盖率 85.64%, 正文片段覆盖率 13.36%; 摘要级结论可信度较高, 全文级深读经讯飞预印本增量 (5,559/5,566 篇带全文) 后明显扩充, 但总体仍受来源差异影响。

1.1 可直接采用的结论

- **规模结论:** 当前数据已经满足近五年、多来源、多领域的统计分析需要。
- **趋势结论:** 大语言模型 (LLM)、检索增强生成 (RAG)、prompt engineering、vision language model 等主题具有明确上升信号; 这些结论来自显式关键词、题名摘要术语、共现网络和主题模型的交叉支持, 但仍应表述为候选趋势而非确定预测。
- **网络结论:** 作者合作网络显示出明显社区结构, 适合用于识别合作团簇和跨领域连接者。
- **质量结论:** 来源偏差、关键词噪声和作者同名问题会影响细粒度排名, 因此核心结论应以趋势和结构为主, 少做单点绝对判断。
- **价值结论:** 报告可服务科研管理、科技情报、产业研发、投资初筛和政策制定, 将分散文献记录转化为可复核的热点监测和方向研判证据。
- **创新结论:** 报告采用融合关键词信号、年度归一化、动量/burst、生命周期、共现网络、主题模型和质量审计的多证据框架, 避免只凭单一词频榜判断热点。

I 2 研究问题与分析口径

报告定位

本报告是一份以数据分析为中心的科技文献观察报告, 关注公开文献数据本身呈现出的结构、变化和限制。报告不把数据处理过程作为叙事重点, 而是围绕“覆盖是否均衡、主题如何演化、合作网络如何组织、哪些结论可信”四个问题展开。

2.1 研究问题

问题	分析对象	解释重点
数据覆盖是否充分	来源、年份、领域、字段完整度	判断样本是否适合做近五年趋势观察。
研究热点如何变化	融合术语年度占比、动量分数、主题模型	区分稳定主题、快速升温主题和可能噪声。
合作网络如何组织	作者合作边、中心性、社区结构	识别核心作者、桥接作者与合作团簇。
结论边界在哪里	摘要、正文、关键词、作者字段覆盖	明确哪些结论可信, 哪些只作为候选信号。

2.2 分析窗口

报告采用 2022–2026 年作为主分析窗口。该窗口与赛题给出的近五年文献场景一致, 同时能覆盖大语言模型、检索增强生成、知识图谱和材料信息学等方向的快速变化期。少量历史记录、未来年份和来源异常不直接删除, 但只进入质量审计, 不进入趋势图的主口径。

2.3 统计原则

- 来源比较看覆盖结构, 不把某个来源的增长直接解释为整个学科的增长。
- 关键词趋势同时看显式关键词和题名摘要术语信号, 避免年度总量变化或关键词字段滞后造成误判。
- 作者合作网络采用分数权重和长作者名单过滤, 降低大型团队论文对网络密度的放大效应。
- 主题模型只作为结构验证, 不把单一模型输出当作唯一事实。

2.4 提交与复现边界

本报告提交时不把原始 JSONL、处理后全量语料、嵌入向量表或数据库运行目录作为附件上传。原因有二: 一是正式提交要求报告与附件逐文件独立上传且单文件大小受限; 二是数据资产可由开源代码、运行说明和 `Makefile` 流水线重新生成。报告正文保留关键统计结果、图表、口径说明与质量边界, 附件保留源代码、评测结果、图谱/模型小型结果和校验清单, 以保证结论可审阅、过程可复现。

3 数据覆盖与字段质量

当前数据基线

本轮数据覆盖 OpenAlex、arXiv、PubMed、PMC、Crossref 和 DOAJ 六个公开来源 + 讯飞交付包 (source=iflytek)，共形成 174,890 条原始记录。经标准化、异常年份治理和跨源去重后，进入分析层的语料为 174,013 条，其中 160,908 条位于 2022–2026 年主分析窗口。讯飞交付包 5,566 篇预印本 PDF(bioRxiv/medRxiv/arXiv，经 PDF 内嵌元数据解析) 已于 2026-08-14 全链路入库运行时 PostgreSQL(papers=164,730、chunk_embeddings=413,971)，分布/趋势/图谱/主题统计均为合并讯飞后的全量重算结果。

3.1 来源结构

见图 1。来源规模决定后续趋势解释的背景权重，因此跨来源比较必须同时保留来源结构。

来源	记录数	数据特征	分析价值
OpenAlex	41,477	综合学术元数据覆盖较广	适合支撑总体分布和跨领域比较
arXiv	29,760	预印本多，计算机科学和交叉方向集中	适合观察快速升温的新兴主题
PubMed	28,163	生物医学摘要和出版信息较完整	适合医学方向主题演化分析
PMC	29,227	开放全文片段较多	适合补充正文级证据和深度文本分析
Crossref	28,500	DOI 和出版元数据覆盖广	适合跨源校验和出版来源分析
DOAJ	11,320	开放期刊文章集中	适合观察开放获取文献结构
讯飞交付包 (iflytek)	5,566	预印本全文 PDF，经 PDF 内嵌元数据解析 (bioRxiv 3,347 / medRxiv 1,589 / arXiv 531 / OpenAlex 99)	适合补充全文级深读证据与预印本信号




图 1 六个公开来源的标准化分析记录规模 (2026-08-10 快照，不含讯飞增量；讯飞 5,566 条见 2.1 节来源表)。数据来源: data/analysis/source_quality_report.csv；统计窗口为全分析语料 168,447 条。OpenAlex 规模最大，DOAJ 规模最小，后续跨来源比较需注意来源结构差异。

3.2 字段完整度

标题、作者和年份字段整体完整度较高，是分布统计和作者网络分析的主要基础。合并语料 (含讯飞增量) 摘要覆盖率为 85.64%，可以支撑摘要级主题和趋势分析；正文片段覆盖率为 13.36%，其中讯飞预印本 5,559/5,566 篇带全文，使全文级证据明显扩充 (2026-08-10 快照同口径为 87.08%/10.50%)。见图 2。

来源	标题	摘要	作者	年份	正文片段
OpenAlex	41,475	41,472	41,415	41,475	55
arXiv	29,760	29,760	29,760	29,760	36
PubMed	28,163	27,547	28,131	28,162	17
PMC	29,227	15,938	29,121	29,226	13,925
Crossref	28,500	14,311	28,044	27,280	0
DOAJ	11,319	11,155	11,310	11,310	121
讯飞交付包 (iflytek)	5,558	2,339	8,303	2,200	5,559




图 2 各来源关键字段完整度矩阵。数据来源:data/analysis/source_quality_report.csv; 颜色越深表示覆盖越高。Crossref 的摘要和关键词覆盖相对较弱, PMC 的正文片段优势明显。

3.3 数据质量初判

- 数据总量和近五年年份覆盖已经足以支撑宏观分布、主题趋势和作者网络分析。
- 摘要覆盖显著高于正文覆盖, 因此关键词和主题结论主要以题名、摘要和作者关键词为依据。
- 来源之间存在天然偏向: arXiv 偏预印本和计算机科学, PubMed/PMC 偏生物医学, Crossref 偏出版元数据, DOAJ 偏开放期刊。
- 材料科学样本量低于计算机科学和生物医学, 对材料方向的热点解释应更多依赖归一化占比和代表性论文, 少做绝对规模比较。

4 文献分布分析

分析目标

文献分布分析用于判断样本是否适合开展趋势研究。这里重点观察三个维度：年份覆盖是否均衡，三大领域是否具备可比性，不同来源是否带来明显结构偏差。

4.1 年份分布

2022–2026 年是本报告的主分析窗口。五个年份均超过 30,000 条分析记录：2022 年 31,112 条、2023 年 30,396 条、2024 年 31,024 条、2025 年 33,541 条、2026 年 34,835 条（2026-08-14 全量重跑，含讯飞增量；2026 年为年中快照，受预印本收录节奏影响，不与完整年度直接比较）。讯飞增量的 3,366 条因 PDF 无可靠出版日期未进入年份统计，只在总量口径中体现。整体看，年份覆盖没有明显断层，可以支持年度趋势和主题动量分析。年度分布与来源覆盖分别见图 3 和图 4。




图 3 2022–2026 年文献数量分布。数据来源: `data/analysis/summary.json` 与年度统计资产；统计口径为主分析窗口内分析语料。年度规模较均衡，2025–2026 年略高，有利于观察近年热点变化。

4.2 领域分布

按赛题三大领域口径统计，计算机科学 75,493 条、生物医学 69,794 条、材料科学 28,096 条（2026-08-14 全量重跑：讯飞预印本并入生物医学桶 +4,936，其中 bioRxiv 3,347 / medRxiv 1,589；另 630 篇讯飞 arXiv/OpenAlex 未按三大桶归类）。计算机科学和生物医学构成主要样本基础，材料科学占比较低但仍具备趋势观察价值。由于领域规模不均衡，报告在比较热点时优先使用年度归一化占比，避免大领域天然占优。领域总量与年度覆盖见图 5 和图 6。

领域	主要观察方向
计算机科学	大语言模型、检索增强生成、知识图谱、图神经网络、信息检索、推荐系统
生物医学	药物发现、生物医学文本挖掘、临床知识、蛋白设计、公共卫生
材料科学	材料发现、电池材料、催化剂、材料信息学、能源材料

4.3 来源偏差

来源偏差是本报告解释趋势时必须保留的前提。arXiv 对快速发表和计算机方向更敏感，PubMed/PMC 更集中于生物医学，Crossref 的出版元数据更广但摘要和关键词较弱，DOAJ 体现开放期刊样本。因而本报告不会把单一来源的




图 4 来源-年份覆盖热力图。数据来源: `data/analysis/` 年度来源统计资产; 统计窗口为 2022-2026 年。不同来源在年份上的覆盖节奏不同, 因此跨来源结论需要同时报告来源结构。




图 5 三大领域文献规模分布。数据来源: `data/analysis/papers_clean.json` 的领域归类结果; 统计口径为分析语料。计算机科学和生物医学占比较高, 材料科学样本较少。




图 6 三大领域年度覆盖热力图。数据来源: `data/analysis/` 领域-年度统计资产; 统计窗口为 2022–2026 年。各领域在近五年内均有持续记录, 但规模差异需要在解释热点时纳入考虑。

增长直接等同于学科整体增长, 而是结合来源分布、领域分布和归一化趋势共同判断。

5 关键词演化与热点趋势

口径注记

本章趋势与主题统计为 2026-08-14 全量重跑结果 (174,013 条, 含讯飞增量)。讯飞预印本以生物医学方向为主, 对 RAG/LLM 等计算机方向热点的排序无实质影响, 生物医学类术语的文档基数小幅上升。

分析目标

关键词和主题演化用于识别近五年科技文献中的热点变化。本章不只展示高频词, 还关注年度归一化占比、近期动量和主题模型是否给出一致证据, 以区分真实升温 and 样本规模变化造成的表现增长。

5.1 处理口径

本章先对大小写、连字符、复数和常见同义表达进行归并, 例如 retrieval-augmented generation、RAG 与 retrieval augmented generation 视为同一方向; 再融合显式关键词和题名摘要中的受控术语信号, 过滤 study、method、model 等低信息量泛词。每个主题词同时计算融合文档数、显式关键词支持数、文本术语支持数、年度占比、近期动量、共现网络位置、burst window、生命周期阶段和语义漂移代理指标。

从整体结果看, retrieval augmented generation、large language model、prompt engineering、vision language model、knowledge graph 等方向同时具有较高频次和较强近期动量。它们不仅出现在词频统计中, 也能在年度归一化趋势和主题模型中得到支持, 因而比单纯高频词更适合作为热点候选。作者边和关键词边均使用增量缓存保存单篇论文的边贡献; 数据继续扩充时, 未变化论文可复用已有边贡献, 只重算新增或内容变化的论文。

2026 年需要单独解释: 截至 2026-08-14 全量重跑 (含讯飞增量), 该年度尚未结束, 且新近论文的关键词和索引记录存在更新滞后。报告主图已使用显式关键词与题名摘要术语的融合信号进行修正, 2026 年融合信号比单看显式关键词增加约 23.4%; 因此 2026 年只作为未完整年度的早期信号, 不与完整年度作机械对比。

5.2 高频与升温主题

本节按”频次 -> 年度热度 -> 近期动量 -> 共现结构 -> 生命周期/主题模型”的顺序阅读。图 7 到图 10 给出主趋势, 图 11 以后用于解释结构与边界。




图 7 2022-2026 年高频融合主题词。数据来源: `data/analysis/keyword_trends.csv`; 统计口径为显式关键词与题名摘要术语的融合信号。




图 8 融合主题词年度热度矩阵。数据来源: `data/analysis/keyword_trends.csv`; 每行按自身最大值归一化, 2026 年仅作作为早期信号。




图 9 融合主题词近期动量。数据来源: `data/analysis/keyword_trends.csv`; 该指标比较 2024–2025 与 2022–2023 的相对变化, 不把 2026 年末完整数据纳入完整年度动量。





图 10 代表性融合主题词年度归一化文档占比。数据来源: `data/analysis/keyword_trends.csv`; 归一化后仍持续上升的主题更可能反映真实研究关注变化。

Core Keyword Co-occurrence Network



Node size: weighted co-occurrence degree. Color: keyword community. Edge width: fractional paper co-occurrence.

图 11 关键词共现网络。数据来源: `data/analysis/keyword_network.*`; 节点大小表示共现加权重, 节点颜色表示关键词社区, 边宽表示同篇论文中的分数化共现强度。该图用于识别 RAG、knowledge graph、question answering、clinical search 等主题之间的结构连接。




图 12 关键词生命周期阶段。横线表示首次出现、峰值年份和最近活跃年份的区间，圆点大小表示融合文档支持度，阶段分为 emergence、growth、maturity、decline。




图 13 关键词年度突发窗口。该图标出年度增长、萌发或回落较强的主题词，用于把“长期高频”与“近期突然变化”区分开。




图 14 主题模型年度占比。主题模型用于检查热点词是否对应稳定的语义结构，而不是孤立词频波动。

5.3 热点分层

候选方向	数据信号	解释边界
RAG	融合信号覆盖 5,588 篇候选文档, 其中 628 篇具有显式关键词支持, 题名摘要信号在近年明显增强	强上升信号, 但需要注意计算机和医学方向样本共同推动。
LLM	融合信号覆盖 17,667 篇候选文档, 其中 2,081 篇具有显式关键词支持, 与 prompt engineering、multimodal learning 共同升温	稳定增长信号, 需区分通用模型热度和具体科研应用。
Knowledge graph	融合信号覆盖 8,295 篇候选文档, 显式关键词和题名摘要均提供支持, 作者合作社区中也能观察到相关团簇	稳定主题结构, 更适合解释知识组织和跨学科连接。
Materials informatics	materials informatics、battery、catalyst discovery 等术语在材料方向具有持续信号, 但更多依赖题名摘要识别	样本规模低于计算机和生物医学, 应优先看归一化趋势。

5.4 趋势判定口径

本报告不把单一高频词直接写成热点, 而是先消除年度样本规模差异, 再观察近期动量与多证据一致性。设关键词 k 在年份 y 的融合命中文档数为 $n_{k,y}$, 当年分析文献总数为 N_y , 年度归一化热度定义为:

$$h_{k,y} = \frac{n_{k,y}}{N_y}$$

其中 $h_{k,y}$ 用于比较不同年份的相对关注度, 避免文献总量增长造成表观升温。

近期动量用于区分稳定高频与真正升温。报告主口径比较 2024–2025 与 2022–2023 的平均归一化热度:

$$m_k = \frac{h_{k,2024} + h_{k,2025}}{2} - \frac{h_{k,2022} + h_{k,2023}}{2}$$

2026 年为未完整年度, 只作为早期信号进入解释, 不纳入完整年度动量。

最终写入结论时, 本报告将主题分为“上升信号”“稳定增长”“早期萌芽”或“可能噪声”, 不使用确定性预测。只有当频次、年度占比、近期动量、共现结构、生命周期/突发窗口、主题模型和代表论文多个证据同时支持时, 一个方向才进入强上升候选; 若某个词只在共现网络中靠近核心主题, 但年度占比和突发窗口不支持, 则只作为关联主题而非热点结论。

6 作者合作网络分析

口径注记

本章图谱统计为 2026-08-14 全量重跑结果 (174,013 条, 含讯飞增量)。候选合作边由 10,499,041 增至 10,513,964(+14,923, 主要来自 bioRxiv/medRxiv 预印本作者); 高连接度/桥接作者的相对排序不受 3.3% 增量影响。

分析目标

作者合作网络用于观察科研协作的组织方式。相比简单统计高产作者, 网络分析更关注作者之间如何连接、哪些作者处在社区内部核心位置、哪些作者连接不同主题或领域。

6.1 网络构建口径

- 节点: 作者实体。优先使用 OpenAlex author ID 和 ORCID, 缺失时退回标准化姓名键 `author_key`。
- 边: 两个作者实体共同出现在同一篇论文中。

- **边权**: 同时保留共同论文次数 `paper_count` 和分数化边权 `weight_fraction_pair`; 对一篇含 n 位作者的论文, 每条作者对边增加 $1/\binom{n}{2}$ 。
- **过滤**: 中心性和正文主图排除作者数超过 12 的论文, 避免大型团队论文生成过多两两合作边。

在全量候选网络中, 作者实体合作边超过千万级。为了让静态报告图可解释, 本章采用两层展示: 核心图只保留一个高权重连通 `component`, 用于阅读核心合作骨架; 多组件概览图展示多个高权重 `component`, 用于观察作者合作生态的分散结构。中心性和社区发现用于识别候选核心作者和桥接作者, 不作为未经消歧核验的最终个人影响力排名。作者署名表、边表、指标表和诊断表分别输出为 `paper_authors.csv`、`author_collaboration_edges.csv`、`author_metrics.csv` 与 `author_network_diagnostics.csv`。

6.2 网络指标

指标	含义	解释方式
Weighted Degree	作者实体的分数化合作强度	区分稳定深度合作与一次性大团队合作。
Betweenness	作者连接不同团簇的桥梁能力	识别跨主题或跨领域连接者。
PageRank / Eigenvector	作者是否连接到高连接作者	识别核心圈层中的代表性节点。
k-core	作者所处核心层级	比单纯度数更适合观察核心合作圈。
Community	Louvain 社区划分结果	观察研究团队、主题群落和合作圈层。
Temporal Activity	作者活跃年份分布	判断节点是否仍处于近年活跃状态。

6.3 合作社区与高频合作

本节先看图 15 的规模压缩, 再看图 16 的核心合作骨架; 多组件和高频边图用于补充外围结构, 不作为未经消歧的个人影响力排名。




图 15 作者合作网络规模漏斗。数据来源:`data/analysis/author_network_diagnostics.csv`; 从近五年论文到核心合作图逐步压缩, 以保证网络图具有可读性。

Core Author Collaboration Network (44 displayed edges)



Labels show the top bridge/core authors only. Node size: weighted degree/PageRank proxy. Edge width: fractional coauthor weight.

图 16 核心作者实体合作网络。数据来源: `data/analysis/author_collaboration_edges.csv` 与 `author_metrics.csv`; 节点大小反映加权合作强度, 颜色表示 Louvain 社区, 边宽表示分数化合作边权。为避免标签遮挡, 图中只外置标注少量核心/桥接作者。

Author Collaboration Component Overview

C1: 131 nodes / 165 edges



C2: 69 nodes / 94 edges



C3: 66 nodes / 87 edges



C4: 50 nodes / 76 edges



C5: 57 nodes / 81 edges




C6: 36 nodes / 57 edges



C7: 51 nodes / 72 edges



C8: 57 nodes / 75 edges



C9: 47 nodes / 59 edges



C10: 39 nodes / 53 edges



C11: 38 nodes / 51 edges



C12: 44 nodes / 48 edges



C13: 37 nodes / 50 edges




C14: 35 nodes / 40 edges



C15: 35 nodes / 51 edges



C16: 16 nodes / 19 edges



Each panel is a high-weight connected component; only its strongest local edges and one anchor author are labeled.

图 17 作者合作多组件概览。每个小图表示一个高权重连通 component，仅绘制局部强边并外置标注一个 anchor 作者；16 个子图统一采用青灰-石墨配色，用于补充核心单组件图无法覆盖的外围合作团簇。




图 18 近五年高频作者合作关系。分数化权重用于降低长作者名单论文的影响。

6.4 核心作者与桥接作者候选

角色类型	主要指标	网络解释
核心合作者	Weighted Degree, PageRank, k-core	与多个高权重合作边相连，通常代表稳定团队或核心实验室/课题组。
桥接作者	Betweenness, 跨社区边数	位于多个社区之间，适合追踪跨主题、跨领域合作机会。
高产但需复核作者	Paper Count, Collaborator Count, identity source	若缺少 author ID 或机构信息，高产姓名可能包含同名聚合，应进入人工核验清单。
新近活跃作者	Last Year, Active Years, 近年边权	可作为潜在合作对象或趋势跟踪对象，但需要代表论文支撑。

关键作者名单以 `author_metrics.csv` 为准，正文只解释角色判读方式。若作者实体来自 OpenAlex author ID 或 ORCID，可信度高于仅由姓名生成的实体；对中文常见名、缩写名和缺机构记录，仍应结合机构、代表论文与主题标签进行抽样核验。

6.5 参数敏感性

社区发现采用 Louvain 算法，并输出 `author_louvain_sensitivity.csv` 比较 `resolution = 0.8, 1.0, 1.2` 下的社区数和模块度。若核心社区、桥接作者候选和高权重合作边在不同分辨率下保持稳定，则可作为报告中的结构性结论；若差异较大，只能作为候选信号进入附录和人工复核。

7 数据质量与结论可信度

质量审计目的

数据分析报告的可信度取决于统计口径是否清楚、字段缺失是否透明、来源偏差是否被纳入解释。本章将质量问题转化为结论边界，明确哪些发现可以直接采用，哪些只能作为候选信号。

7.1 主要质量观察

- 六个公开来源共形成 174,890 条原始记录，治理后进入分析层的语料为 174,013 条 (2026-08-14 全量重跑，含讯飞增量)，重复记录比例可控。
- 标题、作者、年份字段完整度较高，适合开展文献分布和作者合作网络分析。
- OpenAlex 记录提供 author ID、ORCID、机构和国家等署名结构，可显著降低同名作者合并风险；其他来源仍以姓名键作为兜底。
- 合并语料摘要覆盖率为 85.64%，可支撑主题、融合术语和趋势分析。
- 正文片段覆盖率为 8.99%，且高度集中于开放全文来源，因此全文级结论只作为补充证据 (2026-08-14 讯飞预印本增量 5,559 篇带全文，已部分缓解该集中性)。
- 2022–2026 五个年份均超过 30,000 条分析记录，年份覆盖均衡性较好。
- 少量异常年份和来源缺失不会进入主趋势图，但保留为质量说明。

7.2 摘要与正文覆盖




图 19 摘要与正文片段覆盖率对比。摘要覆盖较高，正文片段覆盖较低且来源集中，因此全文级分析需要单独标注证据范围。

风险	表现	处理方式
跨源重复	同一论文可能出现在多个来源中	优先使用 DOI 去重, 再用标题和年份辅助合并。
摘要缺失	部分出版元数据来源摘要不足	相关论文保留在分布统计中, 但不作为主题解释的核心证据。
领域偏差	来源和检索主题会影响领域分布	使用来源分布图和领域分布图共同解释。
作者歧义	同名作者或缩写作者难以完全区分	优先采用 author ID/ORCID, 缺失时将作者榜单只作为候选核心节点。
关键词噪声	泛词、缩写和分类词可能进入高频榜	通过停用词、同义词归并、题名摘要交叉验证和年度归一化降低影响。
新近关键词滞后	2026 年显式关键词信号弱于完整年度	使用题名摘要术语补偿, 同时将 2026 年标记为未完整年度。
超长作者名单	大团队论文会放大合作边数量	正文主图采用长作者名单过滤和分数化边权。
社区参数敏感	Louvain 社区数量会随 resolution 改变	输出 <code>author_louvain_sensitivity.csv</code> , 仅保留跨参数稳定的结构性解释。

7.3 网络稳健性检查

作者网络结论采用三层稳健性控制。第一, 边表同时保留共同论文次数、完整计数和分数化计数, 正文以分数化边权降低长作者名单影响。第二, 作者实体优先使用 author ID 与 ORCID, 并在 `author_network_diagnostics.csv` 中记录 ID 覆盖率、核心图节点数、核心图边数和社区数量。第三, Louvain 社区以多个 resolution 进行敏感性比较; 对只在单一参数下出现的社区或桥接作者, 报告不写成确定结论。

7.4 可信度分层

层级	可采用结论	边界说明
高可信	来源规模、年份覆盖、领域分布、摘要覆盖、融合术语年度归一化趋势	来自大样本统计, 口径稳定, 可复核。
中可信	热点主题、作者合作社区、桥接作者候选、主题年度占比	受主题模型选择和作者消歧影响, 适合做结构性解释。
候选信号	未来研究机会、跨领域扩散、潜在合作者	需要代表论文和人工复核支持, 不宜写成确定预测。
暂不强写	精确机构网络、单个作者影响力排名、全文级跨来源比较	当前机构字段和正文覆盖尚不均衡。

8 应用价值与技术创新

评分维度对应

本章把前文的数据发现转化为评委可直接判读的社会效益、经济效益和技术创新点。所有涉及规模、覆盖率、排名和增长幅度的数字,均以 data/analysis/ 下的复现表和图表生成脚本为准,不做脱离数据的夸大表述。

8.1 社会效益

本报告面向公开科技文献建立了可复核的科研情报分析框架,能帮助科研管理者、科技情报人员和政策制定者在大规模文献中识别真实升温方向、跨学科融合机会和合作网络结构。相比只依赖专家经验或单一数据库检索,本报告将来源、年份、领域、关键词演化、主题模型和作者合作网络放在同一证据链中解释,有助于降低方向研判中的偶然性和主观偏差。

受益方	可执行行动	社会效益
科研管理者	用年度热点、生命周期、主题占比和作者社区制定学科布局、项目指南与交叉方向培育计划	把专家经验前置为可审计证据链,降低方向研判偶然性。
科技情报机构	用关键词动量、burst 窗口、代表论文和来源偏差说明构建年度监测流程	将人工巡检转化为可复现、可更新的情报生产机制。
高校与科研院所	用领域结构、跨主题桥接词和合作网络候选节点帮助青年研究者进入领域	降低中文研究者理解英文前沿和寻找合作入口的门槛。
企业研发与产业研究	用趋势、生命周期和跨领域桥接主题筛选技术路线和潜在应用场景	减少对拥挤主题的重复投入,提高立项前筛选效率。
政策制定部门	用多来源趋势、质量边界和领域融合信号观察科技资源配置方向	为前沿监测和科研资源配置提供可复核依据。

可写入结论的社会价值: 本报告的社会价值不在于给出一个静态热门词榜,而在于提供一套可解释、可复核、可持续更新的科技情报观察机制。它能够把公开文献中的分散信号转化为面向科研治理的结构化证据,支撑热点监测、交叉方向识别、合作网络发现和科研资源配置。

8.2 经济效益

从经济效益看,本报告可将传统人工检索、文献筛选、热点梳理和专家初筛流程前置为数据分析流程。对于企业研发部门,生命周期和动量指标可帮助区分成熟方向、增长方向和早期萌芽方向,减少对已经拥挤主题的重复投入;对于投资机构,跨来源趋势和代表论文证据链可作为技术机会初筛工具;对于科研服务机构,可将报告中的图表和数据表复用为持续情报产品,降低周期性报告生产成本。

应用场景	节省的成本	创造的价值
研发立项前调研	降低人工检索、去重、筛选和初步阅读成本	更快识别值得进入专家评审的候选方向。
产业技术扫描	减少依赖单个关键词或单一数据库造成的漏检	发现跨领域方法迁移和新兴应用场景。
投资尽调初筛	降低早期技术赛道判断的信息收集成本	将热点强度、增长阶段和代表论文作为尽调入口。
科研服务产品化	减少重复制作年度热点报告的人工成本	形成可按年更新的情报监测资产和智能体能力。

经济情景测算: 若按 100 名研究员、每人每年 4 次前期文献调研、每次 40–80 工时估算, SciScope 将“人工逐篇检索/筛读”转为“语义问答 + 证据直达 + 图谱/趋势辅助”。即使只压缩 30% 的前期工时,也相当于释放约 4,800–9,600 个研究工时;若替代 \$15/月/人的文献 AI 订阅(按当前汇率折算),年度订阅支出约可避免 12–18

万元。该测算只用于说明投入产出逻辑, 具体金额、工时和比例必须结合目标机构真实计时或用户实验核对。

$$H_{\text{saved}} = U \times T \times H \times r$$

其中 U 为研究人员数量, T 为年调研次数, H 为单次调研工时, r 为可压缩比例。代入 $U = 100, T = 4, H = 40 \sim 80, r = 30\%$ 得到 4,800–9,600 个释放工时。

量化表述边界: 报告可以说明“降低人工检索和初筛成本”“缩短热点识别链路”“提高方向筛选效率”, 但若要写出确定金额、工时或百分比, 必须结合真实业务流程计时或用户实验核对; 本报告不编造未实测经济数字。

8.3 技术创新

本报告的技术创新体现在“多证据热点识别”而不是单一模型展示。分析流程先治理多来源文献数据, 再融合显式关键词与题名摘要术语, 进一步计算年度归一化趋势、近期动量、burst 窗口、生命周期阶段、关键词共现网络、主题年度占比和作者合作网络, 最后用质量审计限定结论边界。

创新点	数据或模型支撑	解决的问题
融合关键词信号	paper_keyword_signals.csv, keyword_year_matrix.csv	降低显式关键词缺失和新近索引滞后的影响。
归一化趋势与动量	keyword_trends.csv, keyword_burst_windows.csv	区分总体文献增长和真实研究关注上升。
生命周期判别	keyword_lifecycle.csv	将高频、增长、成熟和回落主题分层解释。
共现网络与社区发现	keyword_cooccurrence_edges.csv, keyword_metrics.csv	从孤立词频升级为主题结构和桥接关系分析。
主题模型交叉验证	topic_keywords.csv, topic_year_share.csv	检查热点词是否对应稳定语义主题。
质量可信度分层	source_quality_report.csv, data_layer_readiness.json	避免把字段缺失、来源偏差或作者歧义写成确定结论。

技术创新结论: 本报告形成了“数据治理 – 融合术语 – 趋势动量 – 网络结构 – 主题验证 – 质量边界”的闭环分析框架。该框架既能产出静态报告, 又能作为后续科研智能体的**数据要素与证据服务上游**: 为趋势查询、证据检索、图谱问答和推荐解释提供统一口径的数据资产, 同时明确哪些结论可写成现状、哪些只能保留为候选信号。

I 9 数据资产到智能体的映射

映射目标

本章说明数据报告中的分析资产如何进入科研智能体：分布与字段质量决定检索可信边界，关键词与主题资产支撑趋势和综述，作者与关键词网络进入图谱工具，质量审计约束回答边界。项目报告负责系统能力闭环，本章只给出数据资产到 agent 工具的映射关系。

9.1 资产映射表

数据资产	对应智能体能力	边界说明
来源、年份、领域分布	检索结果解释与趋势背景提示	来源偏差和领域规模差异必须进入解释，不能把单源增长直接外推为全学科增长。
标题、摘要、关键词字段	search_literature、summarize_field、RAG 片段召回	摘要覆盖率较高，适合摘要级综述；全文覆盖较低，全文级深读需单独标注范围。
融合关键词趋势	get_trends、热点问答、研究方向推荐	趋势用于候选信号和排序，不作确定性预测。
作者合作网络	query_knowledge_graph 与合作对象候选发现	高连接作者需要 author ID/ORCID/机构与代表论文复核，不直接等同个人影响力。
质量审计与口径表	verify_claim、回答置信边界、报告导出说明	证据不足或口径不一致时，智能体应明确降级为候选结论。

9.2 可进入智能体的稳定结论

- **覆盖结论：**2022–2026 年每年均超过 30,000 条分析记录，可作为年度趋势和主题动量的基础背景。
- **主题结论：**大语言模型 (LLM)、检索增强生成 (RAG)、prompt engineering、vision language model 和 knowledge graph 等主题具有多证据上升信号，适合进入趋势问答与综述素材。
- **网络结论：**作者合作网络适合发现候选桥接者和合作团簇，但个人层面结论必须保留消歧边界。
- **质量结论：**摘要级结论可信度高于全文级深读；全文片段用于增强证据，不代表全库全文覆盖。

9.3 进入回答时的边界模板

智能体回答边界：当用户询问热点、预测或合作对象时，系统应优先表述为”上升信号””候选方向””待复核桥接者”；只有在检索证据、趋势资产和质量口径一致时，才给出更强结论。该边界与项目报告中的 verify_claim 和 reflect/retry 机制一致。

| 10 结论、局限与后续数据建议

总体结论

当前数据已经能够支撑一份以近五年科技文献为对象的结构化分析报告。最可靠的结论集中在来源规模、年份覆盖、领域结构、摘要级主题趋势和作者合作社区; 需要谨慎解释的部分集中在全文级比较、单个作者影响力和未来趋势预测。

10.1 主要结论

- 数据规模充分:** 174,013 条分析语料 (含讯飞增量) 和 160,908 条近五年语料为分布分析和趋势分析提供了稳定基础。
- 年份覆盖均衡:** 2022–2026 各年均超过 30,000 条记录, 年度趋势具有可比性。
- 领域结构不完全均衡:** 计算机科学和生物医学样本较多, 材料科学样本较少, 需要归一化解释。
- 热点主题有明显上升信号:** LLM、RAG、prompt engineering、vision language model、knowledge graph 等方向在多个统计口径下均较活跃。
- 作者合作网络具有社区结构:** 分数计数后仍能观察到核心合作社区和桥接作者候选, 但作者消歧仍是限制。

10.2 局限

局限	影响	报告处理方式
来源偏差	不同来源覆盖领域和年份节奏不同	所有趋势结论同时参考来源和领域分布。
正文覆盖不足	分析快照全文级深读不能代表全部语料 (讯飞增量已显著补充预印本全文)	全文片段只作为补充证据, 不替代摘要级统计。
作者同名问题	高连接作者可能由同名聚合造成	作者排名表述为候选节点, 不作绝对权威判断。
关键词噪声	泛词和缩写可能干扰热点榜	采用归并、过滤、题名摘要术语和归一化趋势交叉验证。
主题模型不唯一	不同模型可能给出不同主题边界	主题模型作为结构验证, 不作为唯一结论来源。

10.3 后续数据建议

方向	建议
正文覆盖	已部分落地: 讯飞交付包 5,566 篇预印本 PDF 直接解析全文并入库; 后续继续提升其余来源的开放全文覆盖。
字段补全	补充期刊、机构、引用量和标准化作者标识, 支撑更细粒度的影响力分析。
作者消歧	对高连接作者和桥接作者进行机构、主题和署名上下文复核。
关键词治理	持续维护同义词、缩写、领域停用词和题名摘要术语表, 降低关键词噪声。
趋势验证	使用代表论文和跨来源一致性检验上升主题, 避免单一来源波动造成误判。

10.4 最终判断

本报告最稳健的价值不在于给出单个“最热门词”或“最权威作者”, 而在于建立一套可解释的数据分析框架: 先确认来源和年份覆盖, 再用融合术语和归一化趋势识别主题变化, 再用作者网络解释合作结构, 最后用质量审计限定结论边界。基于这一框架, LLM、RAG、知识图谱及其跨领域应用可以作为当前最值得关注的上升方向。

面向评分的最终闭环：评分维度的完整展开见第 8 章「应用价值与技术创新」；简言之，社会效益上报告为科研治理和科技情报提供可复核证据，经济效益上降低研发立项、技术扫描和投资初筛的信息收集成本，技术创新上以融合术语、趋势动量、生命周期、共现网络、主题模型和质量审计形成一体化流程，格式规范上对数据来源、统计口径、结论边界和核对表做显性说明。

附件边界说明：提交边界与 2.4 节一致——不把大型 `data/` 目录、嵌入器权重或 PostgreSQL 运行表作为独立文件上传，由代码仓库、运行说明和 `make` 目标重建；数据报告承担”结论与证据口径”职责，项目报告和附件承担”系统复现与模型重建”职责。

11 数据来源与参考文献

本报告所用数据均来自公开学术数据源，分析方法均为公开统计/机器学习方法，数字与图表可由 data/analysis/ 下脚本复现，来源可追溯。

11.1 数据来源

- D1. OpenAlex ——开放学术知识图谱与元数据 API。 <https://openalex.org>
- D2. PubMed / PubMed Central (PMC) ——美国国立医学图书馆生物医学文献库。 <https://pubmed.ncbi.nlm.nih.gov>
- D3. Crossref ——DOI 注册与文献元数据。 <https://www.crossref.org>
- D4. DOAJ ——开放获取期刊目录。 <https://doaj.org>
- D5. arXiv ——计算机/物理/数学等领域预印本库。 <https://arxiv.org>

11.2 分析方法来源

- R1. Mann, H. B. (1945). Nonparametric tests against trend. *Econometrica*, 13(3), 245–259.
- R2. Sen, P. K. (1968). Estimates of the regression coefficient based on Kendall's tau. *JASA*, 63(324), 1379–1389.
- R3. Blondel, V. D., et al. (2008). Fast unfolding of communities in large networks (Louvain). *J. Stat. Mech.*
- R4. Page, L., Brin, S., et al. (1999). The PageRank citation ranking: Bringing order to the web.
- R5. Blei, D., Ng, A., Jordan, M. (2003). Latent Dirichlet Allocation (LDA). *JMLR*, 3, 993–1022.
- R6. Lee, D. D., Seung, H. S. (1999). Learning the parts of objects by non-negative matrix factorization (NMF). *Nature*, 401, 788–791.

合规声明: 本报告基于公开数据进行统计与可视化分析, 遵循各数据源的开放获取与使用条款, 不再分发受版权保护的论文全文。涉及作者个人的排名与网络指标仅用于结构性分析, 需经消歧复核后方可用于个体评价。