

SciScope 科技文献数据要素服务 与科研智能体系统设计


国赛版架构与完整设计文档（内部）

数据要素服务

证据立场 L3

MCP 证据后端

本机全量演示



文档定位

本文档是团队内部用于统一国赛架构、证据层（stance L3）、协议边界、数据与演示路线的设计文档，是‘docs/project/国赛目标说明书.md’（冻结目标）在设计层的展开。对外交付仍落在两条主线上：可复现的数据分析报告（要素服务化表述），以及可被调用、可演示的科研智能体系统。核心判断：**证据可追溯是魂，协议可调用是门，界面可替换是皮**。

目录

1	主线边界：证据可追溯的科研智能体与数据要素服务	2
1.1	任务主线	2
1.2	叙事比例（国赛答辩）	2
1.3	系统分层	3
2	数据分析报告设计	4
2.1	分析主题	4
2.2	可复现分析流水线	4
2.3	数据资产设计	4
2.4	报告结构草案	4
2.5	全国赛口径：数据要素分层表	5
3	科研智能体系统设计（证据层为核心）	6
3.1	核心能力矩阵	6
3.2	Stance L3 管线（技术主叙事）	6
3.3	协议与模块边界	7
3.4	可信答案原则	7
4	模型与算法设计	8
4.1	算法组合	8
4.2	RAG 检索策略	8
4.3	趋势预测设计	8
4.4	模型文件组织	9
5	AI Infra 架构思路（本机全量优先）	10
5.1	运行 profile（三档）	10
5.2	服务层拓扑	10
5.3	模型 provider 路由	11
5.4	Infra 应该服务的产品指标	11
6	工程交付设计（国赛双轨）	12
6.1	交付物清单	12
6.2	Makefile 命令分层	12
6.3	演示与复现双轨	12
6.4	黄金演示脚本（约 6-8 分钟）	13
6.5	验收口径	13

7 实施路线与风险控制（国赛冻结版）	14
7.1 阶段路线	14
7.2 关键风险	14
7.3 架构决策记录	15
7.4 完成标准	15

1 主线边界：证据可追溯的科研智能体与数据要素服务

核心判断

SciScope 的主线不是炫耀 AI Infra, 也不只是”又一个文献问答助手”, 而是把公开科技文献治理成可计算、可调用的数据要素, 并建成可被其他科研 agent 调用的证据后端。大模型只是生成层; 可复现的数据资产、检索/证据索引、stance 判定与协议出口才是护城河。

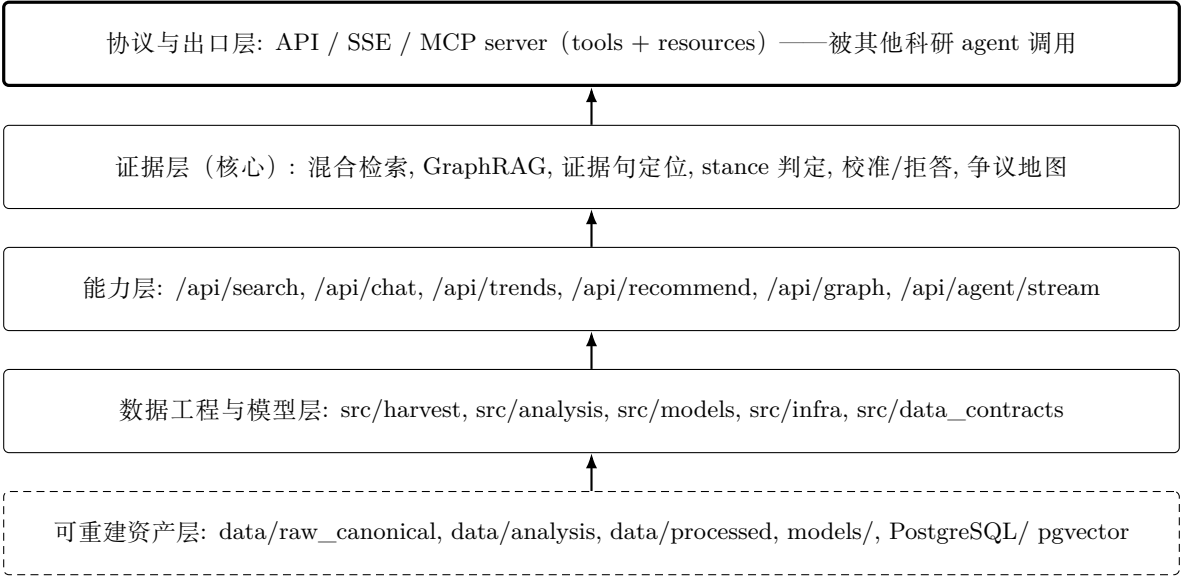
1.1 任务主线

主线模块	必须回答的问题	应形成的资产
数据要素治理	六源文献如何被规范化、去重、分区分层成可审计资产	raw_canonical / analysis / processed 分层 + 口径表
数据分析报告	分布、演化、作者网络、覆盖偏差揭示了什么	图表、统计表、网络图、要素服务化收束
证据立场 L3	一句话与文献是支持 / 反驳 / 中立, 证据落在哪个句子	金标准评测、校准/拒答、争议地图表与视图
混合检索与问答	用户能否用自然语言得到带 ‘[n]’ 证据的答案	混合检索、GraphRAG 证据问答
MCP 协议出口	其他 agent 能否调用核查工具、读取争议资源	MCP tools + resources、OpenCode 真调产物

1.2 叙事比例（国赛答辩）

- **第一优先级（技术魂 A）**：论断级 stance——不是”相关即支持”, 而是证据句级支持/反驳/中立 + 校准拒答 + 限定条件 + 争议沉淀。
- **第二优先级（价值壳 C）**：公开文献治理成数据要素, 以 API/MCP 对外服务, 贴出题单位语境: 智能体作为文献要素服务的调用方。
- **第三优先级（展示皮 B）**：Go TUI 消费 SSE 的完整科研工作流, 本机全量可演示。
- **第四优先级**: 检索/趋势/推荐等赛题基线能力——必须能展示, 但不作为技术主叙事。

1.3 系统分层



2 数据分析报告设计


报告目标

数据分析报告要回答“这批科技文献本身揭示了什么”。它不是系统截图集合，而是由 Python 分析代码可复现生成的研究洞察报告。报告中的每个图表都应能追溯到数据处理脚本、统计口径和中间资产。

2.1 分析主题

分析主题	关键问题	推荐图表
文献分布分析	不同年份、领域、来源、关键词的数量结构如何变化	年份趋势线、领域堆叠图、关键词 Top-K 表
关键词演化	哪些关键词在近年变热，哪些主题在衰退或迁移	关键词时序热力图、突增词榜、主题河流图
作者合作网络	哪些作者或机构是核心节点，合作团簇如何形成	合作网络图、中心性排行、社区划分图
主题结构分析	文献可被分成哪些主题，主题之间如何关联	主题聚类图、主题关键词表、主题间相似矩阵
热点趋势预测	未来一段时间哪些方向可能继续升温	热点预测表、增长率曲线、置信说明

2.2 可复现分析流水线



2.3 数据资产设计

资产	内容	用途
<code>papers.parquet</code>	标准化论文元数据, 包括标题、摘要、作者、年份、关键词、领域	仪表盘统计、筛选、领域对比
<code>chunks.parquet</code>	摘要或全文片段, 保留论文 id、年份、领域、作者上下文	RAG 检索、证据卡片、摘要问答
<code>keyword_year.csv</code>	关键词按年份聚合后的频次、增长率和突增标记	关键词演化、热点检测、趋势图
<code>author_graph.json</code>	作者节点、合作边、中心性、社区编号	作者合作网络、图谱查询
<code>topic_model.json</code>	主题编号、主题词、代表论文、年份分布	主题聚类、综述生成、推荐解释

2.4 报告结构草案

- 数据概览: 样本规模、字段完整度、年份覆盖、领域覆盖。
- 文献分布: 年份趋势、领域结构、关键词总体排行。

- 3. 主题演化: 动态主题、突增关键词、领域间主题迁移。
- 4. 作者合作: 合作网络、核心作者、社区结构、跨领域合作。
- 5. 热点观察: 高增长主题、潜在研究机会、风险与不确定性。
- 6. 要素服务化收束: 每类洞察如何支撑检索、核查、争议地图与 MCP 服务。

2.5 全国赛口径：数据要素分层表

层	资产	用途
原始采集	169,324 条（六源）	审计与重建底账, raw_canonical 分区
分析论文	168,447 条	分析与图件输入, analysis 资产
处理语料	159,164 条	PostgreSQL/RAG 导入边界
运行库	论文 / chunk / 向量实测	PostgreSQL + pgvector 服务层

四层数字**必须分开表述**，不可混用；运行库一层以 PostgreSQL 实测为准。覆盖上注意：全文仅约 10.5% 且高度依赖 PMC，计算机/材料领域主要靠标题摘要——这在报告与答辩中要诚实前置。

3 科研智能体系统设计（证据层为核心）

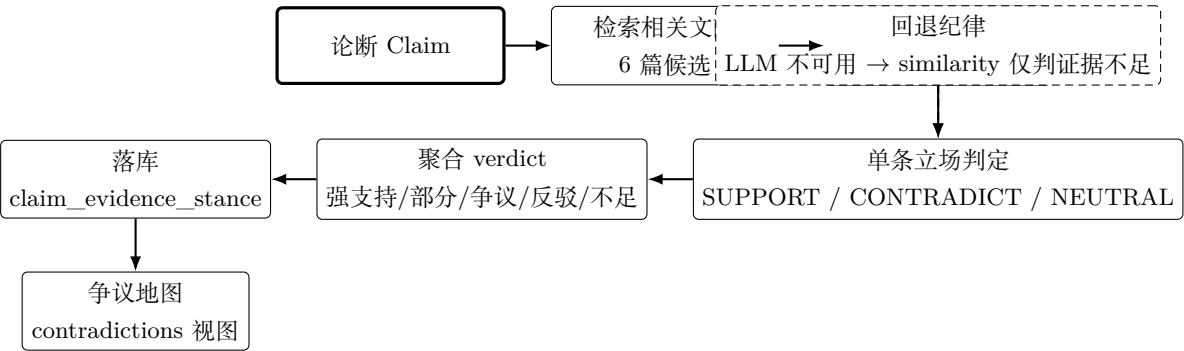
产品定位

科研智能体不是一个普通聊天框，也不只是一套 RAG 检索器。它的差异化在于**证据立场判定**：对一句论断，系统能说出文献是”支持/反驳/中立”，指出证据落在哪个句子，低置信时如实说”证据不足”，并把检测到的矛盾沉淀为可读取的**科学争议地图**。这个原语同时是核查能力、争议检测器和可被其他 agent 调用的服务。

3.1 核心能力矩阵

能力	用户体验	后端能力
证据问答	自然语言问方向，系统返回答案与证据卡	混合检索、GraphRAG、引用约束生成
论断核查	一句话得到支持/反驳/中立，证据句可展开，边界诚实	stance L3: 句级证据, 类别概率, 校准拒答
争议地图	看到”文献里有人反对”的论断与双方证据	claim_evidence_stance + contradictions 视图 + API/Agent tool/MCP resource
趋势预测	询问未来方向，返回解释与不确定性	关键词时序、增长率、显著性核实
论文推荐	输入兴趣，得到推荐与解释原因	向量/主题/作者/时间加权，可解释因子
图谱查询	查询作者/关键词/主题关系	图谱索引与 NetworkX 预计算

3.2 Stance L3 管线（技术主叙事）



- **句级证据**: 采用的证据能落到句级（或等价最小跨度），不拿整段摘要充当证据。
- **校准与拒答**: 低置信倾向”证据不足”；给出类别概率或分数，呈校准/拒答表现。
- **限定条件**: 人群/剂量/时间/物种等明显冲突时降级为 NEUTRAL 或证据不足并写理由。
- **对称性**: 论断 C 与反论断 $\neg C$ 不得无理由同判为支持（这是早期”相似即支持”的裂缝）。
- **回退纪律**: LLM 不可用时仅按相似度给”证据不足”，**禁止**回退序列输出”强支持”式措辞。
- **金标准**: 双语主集 + SciFact 协议锚点，与纯相似度 baseline 同集对照，结果进项目报告。

3.3 协议与模块边界

接口或模块	输入	输出
/api/agent/stream	问题、历史、session_id、retry	SSE 事件流（plan/tool/reflect/final） + meta
/api/chat	问题、证据问答	答案、证据、引用、置信说明
/api/search	查询词	混合检索结果（FTS+ 向量 +RRF）
/api/trends	关键词、时间范围	趋势曲线、显著性、解释
/api/recommend	论文 id / 主题	推荐列表、解释因子
/api/graph	作者/关键词/主题	节点、边、社区、中心性
verify_claim (tool)	论断	verdict、证据句、立场统计
disputes (MCP resource)	—	当前争议前线论断

3.4 可信答案原则

- 答案必须绑定证据卡, 证据卡必须能追溯到论文标题、年份、来源与片段。
- 核查类结论区分”相关”与”支持”; 拒不出现”证据不足却强说支持”。
- 系统敢说”证据不足 / 文献里有人反对”, 也接受人类反驳并认错。
- 趋势/推荐给明数据显示与不确定性, Web 不把代理指标当用户价值。

4 模型与算法设计

模型交付边界

赛题期望的“科研智能体模型”不应只理解为一个大语言模型权重。我们的模型资产应包括 Python 代码、索引文件、主题模型、推荐排序模型、趋势预测结果、图谱结构和 LLM provider 配置。大模型负责语言理解与生成，领域洞察主要来自可复现的数据模型。

4.1 算法组合

模块	实现	输出资产
文本检索	PostgreSQL FTS + multilingual-e5 向量 + RRF(k=60) + 可选 bge-reranker	候选片段、融合分、重排结果
向量表示	multilingual-e5-base 768 维 (query:/passage: 前缀)	chunk_embeddings / paper_embeddings
GraphRAG	关键词图扩展 + 检索证据融合	图谱上下文、关系解释
Stance 判定	LLM 单条证据立场判定 + 聚合 verdict + 校准拒答 + 限定条件	stance 标签、verdict、claim_evidence
趋势预测	关键词频次时序、增长率、突增、显著性	热点榜、趋势曲线、预测说明
论文推荐	向量相似、主题、时间、作者关系重排	推荐列表、解释因子、排序分

4.2 RAG 检索策略



4.3 趋势预测设计

趋势预测不追求夸张的“预测未来”，而是做可解释的热点识别：对关键词、主题和领域构建按年或按月的时序矩阵，计算增长率、近年加速度、突增分数和稳定性。最终输出应是“值得关注的方向 + 依据 + 不确定性”，而不是孤立的排行榜。

指标	含义
频次增长率	近三年出现频次相对历史均值的提升程度
突增分数	某关键词或主题在短时间内显著上升的强度
稳定性	热度是否连续增长，避免一次性噪声造成误判
跨领域扩散	某主题是否从一个领域扩展到多个领域
证据密度	支撑该趋势的论文数量、代表论文和主题一致性

4.4 模型文件组织

路径	内容
data/processed/ src/models/	清洗后的论文表、chunk 表、关键词时序表 代码包: 嵌入/趋势/推荐/图谱/双语/重排脚本（与资产目录 <code>models/</code> 同名不同物）
models/embedder_local/	multilingual-e5-base（768 维）
models/reranker_local/	bge-reranker-v2-m3（可选重排）
models/trends/	热点检测结果、趋势预测结果、解释元数据
models/recommend/	推荐模型资产
output/graphs/	作者合作图、关键词共现图、主题关系图
infra/postgres/	schema.sql + pgvector.sql + stance.sql（争议表与视图）

5 AI Infra 架构思路（本机全量优先）

定位校准


AI Infra 是 SciScope 的工程可靠性和可复现性保障。国赛演示以**本机全量**为主路径：本地 PostgreSQL/pgvector 承载 16 万论文与 36 万 + 片段，本地 embedding/reranker 提供语义能力，生成模型走 DeepSeek API 或本地 LLM，全部通过 Makefile 一键可复现。

5.1 运行 profile（三档）

Profile	用途	技术路径
Full（主演示）	国赛本机全量：检索/核查/争议/MCP	本地 PostgreSQL + pgvector + E5 + reranker + DeepSeek
Lite	无模型快速启动与 CI 验收	Mock provider + 预置证据 + 样本语料
Hosted demo	公开入口（小样本）	Render + Supabase + DeepSeek, 关闭运行时 embedding

口径纪律：hosted demo 约 220 篇/467 片段，不等于国赛演示能力全集。国赛现场以本机全量为准；提交配套”评委视频 + 硬件清单”双轨，说明全量复现的门槛与关键命令，不拿 hosted 冒充全量。

5.2 服务层拓扑



- PostgreSQL/pgvector 是**正式服务层**，不是可选项；本地全量检索与 stance 落库都依赖它。
- 本地 E5 与 bge-reranker 是语义臂与重排器；不可用时检索自动降级，核查回退仅判”证据不足”。
- Makefile 是唯一工程入口：make postgres-refresh, make agent-build, make backend, make tui, make eval-stance, make submission-package。
- 会话状态为进程内 MemorySaver + JSON 落盘（data/.agent_memory），不做数据库级持久化——如实声明。

5.3 模型 provider 路由

Provider	适合场景	注意事项
Mock	CI、无网、接口验收	必须明确标记, 不代表最终回答质量
DeepSeek API	正式生成、中文综述、复杂推理	需要 API Key 与网络环境
本地 LLM (Qwen 7B 4bit)	本机离线演示（可选下载）	需要模型下载与预热

5.4 Infra 应该服务的产品指标

- **启动确定性:** 一条命令启动对应 profile, 端口和模型状态可检查 (`make tui-doctor`)。
- **回答可追溯:** 无论 provider 是谁, 答案必须绑定本地检索证据。
- **失败可降级:** DeepSeek 不可用时切本地 LLM 或 Mock; 数据库不可用时 stance 写入静默跳过。
- **诚实缺口:** 无鉴权/租户、无 OTel、会话非多实例持久化——原型级治理, 报告中如实声明。

6 工程交付设计（国赛双轨）

交付原则

最终交付不是孤立 PDF，也不是只在开发机上的 demo。它是可复现工程包：数据处理代码生成分析资产，服务层消费资产，证据层提供 stance/争议能力，MCP 把能力暴露给外部 agent，Go TUI 演示完整 workflow。提交“配套”评委视频 + 硬件清单”双轨。

6.1 交付物清单

交付物	内容
数据分析报告	文献分布、关键词演化、作者合作网络、覆盖偏差、要素服务化收束
项目报告书	概述/方案/价值三章，L3 证据层为主干，双报告口径一致
科研智能体系统	FastAPI + PostgreSQL + LangGraph Agent + Go TUI
Stance L3 评测	双语金标准、SciFact 锚点、similarity 对照、校准/拒答
争议地图	claim_evidence_stance + contradictions + API/Agent tool/MCP resource
MCP 证据后端	tools (verify_claim 等) + resources (争议前线) + OpenCode 真调产物
评委视频与清单	本机全量黄金脚本录屏 + 硬件/环境清单 + 逐步复现文档

6.2 Makefile 命令分层

命令	作用
make install	安装 Python 依赖
make	数据资产刷新 + schema + 全量入库
postgres-refresh	
make agent-build	embeddings + recommend + trend + graph
make backend	启动 FastAPI (:8000)
make tui	启动 Go TUI (消费 SSE)
make test-backend	后端自动化测试 (当前 269 passed)
make eval-all / make eval-stance	检索/趋势/推荐评测; stance L3 金标准评测
make	白名单提交包 + manifest
submission-package	
make tui-doctor	终端客户端环境自检

6.3 演示与复现双轨

- **评委视频:** 本机全量 + OpenCode 调用的黄金脚本（约 6–8 分钟），综合评委 10 分钟内建立信任。
- **硬件清单:** CPU/RAM/磁盘、PostgreSQL/pgvector、模型路径、耗时量级、关键命令，说明全量可复现的门槛。
- **文档复现:** runbook 逐步：安装 → 起库 → 加载 → 启动 → 黄金脚本。
- **不承诺:** 不把 hosted 小库当国赛主演示；现场环境不允许全量时以视频为能力举证。

6.4 黄金演示脚本（约 6–8 分钟）

1. C 开场: 文献要素治理 → 证据服务。
2. 规模一屏: 运行库论文/chunk 与报告口径一致。
3. B 基线: 真实问题 → ‘[n]’ 证据问答 → 证据卡。
4. A L3: 正论断 / 反论断 / 限定冲突 / 证据不足。
5. 争议地图: 列表读到刚写入的矛盾 claim。
6. OpenCode 调用: MCP verify_claim + disputes resource。
7. 收束: 三创新点 + 一句诚实边界。

6.5 验收口径

1. 本机全量库可起, 运行库数字与报告口径一致。
2. stance 正反论断不同判; 低置信给”证据不足”; 回退不出现”强支持”。
3. 争议地图 API / Agent tool / MCP resource 三条读路径同一 claim 可读。
4. OpenCode 真实调用过一次, 有日志/录屏产物。
5. 所有对外结论都能追溯到数据资产或检索证据。

7 实施路线与风险控制（国赛冻结版）

实施策略

目标上游是 docs/project/国赛目标说明书.md（冻结）：A 技术魂（stance L3）+ C 价值壳（文献数据要素服务）+ B 展示皮（本机全量演示）。大改只允许服务于” 相关 → 蕴含/矛盾 → 可沉淀 → 可调用” 这条主线。

7.1 阶段路线

阶段	目标	验收物
WB0 目录治理	目录分类与架构确定	data_contracts 迁移、stance 包、plan 并入 docs/project、设计 PDF
WB1 运行底座	本机全量起库	schema/load 可复现、doctor 可诊断、四层数字实测
WB2 Stance L3	句级证据/校准拒答/限定条件/回退纪律	正反不同判、低置信拒答、回退不输出强支持
WB3 金标准评测	双语主集 + SciFact 锚点 + 对照	eval_stance 指标进 output/eval 与报告
WB4 争议地图	三读路径产品化	API / Agent tool / MCP resource 同一 claim 可读
WB5 MCP + OpenCode	证据后端正门	OpenCode 真调产物（日志/录屏）
WB6 演示底座	黄金脚本与双轨交付	录屏 + 硬件清单 + 复现文档
WB7 双报告改写	要素服务化表述	两报告共用口径表与诚实边界
WB8 提交收口	提交包与视频	submission-package dry-run 通过

7.2 关键风险

风险	表现	控制方式
Stance 自说自话	核查是 LLM 自己判自己	金标准 + SciFact 锚点 + 相似度对照 + 回退纪律
演示与可复现脱节	视频很神、按文档跑不起来	本机全量视频 + 硬件清单 + runbook 逐步复现
” 要素/可调用” 只有 PPT	无被调用证据	OpenCode MCP 真调产物进报告附录
全文覆盖偏见	全文 10% 且依赖 PMC	诚实前置 + 检索以标题摘要为主体的口径说明
趋势/推荐过度承诺	方向准确率弱、代理指标	保留赛题能力, 不进技术主叙事

7.3 架构决策记录

- PostgreSQL/pgvector 是正式服务层（修订旧稿”轻量底座”决定）；16 万论文/36 万 + 片段/768 维向量。
- 共享数据契约: src/data_contracts/（由 data_pipeline 迁入），backend 与 src.harvest 共用一套 Paper 口径。
- 证据层独立成包: backend/app/services/stance/（store.py 已迁入, L3 后续扩展）。
- DeepSeek 是正式生成后端; 本地 LLM 可选下载, 用 Mock 兜底。
- 协议即正门: API / SSE / MCP tools + resources; Go TUI 只是消费者之一。
- 双报告共享口径: 原始/分析/处理/运行库四层数字分开, 诚实边界共用。

7.4 完成标准

完成定义

当且仅当：本机全量库可一键重建并演示; verify_claim 对正反论断给出可解释的不同判定, 低置信如实拒答, LLM 不可用时不输出”强支持”; 争议地图通过 API/Agent/MCP 三条路径可读; OpenCode 作为外部 agent 真实调用过一次并留下产物; 两份报告以要素服务化口径一致收束——SciScope 才算站上国赛主线。Infra 的完成标准是让这些能力更稳定、更可复现, 而不是替代它们。