

SciScope 科技文献智能分析报告 与科研智能体系统设计


内部架构与设计思路文档

数据分析报告

科研智能体模型

RAG 与知识图谱

AI Infra 支撑



文档定位

这不是交付给评委的最终分析报告, 而是团队内部用于统一架构、模型、数据、工程路线和产品边界的设计文档。最终对外交付仍然必须落在两条主线上: 可复现的数据分析报告, 以及可运行的科研智能体系统。AI Infra 很重要, 但它只服务于主线能力。

目录

1 主线边界：数据洞察与科研智能体优先	3
1.1 任务主线	3
1.2 叙事比例	3
1.3 系统分层	3
2 数据分析报告设计	4
2.1 分析主题	4
2.2 可复现分析流水线	4
2.3 数据资产设计	4
2.4 报告结构草案	4
3 科研智能体系统设计	6
3.1 核心能力矩阵	6
3.2 Agentic Workflow	6
3.3 API 与模块边界	6
3.4 可信答案原则	6
4 模型与算法设计	7
4.1 算法组合	7
4.2 RAG 检索策略	7
4.3 趋势预测设计	7
4.4 模型文件组织建议	8
5 AI Infra 架构思路	9
5.1 三档运行 profile	9
5.2 M5 单机优先, i5 可选增强	9
5.3 模型 provider 路由	9
5.4 Infra 应该服务的产品指标	10
6 工程交付设计	11
6.1 交付物清单	11
6.2 Makefile 命令分层	11
6.3 产品工作台页面	11
6.4 验收口径	11
7 实施路线与风险控制	13

7.1	阶段路线	13
7.2	关键风险	13
7.3	架构决策记录	13
7.4	最终状态定义	14

1 主线边界：数据洞察与科研智能体优先

核心判断

SciScope 的主线不是炫耀 AI Infra, 而是让科研人员从海量科技文献中快速得到可验证洞察。AI Infra 的价值在于保证问答、趋势预测、论文推荐和知识图谱查询稳定运行, 并支撑 DeepSeek 与本地模型之间的可切换能力。


1.1 任务主线

主线模块	必须回答的问题	应形成的资产
数据分析报告	这些论文在年份、领域、关键词、作者合作上呈现什么结构与变化	图表、统计表、网络图、趋势解释、结论摘要
科研智能体系统	用户能否用自然语言查文献、问趋势、找论文、查图谱	前端工作台、FastAPI 服务、RAG 链路、模型与索引文件
模型算法资产	系统是否有可复现的分析与预测能力	向量索引、主题模型、推荐排序、趋势矩阵、作者图谱
AI Infra 支撑	系统是否稳定、可降级、可本地运行、可接入 DeepSeek	Makefile、模型 provider、vLLM 配置、运行文档

1.2 叙事比例

- 第一优先级: 文献分析结果与洞察, 包括分布、演化、合作网络和热点变化。
- 第二优先级: 科研智能体功能闭环, 包括问答、推荐、趋势预测、图谱查询和证据溯源。
- 第三优先级: 算法创新, 包括 GraphRAG、混合检索、动态主题建模、突增检测和推荐排序。
- 第四优先级: AI Infra, 包括 DeepSeek、本地 vLLM、M5 单机优先和 i5 可选协同。

1.3 系统分层



2 数据分析报告设计


报告目标

数据分析报告要回答“这批科技文献本身揭示了什么”。它不是系统截图集合, 而是由 Python 分析代码可复现生成的研究洞察报告。报告中的每个图表都应能追溯到数据处理脚本、统计口径和中间资产。

2.1 分析主题

分析主题	关键问题	推荐图表
文献分布分析	不同年份、领域、来源、关键词的数量结构如何变化	年份趋势线、领域堆叠图、关键词 Top-K 表
关键词演化	哪些关键词在近年变热, 哪些主题在衰退或迁移	关键词时序热力图、突增词榜、主题河流图
作者合作网络	哪些作者或机构是核心节点, 合作团簇如何形成	合作网络图、中心性排行、社区划分图
主题结构分析	文献可被分成哪些主题, 主题之间如何关联	主题聚类图、主题关键词表、主题间相似矩阵
热点趋势预测	未来一段时间哪些方向可能继续升温	热点预测表、增长率曲线、置信说明

2.2 可复现分析流水线



2.3 数据资产设计

资产	内容	用途
<code>papers.parquet</code>	标准化论文元数据, 包括标题、摘要、作者、年份、关键词、领域	仪表盘统计、筛选、领域对比
<code>chunks.parquet</code>	摘要或全文片段, 保留论文 id、年份、领域、作者上下文	RAG 检索、证据卡片、摘要问答
<code>keyword_year.csv</code>	关键词按年份聚合后的频次、增长率和突增标记	关键词演化、热点检测、趋势图
<code>author_graph.json</code>	作者节点、合作边、中心性、社区编号	作者合作网络、图谱查询
<code>topic_model.json</code>	主题编号、主题词、代表论文、年份分布	主题聚类、综述生成、推荐解释

2.4 报告结构草案

- 数据概览: 样本规模、字段完整度、年份覆盖、领域覆盖。
- 文献分布: 年份趋势、领域结构、关键词总体排行。

3. 主题演化: 动态主题、突增关键词、领域间主题迁移。
4. 作者合作: 合作网络、核心作者、社区结构、跨领域合作。
5. 热点预测: 高增长主题、潜在研究机会、风险与不确定性。
6. 系统映射: 报告中的每类洞察如何被智能体调用和解释。

3 科研智能体系统设计


产品定位

科研智能体不是一个普通聊天框，而是一个围绕科技文献构建的研究工作台。它要把数据分析报告中的静态洞察转化为可交互能力：用户能继续追问、筛选证据、跳转图谱、获得推荐，并理解答案来自哪些文献。

3.1 核心能力矩阵

能力	用户体验	后端能力
文献问答	用户用自然语言询问某个方向的研究现状，系统返回答案与证据卡	混合检索、RAG 合成、引用校验
趋势预测	用户询问未来哪些方向值得关注，系统返回趋势解释与依据	关键词时序、主题增长率、突增检测
论文推荐	用户输入兴趣主题或一篇论文，系统推荐相关论文并解释原因	向量相似、主题相似、作者关系、时间加权排序
知识图谱查询	用户查询作者、机构、关键词、主题之间的关系	图谱索引、NetworkX 预计算、前端图谱渲染
综述辅助	用户要求生成某方向的初步综述框架	证据聚合、主题分组、引用约束生成

3.2 Agentic Workflow



3.3 API 与模块边界

接口或模块	输入	输出
/api/chat	问题、筛选条件、会话上下文	答案、证据、引用论文、检索诊断
/api/trends	关键词、主题、时间范围、领域	趋势曲线、突增词、预测说明
/api/recommend	论文 id、主题描述、用户偏好	推荐列表、推荐理由、相似度分解
/api/graph	作者、关键词、主题、机构查询	节点、边、社区、中心性指标
/api/dashboard	数据集版本、过滤条件	报告指标、图表数据、质量诊断

3.4 可信答案原则

- 答案必须绑定证据卡，证据卡必须能追溯到论文标题、年份、作者和片段。
- 趋势判断必须同时给出数据依据和不确定性，避免把短期波动说成确定结论。
- 推荐结果必须解释“为什么推荐”，至少包含主题相似、关键词重叠、作者关系或时间新鲜度之一。
- 图谱查询必须区分真实合作边、关键词共现边和模型推断关系。

4 模型与算法设计

模型交付边界

赛题期望的“科研智能体模型”不应只理解为一个大语言模型权重。我们的模型资产应包括 Python 代码、索引文件、主题模型、推荐排序模型、趋势预测结果、图谱结构和 LLM provider 配置。大模型负责语言理解与生成, 领域洞察主要来自可复现的数据模型。

4.1 算法组合

模块	推荐技术	输出资产
文本检索	SQLite FTS5 或 BM25, 向量检索, RRF 融合	候选片段、分数、召回诊断
向量表示	bge 或 sentence-transformer 本地 embedding, 可替换为云端 embedding	向量索引、文本 chunk embedding
GraphRAG	作者合作图、关键词共现图、论文主题边与检索证据融合	图谱上下文、关系解释、路径证据
主题建模	BERTopic 或 embedding 聚类, 结合关键词抽取与人工可读标签	主题编号、主题词、代表论文
趋势预测	关键词频次时序、增长率、突增检测、滑动窗口预测	热点榜、趋势曲线、预测说明
论文推荐	向量相似、主题相似、时间加权、作者关系重排	推荐列表、解释因子、排序分

4.2 RAG 检索策略



4.3 趋势预测设计

趋势预测不追求夸张的“预测未来”，而是做可解释的热点识别: 对关键词、主题和领域构建按年或按月的时序矩阵, 计算增长率、近年加速度、突增分数和稳定性。最终输出应是“值得关注的方向 + 依据 + 不确定性”，而不是孤立的排行榜。

指标	含义
频次增长率	近三年出现频次相对历史均值的提升程度
突增分数	某关键词或主题在短时间内显著上升的强度
稳定性	热度是否连续增长, 避免一次性噪声造成误判
跨领域扩散	某主题是否从一个领域扩展到多个领域
证据密度	支撑该趋势的论文数量、代表论文和主题一致性

4.4 模型文件组织建议

路径	内容
data/processed/	清洗后的论文表、chunk 表、关键词时序表
indices/fts/	全文或摘要关键词检索索引
indices/vector/	LanceDB 或 FAISS 向量索引
models/topics/	主题模型、主题标签、代表论文映射
models/trends/	热点检测结果、趋势预测结果、解释元数据
graphs/	作者合作图、关键词共现图、主题关系图
configs/	DeepSeek、本地 vLLM、Mock provider 配置
providers.yaml	

5 AI Infra 架构思路


定位校准

AI Infra 是 SciScope 的工程可靠性和差异化加分项, 不是替代数据分析报告与科研智能体模型的主线。它的目标是让同一套智能体能力可以在三种环境下运行: Mock 快速验收, 本地 vLLM 离线运行, DeepSeek 高质量生成。

5.1 三档运行 profile

Profile	用途	技术路径
Lite	无模型环境下快速启动与 CI 验收	Mock provider + 预置证据 + 轻量索引
Local	本机离线演示与 Infra 展示	M5 Pro + vLLM-Metal + 本地 embedding + 轻量知识底座
DeepSeek	正式效果与复杂中文综述	DeepSeek API + 本地检索证据 + 引用约束生成

5.2 M5 单机优先, i5 可选增强



- 基础链路必须在 M5 单机完整跑通, 包括前端、后端、RAG、趋势 API 和模型 provider。
- i5 不承担关键路径, 只作为可选控制面、静态图谱托管或离线批处理节点。
- PostgreSQL 与 Qdrant 不进入默认依赖, 仅作为增强模式或后续生产化选项。
- Makefile 是工程入口, 评审、开发和演示都通过清晰命令启动。

5.3 模型 provider 路由

Provider	适合场景	注意事项
Mock	CI、无网、首次启动、接口验收	必须明确标记, 不代表最终回答质量
vLLM-Metal 0.5B	本地链路 smoke, 端口和 OpenAI-compatible API 验证	速度快, 质量有限
vLLM-Metal 7B	本机离线演示, 强调 M5 推理能力	需要模型下载和预热
DeepSeek	正式生成、中文综述、复杂推理	需要 API Key 与网络环境

5.4 Infra 应该服务的产品指标

- **启动确定性:** 一条命令能启动对应 profile, 端口和模型状态可检查。
- **回答可追溯:** 无论 provider 是 DeepSeek 还是本地模型, 答案都必须绑定本地检索证据。
- **失败可降级:** DeepSeek 不可用时能切回本地 vLLM 或 Mock, 系统不崩。
- **硬件友好:** 老 i5 不被设计为关键数据库中枢, M5 统一内存优先给模型与向量计算。

6 工程交付设计

交付原则

最终交付不是一个孤立 PDF, 也不是一个只能在开发机上运行的 demo。它应是一套可复现工程包: 数据处理代码生成分析资产, 后端服务消费这些资产, 前端工作台展示与交互, 模型 provider 提供可切换生成能力。

6.1 交付物清单

交付物	内容
数据分析报告	文献分布、关键词演化、作者合作网络、主题结构、趋势预测和洞察结论
科研智能体系统	Next.js 工作台, FastAPI 后端, RAG 问答, 推荐、趋势、图谱查询接口
Python 模型代码	数据清洗、索引构建、主题建模、趋势检测、推荐排序、图谱构建
模型与索引文件	向量索引、FTS 索引、主题模型、趋势结果、作者图谱、关键词矩阵
运行与验收文档	Makefile 命令、DeepSeek 配置、本地 vLLM 配置、故障排查、演示脚本

6.2 Makefile 命令分层

命令	作用
make install	安装前后端依赖和 Python 环境依赖
make ingest	读取样本数据, 生成标准化中间表
make index	构建 FTS、向量索引、主题模型和图谱资产
make report	生成数据分析报告所需图表和统计结果
make dev	启动默认开发链路, 可使用 Mock 或 DeepSeek
make vllm-serve	启动本地 vLLM-Metal OpenAI-compatible 服务
make dev-vllm	使用本地 vLLM provider 启动后端
make smoke	检查 ingest、dashboard、chat、recommend、trend、graph
make status	检查端口、索引文件、模型 provider 和数据版本

6.3 产品工作台页面

- **Overview:** 数据集规模、领域分布、年份趋势、热点关键词。
- **Ask:** 文献问答、证据卡、引用论文、检索诊断。
- **Trends:** 关键词演化、主题热度、突增检测、预测说明。
- **Graph:** 作者合作网络、关键词共现、主题关系路径。
- **Recommend:** 论文推荐、相似度解释、时间与主题过滤。
- **Workbench:** 一个研究问题贯穿问答、趋势、图谱、推荐的联动视图。

6.4 验收口径

1. 能从原始样本数据生成标准化资产和分析图表。
2. 能启动前端、后端和至少一种模型 provider。

3. `/api/chat` 能返回答案和证据, 且证据来自本地索引。
4. 趋势、推荐、图谱接口能返回结构化结果。
5. 所有对外结论都能追溯到数据资产或检索证据。

7 实施路线与风险控制

实施策略

先把 1 万样本做成稳定、可复现、可演示的闭环, 再扩展到 5 万全量。每个阶段都必须产生可检查资产, 避免只完成界面或只完成算法而没有端到端价值。

7.1 阶段路线

阶段	目标	验收物
Phase 1	样本数据清洗与报告骨架	processed 数据表、基础统计、报告章节草稿
Phase 2	检索与问答闭环	chunk、FTS、向量索引、/api/chat 证据返回
Phase 3	趋势与推荐模型	关键词时序、主题模型、推荐排序、趋势 API
Phase 4	图谱与 GraphRAG	作者图谱、关键词共现图、图谱查询、图谱辅助问答
Phase 5	产品化与 Infra 加固	工作台联动、DeepSeek、本地 vLLM、Makefile 验收

7.2 关键风险

风险	表现	控制方式
偏离赛题主线	过度讲 AI Infra, 数据分析和智能体能力不足	任何 Infra 章节都必须回扣问答、趋势、推荐或图谱
数据报告空泛	图表漂亮但统计口径不可复现	所有图表由 Python 脚本生成, 保留中间资产
RAG 答案幻觉	回答像综述但缺乏具体文献证据	强制证据卡、引用校验、答案和片段绑定
本地模型质量不足	小模型能跑但回答弱	正式质量使用 DeepSeek, 本地模型用于离线与 Infra 展示
老 i5 拖累链路	PostgreSQL、Docker 或向量库安装不稳定	默认 M5 单机, i5 只做可选增强

7.3 架构决策记录

- **默认轻量数据底座:** 用 SQLite、DuckDB、Parquet、LanceDB 或 FAISS 支撑 1 万到 5 万论文规模。
- **DeepSeek 是正式生成后端:** 用它保证中文综述、复杂推理和演示效果。
- **本地 vLLM 是可降级后端:** 用它证明系统可本地运行, 并作为无网兜底。
- **i5 是可选节点:** 它展示协同架构思路, 但不成为系统生命线。
- **报告和系统共享资产:** 数据分析报告不是孤岛, 智能体也必须调用同一批统计、索引和图谱资产。

7.4 最终状态定义

完成标准

当且仅当我们能从样本数据生成分析资产, 用这些资产生成报告图表, 启动科研智能体系统, 通过自然语言查询得到有证据的答案, 并展示趋势预测、论文推荐和图谱查询时, SciScope 才算真正跑在主线上。AI Infra 的完成标准是让这些能力更稳定, 而不是替代这些能力。