

SciScope 项目报告书

面向科技文献智能分析的科研智能体构建

赛道 智能体开发

成果类型 数据分析报告 + 科研智能体模型 (代码 + 模型文件)

核心能力 文献问答 · 趋势预测 · 论文推荐 · 知识图谱

数据规模 6 个公开来源 · 159,190 篇 (去重后) · 主窗口 2022-2026

模型资产 226,434 条片段向量 · 159,190 篇论文级向量

一句话定位

SciScope 把约 16 万篇公开科技文献炼成一个**可检索、可问答、可预测趋势、可推荐、可看图谱**的科研智能体。大语言模型仅作生成层、可任意替换; 领域智能沉淀在**本地可复现的索引与模型文件**中, 且每个回答都附**可追溯证据** (evidence-grounded)。这正是”科研智能体”区别于”直接问通用大模型”的核心价值。

目录

1	项目概述	2
1.1	项目背景	2
1.2	应用行业	2
1.3	主要工作	2
1.4	创新点	2
2	解决方案	2
2.1	总体方案设计	2
2.2	方案功能	3
2.3	关键技术	3
2.4	实现过程	3
2.4.1	数据生成与采集	3
2.4.2	数据组织与治理	3
2.4.3	信息汲取与建模	3
2.4.4	服务与交互	3
3	结果分析	4
3.1	数据底座规模与分布	4
3.2	检索质量与效率 (测试结果)	4
3.3	语义覆盖修复 (消融对比)	5
3.4	趋势预测结果	5
3.5	知识图谱与合作网络	5
3.6	模型资产规模	6
4	应用价值	6
4.1	社会效益	6
4.2	经济效益	6
4.3	推广前景	7
5	系统运行与复现说明	7
5.1	运行环境	7
5.2	一键安装	7
5.3	构建服务层与模型文件	7
5.4	启动与体验	8
5.5	质量与效果验证	8
5.6	全量重建 (数据更新后)	8
5.7	交付物清单	8

1 项目概述

1.1 项目背景

科研文献数量爆炸式增长, 科研人员在文献调研、知识提取、研究趋势分析等环节面临巨大挑战。传统关键词检索是字面匹配, 难以满足细粒度、多维度、个性化、跨语言的知识需求; 而直接使用通用大模型问答又存在**幻觉**、**无出处**、**不可复现**等问题, 无法支撑严肃的科研决策。本项目构建 **SciScope 科研智能体**, 自动解析文献、提取关键信息、构建知识图谱, 并支持自然语言问答与研究方向推荐, 在**每个结论都附可追溯证据**的前提下提升科研效率与知识管理水平。

1.2 应用行业

高校与科研院所、企业研发部门、科技情报与图书馆机构、科研管理与基金评审部门。典型场景: 研究热点定位、领域脉络梳理、潜在合作者识别、文献调研提速、立项查新与综述辅助。

1.3 主要工作

- **数据底座**: 从 arXiv、PubMed、PMC、OpenAlex、Crossref、DOAJ 6 个公开来源采集、清洗、规范化、去重, 形成 159,190 篇、跨计算机/生物医学/材料等多领域、主窗口 2022–2026 的可复现语料。
- **数据分析报告** (交付物): 文献分布、关键词演化、作者合作网络、主题模型、趋势统计 (见同级交付物 `sciscope_data_report`)
- **科研智能体模型** (交付物): 本地嵌入索引、混合检索、趋势预测、论文推荐、知识图谱五大模型, 配套 FastAPI 服务与 Next.js 工作台。
- **系统工程**: PostgreSQL + pgvector 服务层、本地大模型 (vLLM/MLX) 生成层、一键复现的 Makefile 流水线与自动化测试。

1.4 创新点

四个核心创新

1. **大模型无关的证据接地架构 (LLM-agnostic, evidence-grounded)**: 大模型只负责”用人话写答案”, 领域智能沉淀在本地可复现的索引/模型文件中; 换任意大模型系统照常工作, 每条回答均附引用论文, 杜绝幻觉、可审计。
2. **字面 + 语义混合检索 (Hybrid Retrieval)**: PostgreSQL 全文检索 (FTS) 与 pgvector 向量检索双路并行, 用 RRF(倒数排名融合) 合并, 兼顾精确匹配与语义/跨语言理解 (中文问句可命中英文文献)。
3. **”模型文件”即可复现资产**: 不依赖黑盒训练权重, 而是用本项目代码从本项目语料**计算/拟合**出的嵌入索引、趋势模型、推荐向量、知识图谱;`make agent-build` 可一键重建, 知识产权清晰、评委可复现。
4. **数据质量工程**: 标题优先去重 + 期刊 front-matter 剔除 + PDF 垃圾过滤 + 关键词噪声过滤 (剔除 arXiv 分类码与超泛学科标签), 显著提升检索、趋势与图谱的信噪比。

2 解决方案

2.1 总体方案设计

系统采用**可复现流水线** + **PostgreSQL 服务层**的分层架构, 数据自左向右逐层加工为”可问答系统”:

原始采集 (raw) → 清洗规范化/去重 (processed) → 分析资产 (analysis)
RAG/模型层 → PostgreSQL + pgvector 服务层 → FastAPI → Next.js 工作台

设计原则: 离线可复现 (每层产物由 `make` 目标生成); 大模型可替换 (生成层走 OpenAI 兼容接口); 证据可追溯 (回

答必带引用); 本地优先 (数据与索引均在本地, 支持涉密场景)。

2.2 方案功能

- **文献问答** /api/chat: 中/英文提问 → 混合检索证据 → 本地大模型基于证据生成带引用的回答。
- **混合检索** /api/search: FTS + 向量 + RRF 融合, 返回去重到论文级的结果与命中片段。
- **趋势预测** /api/trends: 关键词/主题的增长率、burst、生命周期与下一年线性外推 (含不确定区间)。
- **论文推荐** /api/recommend: 给定种子论文, 融合语义相似 + 关键词重叠 + 作者关系 + 时近性, 输出带可解释因子的推荐。
- **知识图谱** /api/graph: 作者合作图、关键词共现图、论文-主题图; 作者支持基于数据库的实时 ego 子图。
- **交互工作台**: Next.js 仪表盘 + 检索/趋势/推荐/图谱/问答五大面板。

2.3 关键技术

- **向量化**: 本地 multilingual-e5-base(768 维, 中英跨语言), fp16 加速, 可断点续传; 向量写入 pgvector chunk_embeddings。
- **混合检索与 RRF**: tsvector 全文索引 + ivfflat 余弦向量索引; 两路结果按 $1/(k + \text{rank})$ 融合 ($k=60$), 去重至论文级并回填标题/年份/作者/片段。
- **趋势模型**: 在逐年归一化词频上做最小二乘外推, 残差估计不确定带; 主题模型 LDA/NMF 各 40 个主题。
- **推荐模型**: 论文级平均向量 (pgvector avg) + 多信号加权融合, 每条推荐给出 semantic/keyword/author/recency 因子。
- **知识图谱**: NetworkX 计算中心度/社区, 导出前端友好 JSON; 百万级边表按中心度剪枝, 作者 ego 图走 SQL 实时查询。
- **生成层**: OpenAI 兼容本地服务 (vLLM-Metal / LM Studio), 输出限长防失控; 可平滑切换更大模型或远程模型。

2.4 实现过程

2.4.1 数据生成与采集

通过统一采集器从 6 个公开来源按领域、年份抓取元数据与部分全文; 原始数据落 data/raw_canonical/ 按”来源/年份”分区的 JSONL。

2.4.2 数据组织与治理

规范化统一字段 (标题/摘要/作者/年份/关键词/正文/来源); 治理环节修复三类质量问题: (a) **去重**——长标题 (25 字) 优先于 DOI 的去重键, 合并跨源/预印本-正式版同篇, 每组保留信息最全的一条, 并剔除期刊 front-matter; (b) **PDF 垃圾过滤**——剔除提取失败、混入 PDF 对象字节的”伪正文”; (c) **NUL 字节清洗**——保证入库稳定。治理后 160,488 → 159,190 篇, 残留长标题重复组归零。

2.4.3 信息汲取与建模

将语料切分为检索片段 (标题摘要/正文/关键词), 灌入 PostgreSQL; 计算片段向量与论文级向量, 拟合趋势、推荐、图谱与主题模型; 关键词环节统一过滤 arXiv 分类码 (cs.lg 等)、超泛学科标签与期刊名, 显著提升趋势与图谱质量。所有模型产物由 make agent-build 一键重建。

2.4.4 服务与交互

FastAPI 暴露五大接口, 前端工作台可视化; 问答链路在数据库不可用时自动回退内存检索, 保证演示鲁棒。

3 结果分析

3.1 数据底座规模与分布

治理去重后语料 159,190 篇, 主窗口 2022–2026 年分布均衡, 领域以计算机科学、生物医学、物理、材料为主。




图 1 领域分布: 计算机科学、生物医学、物理科学、材料科学为四大主力领域




图 2 年份分布: 主窗口 2022–2026 年每年约 3 万篇, 近五年覆盖充分

3.2 检索质量与效率 (测试结果)

采用**自检索协议** (以论文自身的标题/关键词为查询, 检验能否检回该文) 在全库 100 篇随机样本上评测:

查询方式	recall@1	recall@10	MRR@10	平均延迟
按标题 (含语义臂)	0.94	0.99	0.965	~250 ms
按关键词	0.60	0.69	0.63	~100 ms

标题查询近乎总能将目标论文排进前列 (recall@10=0.99), 延迟亚秒级, 体现混合检索的**效果与效率**。关键词查询指标偏低, 反映的是全库真实难度 (含摘要稀疏论文), 为后续优化指明方向, 数据真实不回避。

3.3 语义覆盖修复 (消融对比)

初版仅对”有全文”的论文嵌入, 导致语义检索严重偏向生物医学、对最大领域计算机科学近乎失明; 通过**全量标题摘要嵌入**修复后, 论文级向量从 17,913 跃升至 159,190, 计算机科学覆盖如下:

领域	修复前 (论文级向量)	修复后
computer science	87	58,038
biomedicine	9,668	46,405
physical sciences	5,646	28,098
materials science	20	14,572

修复后语义检索与推荐**覆盖全部 16 万篇全领域**, 中文问句可跨语言命中英文文献。

3.4 趋势预测结果

关键词清洗后, 热点排行回归真实研究主题:**retrieval augmented generation、large language model** 位居新兴前列, 与 2022–2026 年科研态势吻合; 主题模型 (40 主题) 清晰区分出 LLM、RAG、图神经网络、锂电池、蛋白结构、知识图谱、催化等领域。




图 3 关键词动量/趋势: 清洗噪声 (arXiv 分类码、期刊名) 后呈现真实研究热点

3.5 知识图谱与合作网络

作者合作网络与关键词共现网络可视化领域结构, 支持以某作者/关键词为中心的子图查询, 辅助识别潜在合作者与研究社区。




图 4 作者合作网络：揭示研究社区与潜在合作关系

3.6 模型资产规模

模型文件 / 索引	规模
片段向量 <code>chunk_embeddings(pgvector)</code>	226,434
论文级向量 <code>paper_embeddings</code>	159,190
主题模型 (LDA + NMF)	40 主题 / 模型
知识图谱 (作者/关键词/主题)	前端友好 JSON
后端自动化测试	92 项全部通过

4 应用价值

4.1 社会效益

- **科研提效与公平**: 把分散在多源、多语言的文献统一为可问答知识底座, 让中小机构、欠发达地区科研人员以更门槛获得高质量文献调研能力, 缩小科研信息鸿沟。
- **可信与可审计**: 每条回答均附引用论文 (evidence-grounded), 从源头抑制大模型幻觉, 支撑**科学决策**与严肃的立项查新、综述撰写, 减少误导性结论传播。
- **知识传承与脉络梳理**: 主题演化、关键词趋势与合作网络帮助新人快速理解领域发展脉络, 促进知识传承。
- **数据安全友好**: 本地优先架构 (数据、索引、可选本地大模型均在本地), 适配涉密/敏感科研场景, 符合数据安全与自主可控要求。

4.2 经济效益

- **效率提升**: 文献调研、热点定位、综述梳理等高耗时环节由”人工逐篇”转为”语义问答 + 证据直达”, 显著压缩科研前期投入工时。

- **成本优化**: 核心智能沉淀在本地可复现的索引与模型文件, 大模型仅作可替换的生成层——可用小模型本地推理、按需切换更强模型, 避免高昂的纯大模型 API 调用成本。
- **创新驱动与决策支持**: 趋势预测与热点识别为研发立项、技术路线选择、专利布局提供数据支撑, 降低试错成本。
- **合作拓展**: 作者合作网络辅助识别潜在合作者与团队, 促进产学研对接与资源整合。

4.3 推广前景

- **高校/科研院所**: 学科情报中心、研究生文献调研、综述与查新服务。
- **企业研发**: 技术情报监测、竞品与专利分析、研发选题。
- **科研管理**: 基金评审辅助、领域态势研判、合作网络分析。
- **可扩展性**: 架构与领域无关, 更换语料即可迁移到任意学科或企业内部文档库; 模型可替换、流水线可复现, 便于产品化与私有化部署。

差异化价值小结

相比“直接问通用大模型”, SciScope 的不可替代之处在于: 基于真实语料、有出处可追溯、本地可复现、领域可迁移、大模型可替换。它不是又一个聊天机器人, 而是一套把机构自有文献资产转化为可信科研生产力的智能体系统。

5 系统运行与复现说明

5.1 运行环境

- Python 3.11(conda 环境), Node.js(前端); PostgreSQL 15 + pgvector 扩展。
- 关键依赖: fastapi、psycopg、pgvector、sentence-transformers、scikit-learn、networkx、pandas。
- 本地大模型 (可选): vLLM-Metal / LM Studio 等 OpenAI 兼容服务; 无则自动用 mock, 检索证据仍真实。

5.2 一键安装

```
make install
```

```
# 安装后端 Python 依赖与前端 npm 依赖
```

5.3 构建服务层与模型文件

```
# 1. 服务层 (建库 + 装载语料/片段)
createdb sciscope
make postgres-schema POSTGRES_DSN=postgresql://USER@localhost:5432/sciscope
psql sciscope -f infra/postgres/pgvector.sql
make postgres-load POSTGRES_DSN=...

# 2. 数据治理: 去重 (先 dry-run 再 APPLY)
make dedupe-db # 干跑统计
make dedupe-db APPLY=1 # 实际去重

# 3. 模型层: 嵌入 + 推荐 + 趋势 + 图谱
SCISCOPE_EMBEDDER_PATH=models/embedder_local/multilingual-e5-base make embeddings
make recommend-model trend-model graph-export
# 或一键: make agent-build
```


5.4 启动与体验

```
# 带数据库 + 本地嵌入启动前后端
SCISCOPE_DB_DSN=postgresql://USER@localhost:5432/sciscope \
SCISCOPE_EMBEDDER_PATH=models/embedder_local/multilingual-e5-base make dev

# 终端直接问答（自动探测本地大模型）
make chat

# 接本地大模型生成（需:8001 上的 OpenAI 兼容服务）
make vllm-serve                                     # 启动本地模型
... make dev                                         # 配 LOCAL_LLM_* 指向该模型
```

打开 <http://localhost:3000> 使用工作台; 后端接口文档见 <http://127.0.0.1:8000/docs>。

5.5 质量与效果验证

```
make test                                           # 92 项后端测试 + 前端类型检查 + 构建
make eval-retrieval                                # 自检索评估:recall@k / MRR / 延迟
```

5.6 全量重建（数据更新后）

持续爬取积累新数据后，一次性重建并自动并入去重与全部模型：

```
make data-layer-refresh && make rag-chunks && make postgres-refresh && make agent-build
```

5.7 交付物清单

- **代码:**src/(采集/治理/分析/模型)、backend/(API)、frontend/(工作台)、infra/(schema)、Makefile(流水线)。
- **模型文件:**pgvector 向量索引、models/(嵌入器/趋势/推荐)、graphs/(图谱 JSON)、RAG 片段语料; 均可由 `make agent-build` 复现。
- **报告:** 本《项目报告书》与同级《数据分析报告》(output/pdf/sciscope_data_report)。
- **基础大模型:** 声明为可替换依赖 (任意 OpenAI 兼容端点), 不绑定特定模型。

SciScope · 面向科技文献智能分析的科研智能体 · 大模型可换, 证据可溯, 流水线可复现