

SciScope 项目报告书

面向科技文献智能分析的科研智能体构建

智能体开发赛道 数据分析报告 + 科研智能体模型 (代码 + 模型文件)

公开来源

6 个

公开采集口径

分析语料

168,447

数据分析报告口径

入库论文

159,187

运行时 PostgreSQL 口径

片段向量

367,773

pgvector 检索资产

核心能力

文献问答 趋势预测 论文推荐 知识图谱 论断核查

模型资产

159,135 篇论文级向量; 本地索引与模型文件可由 Makefile 流水线重建

一句话定位

SciScope 把约 16 万篇公开科技文献炼成一个**可检索、可问答、可预测趋势、可推荐、可看图谱**的科研智能体。大语言模型仅作生成层、可任意替换; 领域智能沉淀在**本地可复现的索引与模型文件**中, 且每个回答都附**可追溯证据** (evidence-grounded)。这正是”科研智能体”区别于”直接问通用大模型”的核心价值。

目录

1	项目概述	3
1.1	项目背景	3
1.2	应用行业	3
1.3	主要工作	3
1.4	创新点	3
2	解决方案	4
2.1	总体架构设计	4
2.2	核心链路: 证据接地的检索增强问答	4
2.3	智能体编排层: 从”固定管线”到”自主 agent”	5
2.4	开放与可扩展:MCP 双向互通 + 专员子智能体	7
2.5	方案功能	7
2.6	关键技术	7
2.7	实现过程	8
2.8	项目结构与分层	8
3	结果分析 (系统效果与效率)	9
3.1	检索质量与效率 (核心测试)	10
3.2	跨语言检索相关性优化 (技术创新)	10
3.3	语义覆盖修复 (消融对比)	11
3.4	差异化能力对比	11
3.5	趋势预测回测与推荐评估 (评测证据包)	12
3.6	数据治理成效	12
3.7	模型资产与工程质量	12
4	示例问答与测试用例	12
4.1	用例一: 英文混合检索 (双臂命中)	12
4.2	用例二: 中文跨语言检索 (命中英文文献)	13
4.3	用例三: 可解释论文推荐	13
4.4	用例四: 趋势热点 (模型输出)	13
4.5	用例五: 证据接地问答	13
4.6	用例六: 科研智能体自主多步编排 (真实轨迹)	13
4.7	用例七: 论断核查与跨语言接地 (verify_claim)	14
4.8	用例八:TUI 产品化工作流与黄金会话导出	14
5	应用价值	14
5.1	社会效益	14
5.2	经济效益	15

5.2.1 经济效益量化 (情景测算)	15
5.3 推广前景	16
6 系统运行与复现说明	16
6.1 运行环境	16
6.2 一键安装	16
6.3 构建服务层与模型文件	17
6.4 启动与体验	17
6.5 质量与效果验证	17
6.6 全量重建 (数据更新后)	17
6.7 交付物清单	17
7 数据来源与参考文献	18
7.1 数据来源	18
7.2 方法与模型来源	18

1 项目概述

1.1 项目背景

在文献更新加速与科研决策压力增大的场景下，核心问题不只是“能不能回答”，而是**可追溯性、可复核性与决策可用性**是否同时成立。传统关键词检索主要依赖字面匹配，难以覆盖跨语言、跨术语和多步骤研究问题；直接使用通用大模型问答又存在**幻觉、无出处、不可复现**等风险。SciScope 的定位不是更强的问答模型，而是将文献资产、检索证据、趋势解释与工具编排形成一条可复用、可验证的科研智能链路，在**每个结论都附可追溯证据**的前提下支撑文献调研、情报监测与科研治理。

1.2 应用行业

高校与科研院所、企业研发部门、科技情报与图书馆机构、科研管理与基金评审部门。典型场景：研究热点定位、领域脉络梳理、潜在合作者识别、文献调研提速、立项查新与综述辅助。

1.3 主要工作

- **数据底座**：从 arXiv、PubMed、PMC、OpenAlex、Crossref、DOAJ 6 个公开来源采集、清洗、规范化、去重，形成 168,447 条分析语料、159,164 篇处理后语料文件和 159,187 篇运行时入库论文，覆盖计算机/生物学/材料等多领域、主窗口 2022–2026。
- **数据分析报告** (交付物 1)：文献分布、关键词演化、作者合作网络、主题模型、趋势统计 (见同级交付物 `sciscope_data_report`)。
- **科研智能体模型** (交付物 2)：本地嵌入索引、混合检索、趋势预测、论文推荐、知识图谱五大模型，配套 FastAPI 服务与终端智能体客户端。
- **系统工程**：PostgreSQL + pgvector 服务层、本地大模型 (vLLM/MLX) 生成层、一键复现的 Makefile 流水线与自动化测试。

1.4 创新点

五个核心创新

1. **大模型无关的证据接地架构 (LLM-agnostic, evidence-grounded)**：大语言模型 (LLM) 只负责“用人话写答案”，领域智能沉淀在本地可复现的索引/模型文件中；生成层经 OpenAI 兼容接口**可插拔** (本地 7B DeepSeek 云端，一处配置切换)，换任意大模型系统照常工作。
2. **工具契约与确定性校验门**：9 个原生语料工具与 1 个 `delegate` 子智能体工具 (共 10 个运行时工具) 均通过统一 Tool 注册表暴露；工具声明只读性、参数校验和结果上限。调用前可拦截模型编造的论文主键 (`paper_id`)；显式科研技能还设置首工具强制调用与工具预算，从架构上降低幻觉、空跑和捏造风险，便于审计。
3. **字面 + 语义混合检索 (Hybrid Retrieval)**：PostgreSQL 全文检索 (FTS) 与 pgvector 向量检索双路并行，用倒数排名融合 (Reciprocal Rank Fusion, RRF) 合并，兼顾精确匹配与语义/跨语言理解 (中文问句可命中英文文献)。
4. **“模型文件”即可复现资产**：不依赖黑盒训练权重，而是用本项目代码从本项目语料**计算/拟合**出的嵌入索引、趋势模型、推荐向量、知识图谱；`make agent-build` 可一键重建，知识产权清晰、评委可复现。
5. **MCP 双向互通与专员子智能体**：SciScope 可作为模型上下文协议 (Model Context Protocol, MCP) 服务端把工具开放给外部客户端，也可消费外部 MCP 工具；复杂任务可通过 `delegate` 下派给综述员、趋势分析师、批判核查员三类专员子智能体，且结构上禁止递归委派。
6. **可观测运行与数据质量工程**：LangGraph 节点事件携带阶段、耗时、终止原因 (`stop_reason`) 和估算 token 用量；新增 `make agent-smoke` 黑盒验收，持续检查真实库表规模、能力边界、论断核查、趋势分析和论文

推荐的工具链路。数据层通过标题优先去重、front-matter 剔除、PDF 垃圾过滤和关键词噪声过滤提升检索、趋势与图谱信噪比。

数字口径说明: 本报告将数据规模分为四类口径: 数据分析报告使用 `data/analysis/summary.json` 的 168,447 条分析语料; 处理后语料文件使用 `data/processed/papers_corpus.summary.json` 的 159,164 篇; 运行时服务以 PostgreSQL 当前库表为准, 即 159,187 篇论文、367,773 个片段、367,773 条片段向量和 159,135 条论文级向量; 系统效果以 `output/eval/eval_report.json` 为准。四类口径用途不同, 不混写为同一个总数。

2 解决方案

2.1 总体架构设计

架构以**数据资产可复现、证据可追溯、决策可复核**为主线。系统分为数据治理与分析资产层、模型与索引层、服务与接口层、智能体编排层四类能力; 各层既可独立评估, 也共享同一数据口径, 便于持续更新与复现。图 1 展示底层数据到智能体交互的完整链路, 图 2 则把工程组件收束为评委可快速识别的能力地图。




图 1 SciScope 总体架构: 采集、治理、分析/模型、服务、接口与交互逐层衔接; 交互层以**终端智能体**自主编排工具, 大模型仅作可替换的生成层。数据来源: 系统实现、Makefile 产物与交付目录映射。

设计原则:(1) 离线可复现, 每层产物由 `make` 目标生成;(2) 大模型可替换, 生成层走 OpenAI 兼容接口;(3) 证据可追溯, 回答必带引用;(4) 本地优先, 数据与索引均在本地, 支持涉密场景。

2.2 核心链路: 证据接地的检索增强问答

问答不直接交给大模型臆测, 而是**先检索证据、再据证生成**, 每条回答都可追溯到具体论文: 见图 3。

检索融合口径: 字面检索与语义检索分别给出排序后, 系统使用倒数排名融合 (Reciprocal Rank Fusion, RRF) 合并多路结果:

$$\text{RRF}(d) = \sum_{r \in R} \frac{1}{k + \text{rank}_r(d)}, \quad k = 60$$

其中 R 表示参与融合的检索路由, d 为候选论文或片段; 该口径能让字面命中和语义相关共同进入证据池。

SciScope capability map

Local-first data intelligence stack: reproducible assets -> grounded agent -> product client




图 2 SciScope 能力地图: 从可复现数据资产到证据接地智能体, 再到终端产品化客户端。数据来源: 系统实现与交付目录映射。



图 3 混合检索 + 证据接地生成链路 (中文问句可跨语言命中英文文献)

2.3 智能体编排层: 从”固定管线”到”自主 agent”

上节的检索增强生成 (Retrieval-Augmented Generation, RAG) 问答是**固定流程**。在其之上, 我们构建了**自主科研智能体**: 大模型不再被动接收检索结果, 而是自己**规划步骤**、**自主选择并调工具**、**观察结果后决定下一步**, 必要时**自我纠错重试**。图 4 与图 5 展示了从后端编排到终端可视化的同一条事件链。




图 4 自主智能体循环: 规划 → 选工具 → 并行执行 → 观察 → (循环) → 反思自评 → 据证作答

核心机制:

- **显式规划 (plan)**: 复杂问题先生成可执行步骤计划 (仅引用内置工具, 且 recommend/compare 等依赖 paper_id 的工具会被安排在 search 之后), 再据计划逐步执行; 计划对用户与评委**可见**。
- **工具自主编排**: 大模型按需调用 9 个原生语料工具和 1 个 delegate 专员委派工具, 可**多步链式** (如先 search 拿到真实 paper_id 再 recommend_papers / get_trends); 只读工具**并行执行**; 相同参数调用**自动去重**防止空转。
- **专业技能 workflow**: TUI 的 /verify、/review、/trend、/recommend 会展开为 .sciscope/skills 中的可审计工作流模板, 分别约束论断核查、综述、趋势分析和论文推荐的工具使用顺序。

Agent trace: from question to grounded answer



图 5 TUI 中可见的智能体执行轨迹: 科研工作流阶段、工具调用、证据卡、reflect 与 final 均通过 SSE 事件流呈现, 便于评委复核系统不是黑盒问答。

- **反思与自评 (reflect):** 回答后由模型自评“是否充分、关键论断是否都有证据支撑”, 不足则改写检索重试一次。
- **上下文压缩:** 长会话自动压缩历史工具结果, 避免超出上下文窗口。
- **会话态与错误恢复:** TUI 传入 `session_id`, 后端映射为 `LangGraph thread_id` 并通过 `checkpoint` 保留会话态; `retry` 在同一线程内携带 `retry=true` 触发恢复。
- **服务/客户端分离:** agent 核心运行于 `/api/agent/stream`(SSE 流式)。事件 `meta` 同时返回运行时、节点、用户可读阶段 (`phase`)、耗时、会话与 `retry` 标记; 当前客户端为 Go TUI, 通过同一 SSE 契约消费智能体核心。
- **可插拔生成层:** 生成大模型经 OpenAI 兼容接口接入, 一处配置即可在本地 7B(离线/涉密) 与 DeepSeek 云端(更强质量) 之间切换, 检索、接地与编排逻辑保持不变——模型成为可替换组件而非锁定项。
- **工具契约 + 执行前校验门:** 每个工具是带契约的一等对象 (自声明只读性、参数校验、结果上限); 调用前做确定性校验——如 `recommend_papers/get_paper` 的 `paper_id` 必须真实, 在访问数据库之前即拦截模型编造的 ID 并提示其先检索, 从机制上消除“凭空捏造主键”的失败模式。显式技能若首轮跳过必需工具, 运行时会强制补上主工具调用; 技能默认 2 次工具预算后强制综合, 避免空跑和无限检索。工具目录由各工具自描述拼装, 与实际工具集永不漂移。
- **自适应检索 + 可观测终止:** 模型自行判断是否需要检索 (概念/常识类问题直接作答而非空转检索), 且检索讲求效率; 每轮在 `meta` 中返回终止原因 (`stop_reason`) 与 `token` 用量, 使智能体的停止条件可解释、调用成本可计量。

当前产品化路线: Agent 由单一 `LangGraph StateGraph` 编排, 无运行时开关。 `meta.phase` 将底层节点翻译为用户可理解的科研工作流阶段; TUI 在运行中显示阶段条, 并用分组 `/timeline` 回看证据链。 `session_id` 映射为 `thread_id`, `checkpoint` 保存会话态, `retry` 支持多线程错误恢复。 MCP 双向互通与专员子智能体已落地 (见后文“开放与可扩展”小节); 下一阶段聚焦持久化 `checkpoint` 与 Human-in-the-Loop。 9 个原生语料工具与 1 个 `delegate` 专员工具 (共 10 个运行时工具) 均通过同一 `Tool` 注册表维护。

用户可见阶段	对应节点	TUI 呈现
理解问题	<code>prepare</code>	解析问题、装载会话上下文
制定研究计划	<code>plan</code>	展示可执行研究步骤
推理与检索决策	<code>llm_step</code>	选择是否调用工具与下一步动作
证据检索	<code>execute_tools</code>	调用检索、趋势、推荐、核查等工具
自检修正	<code>reflect</code>	判断证据是否充分, 必要时重试
综合回答	<code>force_synthesis/final</code>	输出“研究结论 + 证据工具 + 过程入口”

工具	作用
search_literature	跨语言混合检索 (FTS + 向量 + 倒数排名融合 RRF + 双语映射 + 重排)
get_trends	Mann-Kendall(MK) 趋势判定 + Sen's 斜率 + 下一年预测
recommend_papers	语义 + 关键词 + 作者 + 最大边际相关 (Maximum Marginal Relevance, MMR) 多样性的可解释推荐
get_paper	按 paper_id 取论文详情
summarize_field	检索代表论文作为领域综述素材
compare_papers	取两篇论文详情用于多维对比
query_knowledge_graph	作者/关键词/主题图谱与研究社区主题
export_bibliography	导出 BibTeX 引文条目
verify_claim	跨语言论断核查 : 用语义接地度判定支持等级并给出处
delegate	将聚焦子任务交给综述员、趋势分析师或批判核查员三类专员子智能体

2.4 开放与可扩展:MCP 双向互通 + 专员子智能体

在固定的领域工具之外, 智能体层做了三项可扩展性升级, 使 SciScope 从” 封闭工具集” 走向**开放智能体生态**:

- **SciScope 作为 MCP 服务端**: 当前 Tool 注册表经模型上下文协议 (Model Context Protocol, MCP) 对外暴露, 任意 MCP 客户端 (Claude Desktop、Cursor 等) 可直接调用我们的接地语料检索与 verify_claim 核查——把护城河 (16 万语料) 开放成生态入口而非自用孤岛; 复用同一工具契约, 零重复实现。
- **消费外部 MCP 工具**: 智能体可将外部 MCP 服务端的工具按 mcp__server__tool 命名并入工具注册表, 与原生工具统一调度。**新增能力 (如联网取全文、Web 检索) 由” 插入 MCP 服务” 获得, 而非新增原生代码**, 核心工具保持精简、聚焦治理语料。
- **专员子智能体 (多 Agent 分工)**: 复杂多面任务可经 delegate 工具下派给**综述员 / 趋势分析师 / 批判核查员**三类专员, 各携受限工具集独立完成子任务; 专员工具集不含 delegate, **结构上杜绝递归**。

设计取舍 (据实): 不堆砌与科研场景无关的通用编程工具; 核心保持领域工具精简, 长尾能力靠 MCP 与子智能体扩展——与主流生产级智能体” 核心工具精、扩展靠 MCP/sub-agent” 的工程哲学一致。

2.5 方案功能

- **科研智能体 /api/agent/stream**: 大模型自主规划并编排上述能力 (9 个原生语料工具 + 1 个 delegate 工具), 多步推理、自我纠错、据证作答; 终端助手 make tui 提供 Claude Code 风格的流式交互, 并通过 /verify//trend//recommend 等技能命令把常见科研任务展开为可审计工具链。
- **文献问答 /api/chat:GraphRAG**(查询抽取关键词实体 → 沿共现图扩展邻居 → query expansion)+ 混合检索证据 → 本地大模型据证生成带引用回答 → **答案可被证据支撑性校验** (低置信明确提示)。
- **混合检索 /api/search**:FTS + 向量 + RRF 融合, 去重到论文级, 返回命中片段。
- **趋势预测 /api/trends**: 关键词/主题的增长率、burst、生命周期与下一年线性外推 (含不确定区间)。
- **论文推荐 /api/recommend**: 语义相似 + 关键词重叠 + 作者关系 + 时近性融合, 输出**可解释因子**。
- **知识图谱 /api/graph**: 作者合作图、关键词共现图、论文-主题图; 作者支持实时 ego 子图。

2.6 关键技术

- **向量化**: 本地 multilingual-e5-base(768 维, 中英跨语言),fp16 加速、断点续传; 向量入 pgvector。
- **混合检索与 RRF**: 全文索引 (tsvector) + 余弦向量索引 (ivfflat), 两路按 $1/(k + \text{rank})$ 融合 ($k=60$)。
- **趋势模型**: 逐年归一化词频上最小二乘外推 + 残差不确定带; 主题模型 LDA/NMF 各 40 主题。趋势热度 $h_{k,y} = n_{k,y}/N_y$, 预测采用 $\hat{h}_{k,y+1} = a_k y + b_k$ 作为排序信号, 不作确定性预言。

- **推荐模型**: 论文级平均向量 (pgvector avg)+ 多信号加权, 逐条给出可解释因子; 重排采用最大边际相关 (Maximum Marginal Relevance, MMR), 即 $\lambda \text{sim}(q, d) - (1 - \lambda) \max_{d' \in S} \text{sim}(d, d')$, 兼顾相关性与多样性。
- **知识图谱**: NetworkX 中心度/社区, 百万级边按中心度剪枝导出 JSON, 作者 ego 图走 SQL 实时查询。
- **生成层**: OpenAI 兼容本地服务, 输出限长防失控, 可平滑切换更大/远程模型。
- **智能体编排**: 基于 LangGraph StateGraph 的科研智能体运行时。prepare / plan / LLM step / tool execution / reflect / final synthesis 被拆为可观察节点; 底层使用本地 Qwen2.5-7B(vLLM, hermes 工具解析), 支持流式选工具、只读工具并行执行、调用去重、plan/reflect 自校验、会话 checkpoint 与多线程 /retry; 事件流通过 phase 字段向用户呈现科研工作流阶段。

证据接口: verify_claim 不把语义相似度包装为形式逻辑证明, 而是将论断 c 与证据片段 e 的接地强度表达为可解释评分:

$$g(c, e) = \alpha \text{sim}(c, e) + \beta \text{source}(e) + \gamma \text{recency}(e)$$

该评分用于支持等级与证据排序; 最终结论仍必须展示出处, 并由 reflect 节点检查关键论断是否有证据支撑。

2.7 实现过程

数据生成与采集 → 6 源按领域/年份抓取, 落 data/raw_canonical 分区 JSONL。

数据组织与治理 → 规范化字段; 标题优先去重 (合并跨源/预印本同篇, 留最全一条)+ front-matter 剔除 + PDF 垃圾/ NUL 清洗; 168,447 条分析语料进一步形成 159,164 篇处理后语料文件, 运行时库表当前装载 159,187 篇论文。

信息汲取与建模 → 切片入库, 计算片段/论文向量, 拟合趋势/推荐/图谱/主题; 关键词统一过滤 arXiv 码与超泛标签。make agent-build 一键重建。

服务与交互 → FastAPI 暴露检索/问答/趋势/推荐/图谱及**智能体流式**接口; 终端 AI 助手 make tui 自主编排工具; 数据库不可用时自动回退内存检索, 保证演示鲁棒。

2.8 项目结构与分层

代码按”数据 → 模型 → 服务/RAG → 智能体 → 接口 → 客户端”六层组织, 职责单一、依赖自底向上: **Python 承载全部智能** (从数据到 agent), **Go 仅作终端客户端** (经 SSE 消费, 可替换、不绑定)。

```

数据要素/
├── data_pipeline/ [1] 加载 / 规范化
├── src/
│   ├── harvest, analysis/ [1] 6 源采集 / 分析资产 -> 数据报告
│   └── models/ [2] 嵌入 · 趋势 · 推荐 · 图谱 · 双语 · 重排
├── models/, output/graphs/ [2] 模型文件 / 知识图谱 JSON
├── backend/app/
│   ├── services/ [3] 混合检索 (RAG) · GraphRAG · 证据接地
│   ├── agent/ [4] LangGraph StateGraph(plan-> 执行-> 观察-> 反思, session/retry, 9 原生工具 +delegate)
│   └── api/ [5] /api/agent/stream(SSE meta)+ search / chat / trends
├── tui/ [6] Go · Bubble Tea 终端客户端 (消费 SSE)
└── PostgreSQL + pgvector 运行时: papers · chunk_embeddings · ...

```

分层	职责与代码位置
1. 数据层	6 源采集 -> 规范化 / 标题优先去重 -> 分析资产 (data_pipeline、src/harvest、src/analysis)
2. 模型层	片段/论文向量、趋势、推荐、图谱等模型文件, 入 PostgreSQL + pgvector(src/models、models/、output/graphs/)
3. 服务 / RAG	混合检索 (FTS + 向量 + RRF + 双语 + 重排)+ GraphRAG + 证据接地 (backend/app/services)
4. 智能体	LangGraph StateGraph:prepare -> plan -> 选工具 -> 并行执行 -> 观察 -> 反思自评 -> 据证作答; 支持 session checkpoint 与多线程 /retry(backend/app/agent)
5. 接口	FastAPI; 智能体经 /api/agent/stream 以 SSE 流式输出, 并在 meta 中暴露 runtime / node / phase / elapsed / session / retry(backend/app/api)
6. 客户端	Go / Bubble Tea 终端 (tui/main.go), 纯 SSE 消费; 将 phase 渲染为科研工作流阶段条与分组 /timeline; 浏览器侧仅作为品牌宣传、下载与文档入口规划

3 结果分析 (系统效果与效率)

说明: 本章给出三组可复核证据: 检索有效性 (recall/MRR 与延迟)、跨语言相关性 (relevance@5) 与工程稳健性 (自动化测试与资产口径)。指标以脚本生成的评测报告和运行时库表为准; 若与具体业务场景不一致, 应以场景化验证补充, 避免确定性外推。

核心指标一览

检索质量	标题自检索 recall@10= 0.985 ,MRR@10= 0.9583 , 平均延迟 141.6 ms 。
跨语言相关性	中文主题查询 relevance@5= 1.0 (15/15), 优化前为 0.667。
趋势预测	2022-2024 拟合预测 2025, 关键词活跃度排序 Pearson= 0.9756 。
论文推荐	top-5 平均语义相似 0.8918 , 同领域率 0.6733, 共享关键词率 0.6013。
工程质量	后端自动化测试实测 141 passed ;make agent-smoke 黑盒验收通过; 运行时库表含 367,773 条片段向量和 159,135 条论文级向量。





图 6 核心评测指标图形化总览。数据来源:output/eval/eval_report.json 与当前验收记录; 中文相关性为固定主题查询评测口径, 测试项为后端测试基线。

Data-to-agent asset funnel



Counts are file-asset counts, not inflated claims; runtime DB/vector counts are reported separately in tables.

图 7 数据到智能体的资产漏斗。数据来源: data/analysis/summary.json、data/processed/*.summary.json 与 output/eval/eval_report.json; 图中为文件资产口径, 运行时数据库/向量表口径在本章表格中另列。

图 6 将核心效果指标集中展示, 图 7 则说明这些指标背后的文件资产链路。二者分别对应”系统效果”与”可复现资产”两个评审入口。

3.1 检索质量与效率 (核心测试)

采用**自检索协议** (以论文自身标题/关键词为查询, 检验能否检回该文) 评测混合检索。评测结果固化于 output/eval/eval_report.json; 运行时库表当前包含 159,187 篇论文:

查询方式	recall@1	recall@10	MRR@10	平均延迟
按标题 (字面 + 语义臂)	0.94	0.985	0.9583	141.6 ms
按关键词	0.6913	0.745	0.7045	84.2 ms

标题查询 recall@10 达 **0.985**(目标论文几乎总在前 10), 平均延迟 141.6 ms, 体现混合检索”**效果与效率**”兼顾。关键词查询由于同义词、缩写和领域词复用更强, 指标低于标题查询, 但仍保持 recall@10=0.745 和 MRR@10=0.7045; 本报告保留该差异, 不把关键词检索夸大成标题级精确命中。

3.2 跨语言检索相关性优化 (技术创新)

针对真实用户的**中文短查询**, 初版多语言嵌入存在”按语言而非主题召回”的偏差 (如查”扩散模型”却召回到无关的中文医学论文)。我们用 15 个主题查询构建 **relevance@5** 指标 (top-5 是否含主题相关论文,make 可复现), 针对性实施了一组优化:

优化	作用
中英术语映射	中文查询自动替换/补充英文等价词, 把召回锚定到 (以英文为主的) 语料主题
混合字面臂	websearch 精确短语优先 + OR 兜底, 兼顾精确命中与多词召回
语义跨语言答案校验	用 e5 余弦度量”答案 ↔ 证据”接地气度, 中文答案据英文文献不再被误判低置信
”最新”意图识别	识别”最新/近期”等意图, 在相关结果中优先近年论文
多轮对话记忆	指代型追问 (”它的局限呢”) 自动承接上文主题再检索

效果:relevance@5 从 **0.667 提升至 1.0**(15/15 全部命中主题), ”扩散模型””强化学习””量子计算””推荐系统”等此前跑偏的中文查询**全部修复**。

3.3 语义覆盖修复 (消融对比)

初版仅对”有全文”论文嵌入,导致语义检索严重偏向生物医学、对最大领域**计算机科学近乎失明** (论文级向量仅 87 篇);经**全量标题摘要嵌入**修复后,论文级向量 17,913 → 159,164,各领域覆盖如下 (消融前后对比):




图 8 语义检索领域覆盖: 修复前 (空心)vs 修复后 (实心)。计算机科学从 87 跃升至 58,038, 偏科消除。数据来源: 论文级向量覆盖统计与全量标题摘要嵌入修复记录。

修复后语义检索与推荐覆盖运行时全领域论文库, 中文问句可跨语言命中英文文献。

3.4 差异化能力对比

verify_claim grounding workflow




图 9 verify_claim 论断接地流程。数据来源: 工具契约与黄金会话; 输出为支持等级和可追溯证据。

图 9 对应差异化矩阵中的”据实接地/可验证”能力。系统给出支持等级与出处, 但不把语义相似度包装为形式逻辑证明。

能力维度	SciScope	通用大模型	商用文献工具	普通检索
据实接地 / 可验证	verify_claim + 引用证据	易幻觉	部分支持	不支持
跨语言中 → 英检索	relevance@5=1.0	依模型能力波动	通常较弱	不支持
本地部署 / 数据主权	数据、索引、模型本地	查询上传第三方	查询上传第三方	仅检索外部库
自主多步编排	LangGraph plan/reflect + skills + 9 原生工具 + delegate	非工具化问答	固定流程为主	不支持
可复现 / IP 清晰	make 重建资产	黑盒调用	平台黑盒	无模型资产

差异化不来自”又接了一个大模型”, 而来自**本地语料资产、可复现模型文件、证据接地检验和自主工具编排**共同形成的科研智能体闭环。

3.5 趋势预测回测与推荐评估 (评测证据包)

完整评测可由 `make eval-all` 复现, 结果固化于 `output/eval/eval_report.{json,md}`。

趋势预测回测 (拟合 2022-2024 → 预测 2025, 1,998 个关键词): 预测与真实的 Pearson 相关 **0.9756**, 说明模型能较好排序哪些关键词更活跃; 但方向性与点预测不应被解释为确定预测, 归一化词频存在年际噪声和近均值回归。本报告仅把趋势模型作为排序、动量和 burst 的候选信号。

推荐离线评估 (150 篇种子, top-5): 同领域率 **0.6733**、共享关键词率 **0.6013**、平均语义相似 **0.8918**——远高于随机基线, 且每条附可解释因子。

3.6 数据治理成效

治理项	处理	效果
标题优先去重 + front-matter 剔除	分析层与处理后语料分层治理	残留长标题重复组归零
PDF 垃圾正文过滤	清 83 篇 / 46 片段	显著减少回答混入 PDF 乱码的风险
关键词噪声过滤	arXiv 码/泛标签/期刊名	趋势 top 回归真实主题
摘要覆盖治理	140,183 篇有摘要	摘要覆盖率 83.22%, 支撑主题和检索解释
全文片段治理	17,682 篇有正文字段	正文覆盖率 10.50%, 用于深读补充证据

关键词清洗后, 趋势热点回归真实研究主题: **retrieval augmented generation**、**large language model** 位居新兴前列; 主题模型 (40 主题) 清晰区分 LLM、RAG、图神经网络、锂电池、蛋白结构、催化等方向。

3.7 模型资产与工程质量

模型文件 / 索引 / 质量项	规模
片段向量 <code>chunk_embeddings</code> (pgvector)	367,773
论文级向量 <code>paper_embeddings</code>	159,135
主题模型 (LDA + NMF)	40 主题 / 模型
知识图谱 (作者/关键词/主题)	客户端友好 JSON
后端自动化测试	<code>make test-backend</code> 实测 141 passed; <code>make agent-smoke</code> 实测通过

产品化呈现: 智能体运行时已默认切到 `LangGraph` `StateGraph`。SSE `meta` 暴露 `runtime/node/phase/elapsed_ms/session_id/retry`; TUI 据此渲染科研工作流阶段条、分组 `/timeline`、会话保存与 `/retry` 错误恢复。最终回答采用”研究结论 + 证据工具 + 过程入口”结构, 工具日志不混入主聊天。专业技能命令经 `make agent-smoke` 黑盒验收: 能力边界不工具, 论断核查调用 `verify_claim`, 趋势分析调用 `get_trends`, 论文推荐执行 `search_literature -> recommend_papers`, 且均在工具预算内停止。全部模型文件仍可由 `make agent-build` 一键重建, 知识产权清晰、评委可复现。

4 示例问答与测试用例

下列为系统在真实 16 万篇语料上的**实际输出** (非示意), 用于直观展示检索、跨语言、推荐与证据接地能力。

4.1 用例一: 英文混合检索 (双臂命中)

查询: `graph neural network materials discovery`

返回 (`lexical` + `semantic` 双臂命中):

1. Accelerated Discovery of Energy Materials via Graph Neural Networks (2025)

2. CTGNN: Crystal Transformer Graph Neural Network for Crystal Materials (2024)
3. DeepCrysTet: A Deep Learning Approach Using Tetrahedral Mesh (2023)

4.2 用例二：中文跨语言检索 (命中英文文献)

查询：大语言模型的检索增强生成 (中文)

返回 (**semantic** 语义臂, 跨语言命中英文论文):

1. Retrieval-Augmented Retrieval: Large Language Models are Strong Zero-Shot Retrievers (2024)
2. LExT: Towards Evaluating Trustworthiness of Natural Language Explanations (2025)
3. A Comprehensive Study of Jailbreak Attack versus Defense for LLMs (2024)

4.3 用例三：可解释论文推荐

种子论文:PMC13273979(AI 药物发现方向)

推荐 (每条附可解释因子 semantic / keyword / author / recency):

推荐论文	年份	语义相似	融合因子
Generative AI in drug discovery and development	2024	0.941	sem .56 / kw .10
Editorial: Advancing drug discovery with AI	2025	0.934	sem .56 / kw .10
Advancing Drug Discovery with AI: Machine and Deep Learning	2026	0.915	sem .55 / kw .10

4.4 用例四：趋势热点 (模型输出)

/api/trends 新兴热点排行 (关键词清洗后): retrieval augmented generation → large language model
→ gene delivery → ...

与 2022-2026 年科研态势吻合,RAG 与大语言模型领跑。

4.5 用例五：证据接地问答

提问：图神经网络在材料发现中有哪些应用？

系统流程：混合检索 → 取 Top 证据 (如 *A review on the applications of GNNs in materials science、crystal graph convolutional neural network*)→ 本地大模型**仅基于证据**生成回答, 并标注引用 [n]。

关键特性：回答可追溯到具体论文; 证据不足时如实说明, 不臆造。

4.6 用例六：科研智能体自主多步编排 (真实轨迹)

下面是终端智能体 make tui 处理一个复合问题的**真实执行轨迹** (本地 Qwen2.5-7B), 展示”规划 → 自主选工具 → 多步链式 → 据证作答”:

提问：推荐几篇关于知识图谱的代表论文并说明趋势

1. plan 自动生成计划:search_literature(知识图谱) → recommend_papers → get_trends

2. 执行 智能体依计划链式调用:

1. search_literature{query:" 知识图谱"} —— 跨语言命中英文文献, 取得真实 paper_id
2. recommend_papers{paper_id:"W2789524213"} —— 把上一步得到的 id 喂入推荐 (多步链式, 非固定管线)

3. `get_trends{keyword:"knowledge graph"}` —— 中文关键词**自动转英文**查趋势

3. 据证作答 综合三个工具的真实结果, 给出代表论文清单 + 趋势判定, 并标注出处。

关键特性: 计划对用户可见;`recommend` 用的是**检索得到的真实 id 而非臆造**; 相同参数调用自动去重防空转; 回答后还会**自评证据是否充分**, 不足则改写重试。

4.7 用例七: 论断核查与跨语言接地 (`verify_claim`)

下面展示第 9 个智能体工具 `verify_claim` 的真实输出轨迹: 用户给出中文论断, 系统检索英文文献并用同一跨语言 `e5` 向量空间计算“论断-证据”接地度, 返回支持等级而不是让大模型直接判断。

待核查论断: 检索增强生成能够降低大语言模型回答中的幻觉风险

工具输出: 支持等级 = **强支持**, 最高接地相似度 = **0.846**

主要证据:

1. *Retrieval-Augmented Generation and Hallucination in Large Language Models: A Scholarly Overview* 2025, 相似度 0.846
2. *Reinforced Retrieval-Augmented Generation in Large Language Models* 2025, 相似度 0.846
3. *ReRag: A New Architecture for Reducing the Hallucination by Retrieval-Augmented Generation* 2024, 相似度 0.836
4. *Benchmarking Large Language Models in Retrieval-Augmented Generation* 2023, 相似度 0.827

关键特性: 中文论断可由英文论文接地; 工具返回的是**强支持 / 部分支持 / 证据不足**的校准信号, 要求模型据证表述, 证据不足时不得强行断言。

4.8 用例八:TUI 产品化工作流与黄金会话导出

终端客户端将底层 `LangGraph` 节点翻译为用户可读的科研工作流阶段。用户看到的是研究过程, 而不是内部工具日志:`/timeline` 按阶段回看证据链, 最终回答固定为”研究结论 + 证据工具 + 过程入口”。

黄金会话样例:`docs/examples/golden_verify_claim_session.md`

用户问题:RAG 能否降低科研问答系统中的幻觉风险? 请给出证据和判断边界。

阶段	样例中的可见动作
制定研究计划	将中文论断改写为英文检索表达, 规划证据核查路径
证据检索	调用 <code>verify_claim</code> 与文献检索, 返回支持等级和证据卡
自检修正	将结论限定为”降低风险”, 不夸大为”完全消除幻觉”
综合回答	输出研究结论、依据、判断边界和可复现入口

输出边界: 结论表述为”降低幻觉风险并提升可核验性”; 证据工具与 `/timeline` 入口保留给评委复核。

I 5 应用价值

本章只讨论系统产品化带来的组织层价值; 数据来源、字段质量与分析可信边界详见《SciScope 数据分析报告》。价值主线是从**效率提升**走向**决策质量提升**, 再沉淀为机构可复用的**科研情报治理能力**。

5.1 社会效益

- **科研提效与公平:** 把分散在多源、多语言的文献统一为可问答知识底座, 让中小机构、欠发达地区科研人员以更低门槛获得高质量文献调研能力, 缩小科研信息鸿沟。

- **可信与可审计**: 每条回答均附引用论文 (evidence-grounded); **论断核查** (verify_claim) 用跨语言语义接地度给出”强支持/部分支持/证据不足”等级, **工具校验门**在调用前拦截模型编造的论文主键——从生成与调用两端共同抑制大模型幻觉与捏造, 支撑**科学决策**与严肃的立项查新、综述撰写, 减少误导性结论传播。
- **知识传承与脉络梳理**: 主题演化、关键词趋势与合作网络帮助新人快速理解领域发展脉络, 促进知识传承。
- **数据安全友好**: 本地优先架构 (数据、索引、可选本地大模型均在本地), 适配涉密/敏感科研场景, 符合数据安全与自主可控要求。
- **开放与可复用**: 工具经 MCP 协议开放, 接地语料检索与论断核查可被任意 LLM 客户端 (Claude Desktop 等) 复用, 降低各机构重复建设, 放大公共科研基础设施的外溢价值。

受益群体	具体行动	可验证支撑
青年研究者 / 研究生	用中文问题直达英文前沿, 快速获得代表论文、趋势和引用证据	跨语言 relevance@5=1.0; 回答附证据卡与支持等级
科研管理者	基于热点、生命周期、合作网络制定学科布局和指南方向	数据分析报告中的关键词演化、作者社区和质量边界
高校图书馆 / 情报部门	将年度文献巡检沉淀为可复现流程和可复用报告模板	make 流水线、报告 PDF、评测证据包
企业研发 / 技术情报团队	用趋势、推荐和图谱筛选技术路线、竞品方向与潜在合作对象	推荐同领域率 0.6733、语义相似 0.8918、图谱导出
涉密或内网机构	在本地部署语料、索引、嵌入器和生成模型, 减少敏感查询外发	PostgreSQL + pgvector + 本地 7B / 可替换生成层

5.2 经济效益

- **效率提升**: 文献调研、热点定位、综述梳理等高耗时环节由”人工逐篇”转为”语义问答 + 证据直达”, 显著压缩科研前期投入工时。
- **成本优化**: 核心智能沉淀在**本地可复现的索引与模型文件**, 大模型仅作可替换的生成层——可用本地 7B 推理 (边际成本近 0), 或经 OpenAI 兼容接口按需切换 DeepSeek 等云端强模型, 避免被单一高价 API 锁定。
- **创新驱动与决策支持**: 趋势预测与热点识别为研发立项、技术路线选择、专利布局提供数据支撑, 降低试错成本。
- **合作拓展**: 作者合作网络辅助识别潜在合作者与团队, 促进产学研对接与资源整合。
- **扩展低成本**: 新增能力靠**插入 MCP 服务**或派生专员子智能体获得, 而非重新开发; 能力边界增量扩展, 边际开发成本低。

5.2.1 经济效益量化 (情景测算)

为便于评委直观判读, 下面给出**情景测算** (基于公开订阅定价与典型科研流程工时假设), 用于说明本地化方案的成本结构差异。

方案	年度可变成本 (以 100 名研究员估)	数据与自主可控
商用文献 AI 订阅	按 \$15/月/人估, 约 12–18 万元/年 , 随人数线性增长	查询与文献记录依赖第三方平台, 数据主权受平台条款约束
通用大模型 API 问答	按重度文献问答用量估, 数万至十余万元/年 , 随调用量增长	查询内容需发送至外部生成服务
SciScope 本地部署	建库与索引为 一次性可复现投入 , 边际推理成本 近 0 (单卡本地)	数据、索引、模型 全本地 , 自主可控

科研环节	传统人工	SciScope 辅助 (情景估计)
立项查新 / 综述前期调研	单次约 40-80 工时 (逐篇检索、去重、筛选)	语义问答 + 证据直达, 估压缩 30%–50% 前期工时
热点 / 趋势研判	数天人工巡检多个数据库	趋势模型一键产出可解释榜单, 分钟级
相似论文 / 合作者发现	人工滚雪球式查找	推荐与图谱即时给出候选 + 可解释因子

单次问答成本 (基于 token 遥测的核算口径): 本系统在每轮智能体回答的 meta 中返回估算 token 用量 (tokens_in/out) 与终止原因 (stop_reason); 该数值来自运行时对消息内容的确定性估算, 用于**逐次记录、复盘和成本核算**, 而不是本报告中虚构一组固定成本。若接入云端 DeepSeek 等 OpenAI 兼容模型, 组织可把 tokens_in/out 乘以当期公开 API 单价进行**情景估算**; 若使用本地 7B 推理, 则主要成本转为本机算力、电力和运维投入。本项目已经具备成本可观测接口, 但尚未开展正式用户规模化成本实验。

投入产出 / 回本口径: 上述数值按公开订阅区间与典型流程假设做情景估算, 用于说明成本结构变化方向, 不代表实测收益。更稳妥的结论是: 在有持续更新需求的组织中, 本地化流程可将检索、初筛和证据整理从重复劳动转为标准化输入, 提高决策准备效率并降低外部工具依赖风险。

测算边界 (据实声明): 以上为**情景测算**, 依据公开订阅定价区间与典型科研流程工时假设推得, 用于说明成本结构与效率方向; **具体金额、工时与百分比须结合目标机构的真实业务计时或用户实验核对**, 本报告不声称已实测, 亦不夸大未验证的经济数字。

5.3 推广前景

- **高校/科研院所:** 学科情报中心、研究生文献调研、综述与查新服务。
- **企业研发:** 技术情报监测、竞品与专利分析、研发选题。
- **科研管理:** 基金评审辅助、领域态势研判、合作网络分析。
- **可扩展性:** 架构与领域无关, 更换语料即可迁移到任意学科或企业内部文档库; 模型可替换、流水线可复现, 便于产品化与私有化部署。

差异化价值小结

相比”直接问通用大模型”,SciScope 的不可替代之处在于: **基于真实语料、有出处可追溯、本地可复现、领域可迁移、大模型可替换**。它不是又一个聊天机器人, 而是一套把机构自有文献资产转化为可信科研生产力的智能体系统。

6 系统运行与复现说明

6.1 运行环境

- Python 3.11(conda 环境),Go 1.26(终端客户端);PostgreSQL 15 + pgvector 扩展。
- 关键依赖:fastapi、psycopg、pgvector、sentence-transformers、scikit-learn、networkx、pandas。
- 本地大模型 (可选):vLLM-Metal / LM Studio 等 OpenAI 兼容服务; 无则自动用 mock, 检索证据仍真实。

6.2 一键安装

```
make install
```

安装后端 Python 依赖

6.3 构建服务层与模型文件

```
# 1. 服务层（建库 + 装载语料/片段）
createdb sciscope
make postgres-schema POSTGRES_DSN=postgresql://USER@localhost:5432/sciscope
psql sciscope -f infra/postgres/pgvector.sql
make postgres-load POSTGRES_DSN=...

# 2. 数据治理：去重（先 dry-run 再 APPLY）
make dedupe-db # 干跑统计
make dedupe-db APPLY=1 # 实际去重

# 3. 模型层：嵌入 + 推荐 + 趋势 + 图谱
SCISCOPE_EMBEDDER_PATH=models/embedder_local/multilingual-e5-base make embeddings
make recommend-model trend-model graph-export
# 或一键:make agent-build
```

6.4 启动与体验

```
# 带数据库 + 本地嵌入启动后端
SCISCOPE_DB_DSN=postgresql://USER@localhost:5432/sciscope \
SCISCOPE_EMBEDDER_PATH=models/embedder_local/multilingual-e5-base make dev

# 终端科研智能体（Go 客户端，需后端:8000 与本地大模型:8001）
make backend & make llm & make tui

# 接本地大模型生成（需:8001 上的 OpenAI 兼容服务）
make vllm-serve # 启动本地模型
... make dev # 配 LOCAL_LLM_* 指向该模型
```

使用 `make tui` 进入终端科研智能体；后端接口文档见 <http://127.0.0.1:8000/docs>。

6.5 质量与效果验证

```
make test # 后端自动化测试（以当前环境输出为准）
make agent-smoke # live agent 黑盒验收：库表规模、skills、工具预算
make eval-retrieval # 自检索评估:recall@k / MRR / 延迟
```

6.6 全量重建（数据更新后）

持续爬取积累新数据后，一次性重建并自动并入去重与全部模型：

```
make data-layer-refresh && make rag-chunks && make postgres-refresh && make agent-build
```

6.7 交付物清单

- **代码**:src/(采集/治理/分析/模型)、backend/(API + 智能体编排)、tui/(Go 终端客户端)、infra/(schema)、Makefile(流水线)。
- **模型文件**:pgvector 向量索引、models/(嵌入器/趋势/推荐)、output/graphs/(图谱 JSON)、RAG 片段语料；均可由 `make agent-build` 复现。
- **报告**: 本《项目报告书》与同级《数据分析报告》(output/pdf/sciscope_data_report)。
- **演示样例**:docs/examples/golden_verify_claim_session.md 给出一轮跨语言论断核查黄金会话，评委即使不启动环境也可查看 workflow 阶段、证据时间线与最终结论格式。
- **黑盒验收**:make agent-smoke 调用 `live /api/agent`，检查数据库级语料规模、能力边界、论断核查、趋势分析与

论文推荐工具链路。

- **基础大模型:** 声明为可替换依赖 (任意 OpenAI 兼容端点), 不绑定特定模型。

SciScope · 面向科技文献智能分析的科研智能体 · 大模型可换, 证据可溯, 流水线可复现

I 7 数据来源与参考文献

本系统所用数据均来自**公开学术数据源**, 算法与模型均为公开方法或开源权重, 知识产权清晰、可追溯、可复现。

7.1 数据来源

- D1. OpenAlex —— 开放学术知识图谱与元数据 API。 <https://openalex.org>
- D2. PubMed / PubMed Central (PMC) —— 美国国立医学图书馆生物医学文献库。 <https://pubmed.ncbi.nlm.nih.gov>
- D3. Crossref —— DOI 注册与文献元数据。 <https://www.crossref.org>
- D4. DOAJ —— 开放获取期刊目录。 <https://doaj.org>
- D5. arXiv —— 计算机/物理/数学等领域预印本库 (含全文 PDF)。 <https://arxiv.org>

7.2 方法与模型来源

- R1. Mann, H. B. (1945). Nonparametric tests against trend. *Econometrica*, 13(3), 245–259.
- R2. Sen, P. K. (1968). Estimates of the regression coefficient based on Kendall's tau. *JASA*, 63(324), 1379–1389.
- R3. Blondel, V. D., et al. (2008). Fast unfolding of communities in large networks (Louvain). *J. Stat. Mech.*
- R4. Page, L., Brin, S., et al. (1999). The PageRank citation ranking: Bringing order to the web.
- R5. Blei, D., Ng, A., Jordan, M. (2003). Latent Dirichlet Allocation (LDA). *JMLR*, 3, 993–1022.
- R6. Lee, D. D., Seung, H. S. (1999). Learning the parts of objects by non-negative matrix factorization (NMF). *Nature*, 401, 788–791.
- R7. Cormack, G. V., Clarke, C. L. A., Büttcher, S. (2009). Reciprocal rank fusion (RRF). *SIGIR*.
- R8. Robertson, S., Zaragoza, H. (2009). The probabilistic relevance framework: BM25 and beyond.
- R9. Wang, L., et al. (2024). Multilingual E5 text embeddings(multilingual-e5-base, 检索与跨语言嵌入)。
- R10. Chen, J., et al. (2024). BGE M3-Embedding / bge-reranker-v2-m3(跨语言重排)。
- R11. Qwen Team (2024). Qwen2.5 Technical Report(本地生成层 Qwen2.5-7B-Instruct)。
- R12. Model Context Protocol documentation. Open-source standard for connecting AI applications to external systems, tools and workflows. <https://modelcontextprotocol.io/docs/getting-started/intro>

合规声明: 数据用于科研分析与方法验证, 遵循各数据源的开放获取与使用条款; 系统不存储或再分发受版权保护的论文全文, 仅保留用于检索的元数据、摘要与开放获取正文片段。