

SciScope 项目报告书

面向科技文献智能分析的科研智能体构建

赛道 智能体开发

成果类型 数据分析报告 + 科研智能体模型 (代码 + 模型文件)

核心能力 文献问答 · 趋势预测 · 论文推荐 · 知识图谱

数据规模 6 个公开来源 · 159,190 篇 (去重后) · 主窗口 2022-2026

模型资产 226,434 条片段向量 · 159,190 篇论文级向量

一句话定位

SciScope 把约 16 万篇公开科技文献炼成一个**可检索、可问答、可预测趋势、可推荐、可看图谱**的科研智能体。大语言模型仅作生成层、可任意替换; 领域智能沉淀在**本地可复现的索引与模型文件**中, 且每个回答都附**可追溯证据** (evidence-grounded)。这正是”科研智能体”区别于”直接问通用大模型”的核心价值。

目录

1	项目概述	3
1.1	项目背景	3
1.2	应用行业	3
1.3	主要工作	3
1.4	创新点	3
2	解决方案	3
2.1	总体架构设计	3
2.2	核心链路: 证据接地的检索增强问答	4
2.3	方案功能	4
2.4	关键技术	4
2.5	实现过程	5
3	结果分析 (系统效果与效率)	5
3.1	检索质量与效率 (核心测试)	5
3.2	跨语言检索相关性优化 (技术创新)	5
3.3	语义覆盖修复 (消融对比)	5
3.4	趋势预测回测与推荐评估 (评测证据包)	6
3.5	数据治理成效	6
3.6	模型资产与工程质量	6
4	示例问答与测试用例	7
4.1	用例一: 英文混合检索 (双臂命中)	7
4.2	用例二: 中文跨语言检索 (命中英文文献)	7
4.3	用例三: 可解释论文推荐	7
4.4	用例四: 趋势热点 (模型输出)	7
4.5	用例五: 证据接地问答	7
5	应用价值	8
5.1	社会效益	8
5.2	经济效益	8
5.2.1	经济效益量化 (情景测算)	8
5.3	推广前景	9
6	系统运行与复现说明	9
6.1	运行环境	9
6.2	一键安装	9
6.3	构建服务层与模型文件	9
6.4	启动与体验	9

6.5	质量与效果验证	10
6.6	全量重建 (数据更新后)	10
6.7	交付物清单	10
7	数据来源与参考文献	10
7.1	数据来源	10
7.2	方法与模型来源	10

1 项目概述

1.1 项目背景

科研文献数量爆炸式增长, 科研人员在文献调研、知识提取、研究趋势分析等环节面临巨大挑战。传统关键词检索是字面匹配, 难以满足细粒度、多维度、个性化、跨语言的知识需求; 而直接使用通用大模型问答又存在**幻觉**、**无出处**、**不可复现**等问题, 无法支撑严肃的科研决策。本项目构建 **SciScope 科研智能体**, 自动解析文献、提取关键信息、构建知识图谱, 并支持自然语言问答与研究方向推荐, 在**每个结论都附可追溯证据**的前提下提升科研效率与知识管理水平。

1.2 应用行业

高校与科研院所、企业研发部门、科技情报与图书馆机构、科研管理与基金评审部门。典型场景: 研究热点定位、领域脉络梳理、潜在合作者识别、文献调研提速、立项查新与综述辅助。

1.3 主要工作

- **数据底座**: 从 arXiv、PubMed、PMC、OpenAlex、Crossref、DOAJ 6 个公开来源采集、清洗、规范化、去重, 形成 159,190 篇、跨计算机/生物医学/材料等多领域、主窗口 2022–2026 的可复现语料。
- **数据分析报告** (交付物): 文献分布、关键词演化、作者合作网络、主题模型、趋势统计 (见同级交付物 `sciscope_data_report`)
- **科研智能体模型** (交付物): 本地嵌入索引、混合检索、趋势预测、论文推荐、知识图谱五大模型, 配套 FastAPI 服务与 Next.js 工作台。
- **系统工程**: PostgreSQL + pgvector 服务层、本地大模型 (vLLM/MLX) 生成层、一键复现的 Makefile 流水线与自动化测试。

1.4 创新点

四个核心创新

1. **大模型无关的证据接地架构 (LLM-agnostic, evidence-grounded)**: 大模型只负责“用人话写答案”, 领域智能沉淀在本地可复现的索引/模型文件中; 换任意大模型系统照常工作, 每条回答均附引用论文, 杜绝幻觉、可审计。
2. **字面 + 语义混合检索 (Hybrid Retrieval)**: PostgreSQL 全文检索 (FTS) 与 pgvector 向量检索双路并行, 用 RRF(倒数排名融合) 合并, 兼顾精确匹配与语义/跨语言理解 (中文问句可命中英文文献)。
3. **”模型文件”即可复现资产**: 不依赖黑盒训练权重, 而是用本项目代码从本项目语料**计算/拟合**出的嵌入索引、趋势模型、推荐向量、知识图谱;`make agent-build` 可一键重建, 知识产权清晰、评委可复现。
4. **数据质量工程**: 标题优先去重 + 期刊 front-matter 剔除 + PDF 垃圾过滤 + 关键词噪声过滤 (剔除 arXiv 分类码与超泛学科标签), 显著提升检索、趋势与图谱的信噪比。

2 解决方案

2.1 总体架构设计

系统采用**可复现流水线 + PostgreSQL 服务层 + 可替换大模型**的分层架构。数据自底向上逐层加工为”可问答系统”; 其中**分析层**产出《数据分析报告》, **模型层**产出科研智能体的”模型文件”, 两者共享同一数据底座。




图 1 SciScope 总体架构：采集 → 治理 → 分析/模型 → 服务 → 接口 → 交互；大模型仅作可替换的生成层

设计原则：离线可复现 (每层产物由 `make` 目标生成)；大模型可替换 (生成层走 OpenAI 兼容接口)；证据可追溯 (回答必带引用)；本地优先 (数据与索引均在本地，支持涉密场景)。

2.2 核心链路：证据接地的检索增强问答

问答不直接交给大模型臆测，而是**先检索证据、再据证生成**，每条回答都可追溯到具体论文：




图 2 混合检索 + 证据接地生成链路 (中文问句可跨语言命中英文文献)

2.3 方案功能

- 文献问答** /api/chat:GraphRAG(查询抽取关键词实体 → 沿共现图扩展邻居 → query expansion)+ 混合检索证据 → 本地大模型据证生成带引用回答 → **答案可被证据支撑性校验** (低置信明确提示)。
- 混合检索** /api/search:FTS + 向量 + RRF 融合, 去重到论文级, 返回命中片段。
- 趋势预测** /api/trends: 关键词/主题的增长率、burst、生命周期与下一年线性外推 (含不确定区间)。
- 论文推荐** /api/recommend: 语义相似 + 关键词重叠 + 作者关系 + 时近性融合, 输出**可解释因子**。
- 知识图谱** /api/graph: 作者合作图、关键词共现图、论文-主题图; 作者支持实时 ego 子图。

2.4 关键技术

- 向量化**: 本地 multilingual-e5-base(768 维, 中英跨语言),fp16 加速、断点续传; 向量入 pgvector。
- 混合检索与 RRF**:tsvector 全文索引 + ivfflat 余弦向量索引, 两路按 $1/(k + \text{rank})$ 融合 ($k=60$)。
- 趋势模型**: 逐年归一化词频上最小二乘外推 + 残差不确定带; 主题模型 LDA/NMF 各 40 主题。
- 推荐模型**: 论文级平均向量 (pgvector avg)+ 多信号加权, 逐条给出可解释因子。

- **知识图谱**:NetworkX 中心度/社区, 百万级边按中心度剪枝导出 JSON, 作者 ego 图走 SQL 实时查询。
- **生成层**:OpenAI 兼容本地服务, 输出限长防失控, 可平滑切换更大/远程模型。

2.5 实现过程

数据生成与采集 → 6 源按领域/年份抓取, 落 data/raw_canonical 分区 JSONL。

数据组织与治理 → 规范化字段; 标题优先去重 (合并跨源/预印本同篇, 留最全一条)+ front-matter 剔除 + PDF 垃圾/ NUL 清洗;160,488 → 159,190 篇。

信息汲取与建模 → 切片入库, 计算片段/论文向量, 拟合趋势/推荐/图谱/主题; 关键词统一过滤 arXiv 码与超泛标签。make agent-build 一键重建。

服务与交互 → FastAPI 暴露五接口, 前端可视化; 数据库不可用时自动回退内存检索, 保证演示鲁棒。

3 结果分析 (系统效果与效率)

说明: 本章聚焦**系统/算法的效果与效率测试**。关于语料本身的分布、关键词演化、作者网络与主题分析, 详见同级交付物《SciScope 数据分析报告》, 此处不重复。

3.1 检索质量与效率 (核心测试)

采用**自检索协议** (以论文自身标题/关键词为查询, 检验能否检回该文) 评测混合检索, **全部 16 万篇均已入向量库**:

查询方式	recall@1	recall@10	MRR@10	平均延迟
按标题 (字面 + 语义臂)	0.62	0.97	0.75	~250 ms
按关键词	0.43	0.70	0.53	~100 ms

标题查询 recall@10 达 **0.97**(目标论文几乎总在前 10)、延迟亚秒级, 体现混合检索**效果与效率**”兼顾。说明: 相比初版仅 1.7 万篇入库时的 recall@1≈0.94, **全量 16 万篇入库后单篇精确命中的竞争候选激增**,recall@1 回落属真实现象; 但”前 10 命中”与下文的**主题相关性**在优化后均达到很高水平。数据真实不回避。

3.2 跨语言检索相关性优化 (技术创新)

针对真实用户的**中文短查询**, 初版多语言嵌入存在”按语言而非主题召回”的偏差 (如查”扩散模型”却召回到无关的中文医学论文)。我们用 15 个主题查询构建 **relevance@5** 指标 (top-5 是否含主题相关论文,make 可复现), 针对性实施了一组优化:

优化	作用
中英术语映射	中文查询自动替换/补充英文等价词, 把召回锚定到 (以英文为主的) 语料主题
混合字面臂	websearch 精确短语优先 + OR 兜底, 兼顾精确命中与多词召回
语义跨语言答案校验	用 e5 余弦度量”答案 ↔ 证据”接地度, 中文答案据英文文献不再被误判低置信
”最新”意图识别	识别”最新/近期”等意图, 在相关结果中优先近年论文
多轮对话记忆	指代型追问 (”它的局限呢”) 自动承接上文主题再检索

效果:relevance@5 从 **0.667 提升至 1.0**(15/15 全部命中主题), ”扩散模型””强化学习””量子计算””推荐系统”等此前跑偏的中文查询**全部修复**。

3.3 语义覆盖修复 (消融对比)

初版仅对”有全文”论文嵌入, 导致语义检索严重偏向生物医学、对最大领域**计算机科学近乎失明** (论文级向量仅 87 篇); 经**全量标题摘要嵌入**修复后, 论文级向量 17,913 → 159,164, 各领域覆盖如下 (消融前后对比):




图 3 语义检索领域覆盖: 修复前 (空心)vs 修复后 (实心)。计算机科学从 87 跃升至 58,038, 偏科消除

修复后语义检索与推荐覆盖全部 16 万篇全领域, 中文问句可跨语言命中英文文献。

3.4 趋势预测回测与推荐评估 (评测证据包)

完整评测可由 `make eval-all` 复现, 结果固化于 `output/eval/eval_report.{json,md}`。

趋势预测回测 (拟合 2022-2024 → 预测 2025, 1,998 个关键词): 预测与真实的 Pearson 相关 **0.976** (能准确排序哪些关键词更活跃); 点预测 MAE 与 naive 持平基线相当 (归一化词频年际噪声大、近均值回归), 故采用阻尼外推并附不确定带, 谨慎解读。模型价值在排序与多年动量/burst。

推荐离线评估 (150 篇种子, top-5): 同领域率 **0.67**、共享关键词率 **0.60**、平均语义相似 **0.89**——远高于随机基线, 且每条附可解释因子。

3.5 数据治理成效

治理项	处理	效果
标题优先去重 + front-matter 剔除	删 1,298 篇	残留长标题重复组归零
PDF 垃圾正文过滤	清 83 篇 / 46 片段	杜绝回答吐 PDF 乱码
关键词噪声过滤	arXiv 码/泛标签/期刊名	趋势 top 回归真实主题
摘要回填 (OpenAlex DOI)	补 +9,170 篇	有摘要覆盖升至 86.4%, 上万”隐形”论文进入检索
arXiv 全文补抓 (PDF)	补全文至 13,611 篇	有正文升至 8.6%, 支撑深度问答

关键词清洗后, 趋势热点回归真实研究主题: **retrieval augmented generation**、**large language model** 位居新兴前列; 主题模型 (40 主题) 清晰区分 LLM、RAG、图神经网络、锂电池、蛋白结构、催化等方向。

3.6 模型资产与工程质量

模型文件 / 索引 / 质量项	规模
片段向量 <code>chunk_embeddings</code> (pgvector)	367,773
论文级向量 <code>paper_embeddings</code>	159,164
主题模型 (LDA + NMF)	40 主题 / 模型
知识图谱 (作者/关键词/主题)	前端友好 JSON
后端自动化测试	92 项全部通过

全部模型文件可由 `make agent-build` 一键重建, 知识产权清晰、评委可复现。

4 示例问答与测试用例

下列为系统在真实 16 万篇语料上的**实际输出** (非示意), 用于直观展示检索、跨语言、推荐与证据接地能力。

4.1 用例一: 英文混合检索 (双臂命中)

查询:graph neural network materials discovery

返回 (lexical)+(semantic) 双臂命中):

- Accelerated Discovery of Energy Materials via Graph Neural Networks (2025)
- CTGNN: Crystal Transformer Graph Neural Network for Crystal Materials (2024)
- DeepCrysTet: A Deep Learning Approach Using Tetrahedral Mesh (2023)

4.2 用例二: 中文跨语言检索 (命中英文文献)

查询: 大语言模型的检索增强生成 (中文)

返回 (semantic) 语义臂, 跨语言命中英文论文):

- Retrieval-Augmented Retrieval: Large Language Models are Strong Zero-Shot Retrievers (2024)
- LEXT: Towards Evaluating Trustworthiness of Natural Language Explanations (2025)
- A Comprehensive Study of Jailbreak Attack versus Defense for LLMs (2024)

4.3 用例三: 可解释论文推荐

种子论文:PMC13273979(AI 药物发现方向)

推荐 (每条附可解释因子 semantic / keyword / author / recency):

推荐论文	年份	语义相似	融合因子
Generative AI in drug discovery and development	2024	0.941	sem .56 / kw .10
Editorial: Advancing drug discovery with AI	2025	0.934	sem .56 / kw .10
Advancing Drug Discovery with AI: Machine and Deep Learning	2026	0.915	sem .55 / kw .10

4.4 用例四: 趋势热点 (模型输出)

/api/trends 新兴热点排行 (关键词清洗后): retrieval augmented generation → large language model → gene delivery → ...

与 2022-2026 年科研态势吻合,RAG 与大语言模型领跑。

4.5 用例五: 证据接地问答

提问: 图神经网络在材料发现中有哪些应用?

系统流程: 混合检索 → 取 Top 证据 (如 A review on the applications of GNNs in materials science、crystal graph convolutional neural network)→ 本地大模型**仅基于证据**生成回答, 并标注引用 [n]。

关键特性: 回答可追溯到具体论文; 证据不足时如实说明, 不臆造。

5 应用价值

5.1 社会效益

- **科研提效与公平**: 把分散在多源、多语言的文献统一为可问答知识底座, 让中小机构、欠发达地区科研人员以更低门槛获得高质量文献调研能力, 缩小科研信息鸿沟。
- **可信与可审计**: 每条回答均附引用论文 (evidence-grounded), 从源头抑制大模型幻觉, 支撑**科学决策**与严肃的立项查新、综述撰写, 减少误导性结论传播。
- **知识传承与脉络梳理**: 主题演化、关键词趋势与合作网络帮助新人快速理解领域发展脉络, 促进知识传承。
- **数据安全友好**: 本地优先架构 (数据、索引、可选本地大模型均在本地), 适配涉密/敏感科研场景, 符合数据安全与自主可控要求。

5.2 经济效益

- **效率提升**: 文献调研、热点定位、综述梳理等高耗时环节由”人工逐篇”转为”语义问答 + 证据直达”, 显著压缩科研前期投入工时。
- **成本优化**: 核心智能沉淀在**本地可复现的索引与模型文件**, 大模型仅作可替换的生成层——可用小模型本地推理、按需切换更强模型, 避免高昂的纯大模型 API 调用成本。
- **创新驱动与决策支持**: 趋势预测与热点识别为研发立项、技术路线选择、专利布局提供数据支撑, 降低试错成本。
- **合作拓展**: 作者合作网络辅助识别潜在合作者与团队, 促进产学研对接与资源整合。

5.2.1 经济效益量化 (情景测算)

为便于评委直观判读, 下面给出**情景测算** (基于公开订阅定价与典型科研流程工时假设), 用于说明本地化方案的成本结构差异。

方案	年度可变成本 (以 100 名研究员估)	数据与自主可控
商用文献 AI 订阅	按 \$15/月/人估, 约 12–18 万元/年 , 随人数线性增长	查询与文献记录上传第三方, 数据出境
通用大模型 API 问答	按重度文献问答用量估, 数万至十余万元/年 , 随调用量增长	查询内容上传第三方
SciScope 本地部署	建库与索引为 一次性可复现投入 , 边际推理成本 近 0 (单卡本地)	数据、索引、模型 全本地 , 自主可控

科研环节	传统人工	SciScope 辅助 (情景估计)
立项查新 / 综述前期调研	单次约 40–80 工时 (逐篇检索、去重、筛选)	语义问答 + 证据直达, 估 压缩 30%–50% 前期工时
热点 / 趋势研判	数天人工巡检多个数据库	趋势模型一键产出可解释榜单, 分钟级
相似论文 / 合作者发现	人工滚雪球式查找	推荐与图谱即时给出候选 + 可解释因子

测算边界 (据实声明): 以上为**情景测算**, 依据公开订阅定价区间与典型科研流程工时假设推得, 用于说明成本结构与效率方向; **具体金额、工时与百分比须结合目标机构的真实业务计时或用户实验核对**, 本报告不声称已实测, 亦不夸大未验证的经济数字。

5.3 推广前景

- **高校/科研院所:** 学科情报中心、研究生文献调研、综述与查新服务。
- **企业研发:** 技术情报监测、竞品与专利分析、研发选题。
- **科研管理:** 基金评审辅助、领域态势研判、合作网络分析。
- **可扩展性:** 架构与领域无关, 更换语料即可迁移到任意学科或企业内部文档库; 模型可替换、流水线可复现, 便于产品化与私有化部署。

差异化价值小结

相比”直接问通用大模型”,SciScope 的不可替代之处在于: **基于真实语料、有出处可追溯、本地可复现、领域可迁移、大模型可替换**。它不是又一个聊天机器人, 而是一套把机构自有文献资产转化为可信科研生产力的智能体系统。

6 系统运行与复现说明

6.1 运行环境

- Python 3.11(conda 环境),Node.js(前端);PostgreSQL 15 + pgvector 扩展。
- 关键依赖:fastapi、psycopg、pgvector、sentence-transformers、scikit-learn、networkx、pandas。
- 本地大模型 (可选):vLLM-Metal / LM Studio 等 OpenAI 兼容服务; 无则自动用 mock, 检索证据仍真实。

6.2 一键安装

```
make install
```

```
# 安装后端 Python 依赖与前端 npm 依赖
```

6.3 构建服务层与模型文件

```
# 1. 服务层 (建库 + 装载语料/片段)
createdb sciscope
make postgres-schema POSTGRES_DSN=postgresql://USER@localhost:5432/sciscope
psql sciscope -f infra/postgres/pgvector.sql
make postgres-load POSTGRES_DSN=...

# 2. 数据治理: 去重 (先 dry-run 再 APPLY)
make dedupe-db # 干跑统计
make dedupe-db APPLY=1 # 实际去重

# 3. 模型层: 嵌入 + 推荐 + 趋势 + 图谱
SCISCOPE_EMBEDDER_PATH=models/embedder_local/multilingual-e5-base make embeddings
make recommend-model trend-model graph-export
# 或一键:make agent-build
```

6.4 启动与体验

```
# 带数据库 + 本地嵌入启动前后端
SCISCOPE_DB_DSN=postgresql://USER@localhost:5432/sciscope \
SCISCOPE_EMBEDDER_PATH=models/embedder_local/multilingual-e5-base make dev

# 终端直接问答 (自动探测本地大模型)
make chat
```

```
# 接本地大模型生成（需:8001 上的 OpenAI 兼容服务）
make vllm-serve                                     # 启动本地模型
... make dev                                         # 配 LOCAL_LLM_* 指向该模型
```

打开 <http://localhost:3000> 使用工作台; 后端接口文档见 <http://127.0.0.1:8000/docs>。

6.5 质量与效果验证

```
make test                                           # 92 项后端测试 + 前端类型检查 + 构建
make eval-retrieval                                # 自检索评估:recall@k / MRR / 延迟
```

6.6 全量重建 (数据更新后)

持续爬取积累新数据后, 一次性重建并自动并入去重与全部模型:

```
make data-layer-refresh && make rag-chunks && make postgres-refresh && make agent-build
```

6.7 交付物清单

- **代码:**src/(采集/治理/分析/模型)、backend/(API)、frontend/(工作台)、infra/(schema)、Makefile(流水线)。
- **模型文件:**pgvector 向量索引、models/(嵌入器/趋势/推荐)、graphs/(图谱 JSON)、RAG 片段语料; 均可由 `make agent-build` 复现。
- **报告:** 本《项目报告书》与同级《数据分析报告》(output/pdf/sciscope_data_report)。
- **基础大模型:** 声明为可替换依赖 (任意 OpenAI 兼容端点), 不绑定特定模型。

SciScope · 面向科技文献智能分析的科研智能体 · 大模型可换, 证据可溯, 流水线可复现

7 数据来源与参考文献

本系统所用数据均来自公开学术数据源, 算法与模型均为公开方法或开源权重, 知识产权清晰、可追溯、可复现。

7.1 数据来源

- D1. OpenAlex —— 开放学术知识图谱与元数据 API。 <https://openalex.org>
- D2. PubMed / PubMed Central (PMC) —— 美国国立医学图书馆生物医学文献库。 <https://pubmed.ncbi.nlm.nih.gov>
- D3. Crossref —— DOI 注册与文献元数据。 <https://www.crossref.org>
- D4. DOAJ —— 开放获取期刊目录。 <https://doaj.org>
- D5. arXiv —— 计算机/物理/数学等领域预印本库 (含全文 PDF)。 <https://arxiv.org>

7.2 方法与模型来源

- R1. Mann, H. B. (1945). Nonparametric tests against trend. *Econometrica*, 13(3), 245–259.
- R2. Sen, P. K. (1968). Estimates of the regression coefficient based on Kendall's tau. *JASA*, 63(324), 1379–1389.
- R3. Blondel, V. D., et al. (2008). Fast unfolding of communities in large networks (Louvain). *J. Stat. Mech.*

- R4. Page, L., Brin, S., et al. (1999). The PageRank citation ranking: Bringing order to the web.
- R5. Blei, D., Ng, A., Jordan, M. (2003). Latent Dirichlet Allocation (LDA). *JMLR*, 3, 993–1022.
- R6. Lee, D. D., Seung, H. S. (1999). Learning the parts of objects by non-negative matrix factorization (NMF). *Nature*, 401, 788–791.
- R7. Cormack, G. V., Clarke, C. L. A., Büttcher, S. (2009). Reciprocal rank fusion (RRF). *SIGIR*.
- R8. Robertson, S., Zaragoza, H. (2009). The probabilistic relevance framework: BM25 and beyond.
- R9. Wang, L., et al. (2024). Multilingual E5 text embeddings(`multilingual-e5-base`, 检索与跨语言嵌入)。
- R10. Chen, J., et al. (2024). BGE M3-Embedding / `bge-reranker-v2-m3`(跨语言重排)。
- R11. Qwen Team (2024). Qwen2.5 Technical Report(本地生成层 `Qwen2.5-7B-Instruct`)。

合规声明: 数据用于科研分析与方法验证, 遵循各数据源的开放获取与使用条款; 系统不存储或再分发受版权保护的论文全文, 仅保留用于检索的元数据、摘要与开放获取正文片段。