

项目报告书

可复现文献资产驱动的
证据接地科研智能体



SciScope 终端智能体客户端 (Go TUI): 输入研究问题 / 待核查论断 → 实时渲染规划、工具调用、证据与回答。

FIVE CAPABILITIES

文献问答 · 趋势描述 · 论文推荐 · 知识图谱 · 论断核查

目录

1	项目概述	3
1.1	项目背景	3
1.2	应用行业	3
1.3	主要工作	3
1.4	创新点	3
2	解决方案	4
2.1	总体架构设计	4
2.2	终端产品形态	4
2.3	核心链路: 证据接地的检索增强问答	4
2.4	智能体编排层: 从”固定管线”到”自主 agent”	6
2.5	开放与可扩展:MCP 双向互通 + 专员子智能体	8
2.6	方案功能	8
2.7	关键技术	9
2.8	实现过程	9
2.9	交付结构与复现索引	9
3	结果分析 (系统效果与效率)	10
3.1	检索质量与效率 (核心测试)	10
3.2	跨语言检索相关性优化 (历史定向样例)	12
3.3	全量向量运行态	12
3.4	差异化能力对比	12
3.5	趋势回测与推荐评估 (评测证据包)	13
3.6	数据治理成效	13
3.7	模型资产与工程质量	14
3.8	开源治理、分发与托管体验	14
4	应用价值	14
4.1	社会效益	14
4.2	经济效益	15
4.2.1	经济效益量化 (情景测算)	15
4.3	推广前景	16
5	系统运行与复现说明	16
5.1	运行环境	17
5.2	一键安装	17
5.3	构建服务层与模型文件	17
5.4	启动与体验	17

5.5	预编译客户端安装	17
5.6	质量与效果验证	18
5.7	全量重建 (数据更新后)	18
5.8	交付物清单	18
6	示例问答与测试用例	18
6.1	用例一: 英文混合检索 (双臂命中)	19
6.2	用例二: 中文跨语言检索 (命中英文文献)	19
6.3	用例三: 可解释论文推荐	19
6.4	用例四: 趋势热点 (描述性输出)	19
6.5	用例五: 证据接地问答	19
6.6	用例六: 科研智能体自主多步编排 (真实轨迹)	19
6.7	用例七: 论断核查与跨语言接地	20
6.8	用例八:TUI 产品化工作流与黄金会话导出	20
7	数据来源与参考文献	21
7.1	数据来源	21
7.2	方法与模型来源	21

1 项目概述

1.1 项目背景

在文献更新加速与科研决策压力增大的场景下，核心问题不只是“能不能回答”，而是**可追溯性、可复核性与决策可用性**是否同时成立。传统关键词检索主要依赖字面匹配，难以覆盖跨语言、跨术语和多步骤研究问题；直接使用通用大模型问答又存在**幻觉、无出处、不可复现**等风险。SciScope 的定位不是更强的问答模型，而是将文献资产、检索证据、趋势解释与工具编排形成一条可复用、可验证的科研智能链路，在**每个结论都附可追溯证据**的前提下支撑文献调研、情报监测与科研治理。

1.2 应用行业

高校与科研院所、企业研发部门、科技情报与图书馆机构、科研管理与基金评审部门。典型场景：研究热点定位、领域脉络梳理、潜在合作者识别、文献调研提速、立项查新与综述辅助。

1.3 主要工作

- **数据底座**：从 arXiv、PubMed、PMC、OpenAlex、Crossref、DOAJ 6 个公开来源采集、清洗、规范化、去重，形成 168,447 条分析语料、159,164 篇处理后语料文件；
2026-08-14 讯飞交付包 5,566 篇预印本 PDF(bioRxiv/medRxiv/arXiv,source=iflytek) 已全链路入库，运行时 PostgreSQL 装载 164,730 篇论文、413,971 个检索片段，覆盖计算机/生物医学/材料等领域，主窗口 2022–2026。
- **数据分析报告** (交付物 1)：文献分布、关键词演化、作者合作网络、主题模型、趋势统计 (见同级交付物 `sciscope_data_report`)。
- **科研智能体模型** (交付物 2)：本地嵌入索引、混合检索、趋势描述/方向辅助、论文推荐、知识图谱与论断核查能力，配套 FastAPI 服务、MCP 出口和终端智能体客户端。
- **系统工程**：PostgreSQL + pgvector 服务层、本地大模型 (vLLM/MLX) 生成层、一键复现的 Makefile 流水线与自动化测试。

赛题要求对齐

赛题要求提交**数据分析报告**和**科研智能体模型 (Python 代码 + 模型文件)**，并明确支持文献问答、趋势预测、论文推荐等功能；评分关注社会效益 (20 分)、经济效益 (20 分)、技术创新 (30 分) 和格式规范 (30 分)。本项目对应关系如下：第一份报告回答“数据从何而来、质量如何、趋势与图谱发现是什么”；本项目报告回答“系统如何工作、创新在哪里、效果如何、如何复现”；模型资产包含片段/论文向量、趋势模型、推荐模型与知识图谱，并通过终端智能体给出可演示的问答、核查、推荐和趋势分析 workflow。

1.4 创新点

五个核心创新

1. **大模型无关的证据接地架构 (LLM-agnostic, evidence-grounded)**：大语言模型 (LLM) 只负责“用人话写答案”，领域智能沉淀在本地可复现的索引/模型文件中；生成层经 OpenAI 兼容接口**可插拔** (本地 7B 与 DeepSeek 云端一处配置切换)，换任意大模型系统照常工作。
2. **可信工具契约与确定性校验门**：智能体具备 12 类运行时能力 (与代码注册表一致)，覆盖检索、趋势、推荐、图谱、引用导出、论断核查与专员委派。每类能力声明只读边界、参数校验和结果上限；调用前可拦截模型编造的论文主键，显式科研技能还设置首工具强制调用与工具预算，从架构上降低幻觉、空跑和捏造风险，便于审计。
3. **字面 + 语义混合检索 (Hybrid Retrieval)**：PostgreSQL 全文检索 (FTS) 与 pgvector 向量检索双路并行，

用倒数排名融合 (Reciprocal Rank Fusion, RRF) 合并, 兼顾精确匹配与语义/跨语言理解 (中文问句可命中英文文献)。

4. ”模型文件”即可复现资产: 不依赖黑盒训练权重, 而是用本项目代码从本项目语料计算/拟合出的嵌入索引、趋势模型、推荐向量、知识图谱; `make agent-build` 可一键重建, 知识产权清晰、评委可复现。
5. 开放互通与专员子智能体: SciScope 可作为模型上下文协议 (Model Context Protocol, MCP) 服务端把科研能力开放给外部客户端, 也可消费外部 MCP 工具; 复杂任务可下派给综述员、趋势分析师、批判核查员三类专员子智能体, 且结构上禁止递归委派。2026-08-10 已验证真实 OpenCode 顺序调用”先核查 tool, 再读取 disputes resource”的协议闭环, 但这证明的是接口可调用, 不是自然语料质量证明。
6. 可观测运行与数据质量工程: 智能体事件携带用户可读阶段、耗时、终止原因和估算 token 用量; 黑盒验收持续检查真实库表规模、能力边界、论断核查、趋势分析和论文推荐链路。数据层通过标题优先去重、front-matter 剔除、PDF 垃圾过滤和关键词噪声过滤提升检索、趋势与图谱信噪比。

数字口径说明: 本报告将数据规模与证据分为五层口径: 数据分析报告使用 `data/analysis/summary.json` 的 168,447 条分析语料 (2026-08-10 分析快照, 未含讯飞增量); 处理后语料文件使用 `data/processed/papers_corpus.summary.json` 的 159,164 篇, 另加讯飞交付包 `xunfei_papers.json` 的 5,566 篇; 演示服务器 PostgreSQL 当前库表为 164,730 篇论文与 413,971 个片段 (2026-08-14, 讯飞增量 46,110 块 GPU 向量化后); 2026-08-10 远端 2080 Ti 全量运行态历史口径为 `chunk_embeddings=367,861/367,861` 与 `paper_embeddings=159,164/159,164`。系统效果还需区分历史评测 (如 `output/eval/eval_report.json`)、当前工程回归、以及尚未完成的人工 Gold/真实用户证明。五类口径用途不同, 不混写为同一个总数。

2 解决方案

2.1 总体架构设计

架构以**数据资产可复现、证据可追溯、决策可复核**为主线。系统分为数据治理与分析资产层、模型与索引层、服务与接口层、智能体编排层四类能力; 各层既可独立评估, 也共享同一数据口径, 便于持续更新与复现。图 1 展示底层数据到智能体交互的完整链路, 图 2 则把工程组件收束为评委可快速识别的能力地图。

设计原则:(1) 离线可复现, 每层产物由 `make` 目标生成;(2) 大模型可替换, 生成层走 OpenAI 兼容接口;(3) 关键可验证结论必须带引用或显式降级为证据不足/依赖故障;(4) 本地优先, 数据与索引均在本地, 支持涉密场景。

2.2 终端产品形态

SciScope 不止是代码与模型文件, 而是一个可运行的**终端智能体客户端** (Go TUI): 用户输入研究问题或待核查论断, 客户端消费后端 `/agent/stream` 的 SSE 事件, 实时渲染规划、工具调用、证据与最终回答; 它本身不承载推理与检索决策, 只做协议消费与呈现, 见图 3。客户端采用**沉浸式纯黑画布 + 圆角命令面板**的呈现风格 (2026-08 已重构为 Grok 式沉浸态): 首屏为居中 Welcome(品牌标识 + 最近会话 + 命令入口), 研究计划与自检过程在回答完成后**自动折叠为一行摘要**, 证据卡收敛为可展开层 (`Enter` 展开完整论文列表与接地相似度), 首屏优先呈现结论与证据等级, 过程细节按需展开—— workflow 可见而不喧宾夺主。斜杠命令 (`/verify`、`/trend`、`/review`、`/export`) 经 `/` 呼出 **Command Palette**(常用/会话/证据/系统四分组 + 过滤 + 选中态) 呈现, 回答内容经结构化渲染 (标题、列表、加粗、代码块) 而非裸露 Markdown 语法符号。

2.3 核心链路: 证据接地的检索增强问答

问答不直接交给大模型臆测, 而是**先检索证据、再据证生成**, 每条回答都可追溯到具体论文: 见图 4。

检索融合口径: 字面检索与语义检索分别给出排序后, 系统使用倒数排名融合 (Reciprocal Rank Fusion, RRF) 合并





图 1 SciScope 总体架构: 采集、治理、分析/模型、服务、接口与交互逐层衔接; 交互层以终端智能体自主编排工具, 大模型仅作可替换的生成层。数据来源: 系统实现、Makefile 产物与交付目录映射。

SciScope capability map

Reproducible research assets -> grounded agent runtime -> terminal product surface



Boundary: no unsupported web-front-end claim; distribution landing is a download/brand page.

图 2 SciScope 能力地图: 从可复现数据资产到证据接地智能体, 再到终端产品化客户端。数据来源: 系统实现与交付目录映射。



图 3 终端智能体客户端 (Go TUI) 实景: 沉浸式纯黑画布, 欢迎页居中呈现品牌标识与命令入口; 底部为“研究问题 / 待核查论断”输入栏。客户端只消费 `/agent/stream` 的 SSE 事件, 渲染研究计划、工具调用、证据与回答。数据来源: 运行中的 `make tui` 客户端截图。




图 4 混合检索 + 证据接地生成链路 (中文问句可跨语言命中英文文献)

多路结果:

$$\text{RRF}(d) = \sum_{r \in R} \frac{1}{k + \text{rank}_r(d)}, \quad k = 60$$

其中 R 表示参与融合的检索路由, d 为候选论文或片段; 该口径能让字面命中和语义相关共同进入证据池。

2.4 智能体编排层: 从“固定管线”到“自主 agent”

上节的检索增强生成 (Retrieval-Augmented Generation, RAG) 问答是**固定流程**。在其之上, 我们构建了**自主科研智能体**: 大模型不再被动接收检索结果, 而是**自己规划步骤、自主选择并调用工具、观察结果后决定下一步**, 必要时**自我纠错重试**。图 5 与图 6 展示了从后端编排到终端可视化的同一条事件链。




图 5 自主智能体循环: 规划 → 选工具 → 并行执行 → 观察 → (循环) → 反思自评 → 据证作答

核心机制:

- **显式规划**: 复杂问题先生成可执行研究计划, 再据计划逐步执行; 计划对用户与评委**可见**, 避免“直接给答案”的黑盒感。
- **工具自主编排**: 大模型按需调用检索、推荐、趋势、图谱、论断核查等 12 类运行时能力 (与代码注册表 `NATIVE_TOOLS`

Agent trace: from question to grounded answer

The TUI renders the same SSE phases that the backend emits.




图 6 TUI 中可见的智能体执行轨迹: 科研工作流阶段、工具调用、证据卡、自检与最终回答均通过流式事件呈现, 便于评委在不阅读源码的情况下复核系统不是黑盒问答。

一一对应), 可**多步链式**(例如先检索得到真实论文, 再据此推荐相近论文或分析趋势); 只读能力可并行执行, 相同参数自动去重防止空转。

- **专业技能 workflow:** 终端命令把论断核查、文献综述、趋势分析和论文推荐展开为可审计流程模板, 约束关键任务必须先取证、再综合。
- **反思与自评:** 回答后由模型自评”是否充分、关键论断是否都有证据支撑”, 不足则改写检索**重试一次**。
- **上下文压缩:** 长会话自动压缩历史工具结果, 避免超出上下文窗口。
- **会话态与错误恢复:** 每轮交互携带会话标识, 同一研究线程内可保存上下文并触发错误恢复, 便于连续调研。
- **服务/客户端分离:** 智能体核心以流式接口输出阶段、耗时、会话与重试标记; 当前客户端为 Go TUI, 通过同一契约消费智能体核心, 后续也可替换为其他界面。
- **可插拔生成层:** 生成大模型经 OpenAI 兼容接口接入, 一处配置即可在**本地 7B(离线/涉密)** 与 **DeepSeek 云端(更强质量)** 之间切换, 检索、接地与编排逻辑保持不变——模型成为可替换组件而非锁定项。
- **工具契约 + 执行前校验门:** 每类能力声明只读性、参数校验与结果上限; 需要论文主键的动作必须使用真实论文编号, 在访问数据库之前即**拦截模型编造的 ID** 并提示其先检索, 从机制上消除”凭空捏造主键”的失败模式。显式技能若首轮跳过必需取证步骤, 运行时会强制补上主动; 默认工具预算后强制综合, 避免空跑和无限检索。
- **自适应检索 + 可观测终止:** 模型自行判断是否需要检索(概念/常识类问题直接作答而非空转检索), 且检索讲求效率; 每轮返回**终止原因与 token 用量**, 使智能体的停止条件可解释、调用成本可计量。

当前产品化路线: 智能体由单一可观测状态图编排, 无运行时开关。底层节点被翻译为用户可理解的科研工作流阶段; TUI 在运行中显示阶段条, 并用分组时间线回看证据链。会话标识支持同线程恢复与重试(会话 checkpoint 为内存级, 进程内持久)。**MCP 双向互通与专员子智能体已落地:** 2026-08-10 已在真实 OpenCode 客户端上验证”先核查 tool、再读取 disputes resource”的顺序调用; 下一阶段聚焦跨进程持久化 checkpoint(如 SQLite/Postgres saver) 与 Human-in-the-Loop。12 类运行时能力通过同一契约维护, 确保报告中的能力清单与实际系统不漂移。

用户可见阶段	系统动作	TUI 呈现
理解问题	解析问题、装载会话上下文	显示任务入口与问题摘要
制定研究计划	拆解为可执行研究步骤	展示计划, 评委可直接复核
推理与检索决策	判断是否需要取证、调用哪类能力	显示当前阶段和后续动作
证据检索	调用检索、趋势、推荐、核查等能力	返回证据卡和来源信息
自检修正	判断证据是否充分, 必要时重试	标明修正原因与边界
综合回答	生成”研究结论 + 证据工具 + 过程入口”	工具日志不混入主回答

运行时能力	评委可见价值
跨语言文献检索	中文或英文问题均可命中英文论文, 输出论文、年份、片段与来源
趋势描述 / 方向辅助	给出关键词/主题热度、增长趋势、生命周期与候选方向信号, 并标注不确定边界; 未经回溯验证不得写成预测能力
论文推荐	基于语义、关键词、作者关系与时近性给出可解释推荐, 不是单纯相似度排序
论文详情	对真实论文编号取详情, 用于综述与立项查新
结构化论文信息	单篇论文的结构化摘要卡 (结论/方法/指标), 支撑快速精读
论文对比	对多篇真实论文做多维对比, 用于选型与批判性阅读
领域综述素材	检索代表论文并组织成综述素材, 支撑快速调研
知识图谱查询	展示作者合作、关键词共现、主题社区和 ego 子图, 支撑潜在合作者识别
引文导出	输出规范 BibTeX 条目, 服务论文写作与报告归档
论断核查	用检索证据 + 立场判定给出支持/反驳/证据不足, 并给出可追溯证据与拒答边界
争议读取	列出同 claim 的争议记录与三读立场, 支撑分歧追溯与审计
专员子智能体	将综述、趋势、批判核查等聚焦任务交给受限工具集的专员完成

2.5 开放与可扩展:MCP 双向互通 + 专员子智能体

在固定的领域工具之外, 智能体层做了三项可扩展性升级, 使 SciScope 从”封闭工具集”走向**开放智能体生态**:

- **1. SciScope 作为 MCP 服务端**: 当前能力可经模型上下文协议 (Model Context Protocol, MCP) 对外暴露, **任意 MCP 客户端** (Claude Desktop、Cursor、OpenCode 等) 可直接调用接地语料检索、论断核查与争议读取——把护城河 (16.5 万语料) 开放成生态入口而非自用孤岛。
- **2. 消费外部 MCP 工具**: 智能体可将外部 MCP 服务端能力并入统一调度。**新增能力 (如联网取全文、Web 检索) 由”插入 MCP 服务”获得, 而非改造核心系统**, 核心工具保持精简、聚焦治理语料。
- **3. 专员子智能体 (多 Agent 分工)**: 复杂多面任务可下派给**综述员 / 趋势分析师 / 批判核查员**三类专员, 各携受限能力集独立完成子任务; 专员不再继续委派, **结构上杜绝递归**。

设计取舍 (据实): 不堆砌与科研场景无关的通用编程工具; 核心保持领域工具精简, 长尾能力靠 MCP 与子智能体扩展——与主流生产级智能体”核心工具精、扩展靠 MCP/sub-agent”的工程哲学一致。

2.6 方案功能

- **科研智能体**: 大模型**自主规划并编排**检索、核查、趋势、推荐、图谱等能力, 多步推理、自我纠错、据证作答; 终端助手提供流式交互, 并把常见科研任务展开为可审计工具链。
- **文献问答: GraphRAG**(查询抽取关键词实体 → 沿共现图扩展邻居 → query expansion)+ 混合检索证据 → 本地大模型据证生成带引用回答 → **答案可被证据支撑性校验** (低置信明确提示)。
- **混合检索**: 全文检索 + 向量检索 + RRF 融合, 去重到论文级, 返回命中片段。
- **趋势描述/方向辅助**: 关键词/主题的增长率、burst、生命周期与受约束的短期外推 (含不确定区间); 若回溯未超过 naive 基线, 只可作为描述性趋势。

- **论文推荐:** 语义相似 + 关键词重叠 + 作者关系 + 时近性融合, 输出**可解释因子**。
- **知识图谱:** 作者合作图、关键词共现图、论文-主题图; 作者支持实时 ego 子图。

2.7 关键技术

- **向量化:** 本地 multilingual-e5-base 嵌入器 (768 维, 中英跨语言), fp16 加速、断点续传; 向量入 pgvector。
- **混合检索与 RRF:** 全文索引 + 余弦向量索引, 两路按 $1/(k + \text{rank})$ 融合 ($k=60$)。
- **趋势模型:** 逐年归一化词频上最小二乘外推 + 残差不确定带; 主题模型 LDA/NMF 各 40 主题。趋势热度 $h_{k,y} = n_{k,y}/N_y$, 预测采用 $\hat{h}_{k,y+1} = a_k y + b_k$ 作为排序信号, 不作确定性预言。
- **推荐模型:** 论文级平均向量 + 多信号加权, 逐条给出可解释因子; 重排采用最大边际相关 (Maximum Marginal Relevance, MMR), 即 $\lambda \text{sim}(q, d) - (1 - \lambda) \max_{d' \in S} \text{sim}(d, d')$, 兼顾相关性与多样性。
- **知识图谱:** NetworkX 中心度/社区, 百万级边按中心度剪枝导出 JSON, 作者 ego 图走 SQL 实时查询。
- **生成层:** OpenAI 兼容本地服务, 输出限长防失控, 可平滑切换更大/远程模型。
- **智能体编排:** 基于 LangGraph StateGraph 的科研智能体运行时。理解问题、制定计划、选择能力、执行工具、观察结果、自检修正、综合回答被拆为可观察节点; 底层默认本地 Qwen2.5-7B(演示服务器当前为 DeepSeek 云端, OpenAI 兼容切换, 编排逻辑不变), 支持流式选工具、只读工具并行执行、调用去重、规划/反思自校验、会话 checkpoint 与同线程重试; 事件流向用户呈现科研工作流阶段。

证据接口口径: 论断核查不把语义相似度包装为形式逻辑证明, 而是将论断 c 与证据片段 e 的接地强度表达为可解释评分:

$$g(c, e) = \alpha \text{sim}(c, e) + \beta \text{source}(e) + \gamma \text{recency}(e)$$

该评分用于支持等级与证据排序; 最终结论仍必须展示出处, 并由 reflect 节点检查关键论断是否有证据支撑。

2.8 实现过程

数据生成与采集 → 6 源按领域/年份抓取, 形成可追溯的原始分区底账。

数据组织与治理 → 规范化字段; 标题优先去重 (合并跨源/预印本同篇, 留最全一条) + front-matter 剔除 + PDF 垃圾/ NUL 清洗; 168,447 条分析语料进一步形成 159,164 篇处理后语料文件, 另讯飞交付包 5,566 篇经同一治理链入库, 运行时库表当前装载 164,730 篇论文与 413,971 个片段。

信息汲取与建模 → 切片入库, 计算片段/论文向量, 拟合趋势/推荐/图谱/主题; 关键词统一过滤 arXiv 码与超泛标签。模型资产可由一键流水线重建; 其中全量 embedding 与 ANN 索引已于 2026-08-10 在 2080 Ti 远端运行态验证, 2026-08-14 讯飞增量 46,110 块已全部 GPU 向量化入库 (chunk_embeddings 总 413,971), 演示服务器后端 0.0.0.0:8010 对外可用、mac 本地 TUI 实测连通。

服务与交互 → FastAPI 暴露检索/问答/趋势/推荐/图谱及**智能体流式**接口; 终端 AI 助手自主编排工具; 数据库不可用时自动回退内存检索, 保证演示鲁棒。

2.9 交付结构与复现索引

从评审视角看, 本项目按”数据 → 模型 → 服务/RAG → 智能体 → 接口 → 客户端”**六层交付**; 职责单一、依赖自底向上:**Python 承载全部智能** (从数据到 agent), **Go 仅作终端客户端** (经流式接口消费, 可替换、不绑定)。源码路径不作为正文卖点, 仅作为复现索引列示。

分层	评委可见成果	复现索引
1. 数据层	6 源采集、规范化、标题优先去重、分析资产与数据报告	data_pipeline/, src/harvest, src/analysis
2. 模型层	片段/论文向量、趋势、推荐、图谱等模型文件	src/models, models/, output/graphs
3. 服务 / RAG	混合检索、GraphRAG、证据接地、可解释推荐与趋势查询	backend/app/services
4. 智能体	可观测状态图: 规划、选能力、取证、观察、自检、据证作答	backend/app/agent, .sciscope/skills
5. 接口	FastAPI 流式接口与常规检索/问答/趋势/推荐/图谱接口	backend/app/api
6. 客户端	Go 终端客户端; 展示科研阶段条、时间线、会话导出与重试	tui/

3 结果分析 (系统效果与效率)

说明: 本章只写三类可复核证据: 历史固定评测 (检索 recall/MRR 与延迟)、当前工程运行态 (测试、全量 embedding、OpenCode/MCP 闭环) 和当前自动代理基线 (推荐 proxy、趋势回测)。历史评测、工程 PASS 与外部质量证明分开陈述; 若与真实业务场景不一致, 必须以后续人工 Gold、用户试点或场景化验证补充, 避免确定性外推。

核心指标一览

检索质量 (历史固定评测)	标题自检索 recall@10= 0.985 ,MRR@10= 0.9583 , 平均延迟 141.6 ms ; 关键词自检索 recall@10=0.745,MRR@10=0.7045。
跨语言相关性 (历史定向样例)	15 条固定中文主题查询上的 relevance@5= 1.0 (15/15), 优化前为 0.667; 该结果只代表定向样例, 不是全局质量证明。
趋势描述边界 (当前回测)	Pearson= 0.9756 , 但 MAE 与 sMAPE 在 2/2 个滚动切分上均未超过 naive 基线, 故当前只可称 描述性趋势 。
论文推荐 (四路自动多基线)	‘current’ 100 seeds/500 recs: same-field 0.7180 ,shared-keyword 0.6280 ,semantic 0.9263 ,diversity 0.0823 ,novelty proxy 0.5885 ; 相对 ‘dense’ 的 0.6940/0.5080/0.9332/0.0682/0.5810 是工程权衡, 不是全面胜出。
工程运行态 (2026-08-14)	后端回归 539 passed, 1 skipped ; 2026-08-14 讯飞增量入库后 chunk_embeddings=413,971、papers=164,730; 2026-08-10 历史口径 367,861/367,861 与 159,164/159,164 保留; OpenCode 顺序调用核查 tool + disputes resource 已通过。

图 7 将核心效果指标集中展示, 图 8 则说明这些指标背后的文件资产链路。二者分别对应”系统效果”与”可复现资产”两个评审入口。

3.1 检索质量与效率 (核心测试)

采用**自检索协议** (以论文自身标题/关键词为查询, 检验能否检回该文) 评测混合检索。评测结果固化于 output/eval/eval_report.json; 当前运行时库表包含 164,730 篇论文和 413,971 个片段 (2026-08-14, 含讯飞增量), 该章中的 recall/MRR 仍引用 2026-06-22 历史固定评测而非 2026-08-10 重跑结果:

查询方式	recall@1	recall@10	MRR@10	平均延迟
按标题 (字面 + 语义臂)	0.94	0.985	0.9583	141.6 ms
按关键词	0.6913	0.745	0.7045	84.2 ms





图 7 核心评测指标图形化总览。数据来源:output/eval/eval_report.json、output/eval/trends_backtest.json、output/eval/recommend_bakeoff.json 与当前验收记录; 中文相关性为固定主题查询评测口径, 测试与 OpenCode 为 2026-08-10 工程基线。

Data-to-agent asset scale

Counts come from summary files generated by the data pipeline.



File-asset counts come from reproducible pipeline summaries; runtime DB state is evidenced separately.

图 8 数据到智能体的资产漏斗。数据来源:data/analysis/summary.json、data/processed/*.summary.json 与 output/eval/eval_report.json; 图中为文件资产口径, 运行时数据库/向量表口径在本章表格中另列。

标题查询 recall@10 达 **0.985**(目标论文几乎总在前 10), 平均延迟 141.6 ms, 体现混合检索”效果与效率”兼顾。关键词查询由于同义词、缩写和领域词复用更强, 指标低于标题查询, 但仍保持 recall@10=0.745 和 MRR@10=0.7045; 本报告保留该差异, 不把关键词检索夸大成标题级精确命中。

3.2 跨语言检索相关性优化 (历史定向样例)

针对中文短查询, 初版多语言嵌入存在”按语言而非主题召回”的偏差 (如查”扩散模型”却召回到无关的中文医学论文)。我们用 15 个主题查询构建 relevance@5 指标 (top-5 是否含主题相关论文,make 可复现), 针对性实施了一组优化:

优化	作用
中英术语映射	中文查询自动替换/补充英文等价词, 把召回锚定到 (以英文为主的) 语料主题
混合字面臂	websearch 精确短语优先 + OR 兜底, 兼顾精确命中与多词召回
语义跨语言答案校验	用 e5 余弦度量”答案 ↔ 证据”接地度, 中文答案据英文文献不再被误判低置信
”最新”意图识别	识别”最新/近期”等意图, 在相关结果中优先近年论文
多轮对话记忆	指代型追问 (”它的局限呢”) 自动承接上文主题再检索

在这组固定样例上,relevance@5 从 **0.667 提升至 1.0**(15/15 全部命中主题), ”扩散模型””强化学习””量子计算””推荐系统”等此前跑偏的中文查询被修复。该结果是**定向样例工程优化证据**, 不能替代更大规模人工 qrels 或真实用户评测。

3.3 全量向量运行态

2026-08-10 在 2080 Ti 远端运行态中, 全量 chunk_embeddings 与 paper_embeddings 已分别达到 367,861/367,861 与 159,164/159,164, 从而关闭了”推荐缺 embedding”这一工程阻塞;2026-08-14 讯飞交付包 5,566 篇 (46,110 块;2 篇摄取失败不计入) 经 GPU 向量化增量入库, 总 chunk_embeddings=413,971、papers=164,730。这里仅使用能够由远端数据库计数和运行日志复核的总量, 不再保留缺少独立证据产物的领域覆盖消融数字。该证据证明的是**全量资产可运行**; 推荐质量与用户价值仍需单独评测。

3.4 差异化能力对比




图 9 论断接地流程。数据来源: 工具契约与黄金会话; 输出为支持等级和可追溯证据。

图 9 对应差异化矩阵中的”据实接地/可验证”能力。系统给出支持等级与出处, 但不把语义相似度包装为形式逻辑证明。

能力维度	SciScope	通用大模型	商用文献工具	普通检索
据实接地 / 可验证	论断核查 + 引用证据	易幻觉	部分支持	不支持
跨语言中 → 英检索	固定中文主题样例已验证	依模型能力波动	通常较弱	不支持
本地部署 / 数据主权	数据、索引、模型本地	查询上传第三方	查询上传第三方	仅检索外部库
自主多步编排	可观测规划/反思 + 专业技能 + 12 类运行时能力	非工具化问答	固定流程为主	不支持
可复现 / IP 清晰	make 重建资产	黑盒调用	平台黑盒	无模型资产

差异化不来自”又接了一个大模型”，而来自本地语料资产、可复现模型文件、证据接地检验和自主工具编排共同形成的科研智能体闭环。

3.5 趋势回测与推荐评估 (评测证据包)

历史自检索评测由 `make eval-all` 保留; 当前趋势回测由 `python-mevaluation.eval_trends_backtest` 重建, 推荐四路对照由 `python-mevaluation.eval_recommend_bakeoff` 在全量远端数据库重建。对应产物分别是 `output/eval/eval_report.{json,md}`、`trends_backtest.{json,md}` 与 `recommend_bakeoff.{json,md}`; 不再声称单个旧入口覆盖全部当前指标。

趋势回测 (拟合 2022–2024 → 预测 2025,1,998 个关键词): 预测与真实的 Pearson 相关 **0.9756**, 但在两个固定滚动切分上, 趋势模型的 MAE 与 sMAPE 均未超过 last-value / moving-average naive 基线, 因此当前输出被明确降级为 **descriptive_only=true**。它可以用于描述历史方向、波动和 burst, 但**不得**在答辩或报告中写成”预测能力”或”研究方向预测结论”。

推荐自动多基线评测 (2026-08-10,100 篇 seeds,top-5): 四路方法 popularity_proxy/keyword_tfidf/dense/current 已统一落表。‘current’ 的 coverage 为 **1.0**,same-field **0.7180**,shared-keyword **0.6280**, 平均语义相似 **0.9263**,diversity **0.0823**,novelty proxy **0.5885**; 相比 pure ‘dense’ 的 0.6940 / 0.5080 / 0.9332 / 0.0682 / 0.5810, 它在同领域率、共享关键词、多样性和新颖度代理上更高, 但语义相似度更低, 且延迟显著更高 (本次 ‘current’ p50 约 100.6 ms, ‘dense’ p50 约 4.2 ms)。这些都是**自动代理指标**, 只能说明推荐器之间的工程权衡, 不能替代研究者满意度、用户盲评或真实科研提效证明。

3.6 数据治理成效

治理项	处理	效果
标题优先去重 + front-matter 剔除	分析层与处理后语料分层治理	残留长标题重复组归零
PDF 垃圾正文过滤	清 83 篇 / 46 片段	显著减少回答混入 PDF 乱码的风险
关键词噪声过滤	arXiv 码/泛标签/期刊名	趋势 top 回归真实主题
摘要覆盖治理	140,183 篇有摘要	摘要覆盖率 83.22%, 支撑主题和检索解释
开放正文补充证据	分析层正文片段覆盖集中于开放全文来源	分析层正文片段覆盖率 8.99%; 处理后语料中 full-text 非空为 13,400/159,164(8.42%); 另讯飞增量 5,566 篇中 5,559 篇全文 ≥500 字 (预印本 PDF 直接解析), 全文级深读证据显著扩充

关键词清洗后, 趋势热点回归真实研究主题:retrieval augmented generation、large language model 位居新兴前列; 主题模型 (40 主题) 清晰区分 LLM、RAG、图神经网络、锂电池、蛋白结构、催化等方向。

3.7 模型资产与工程质量

模型文件 / 索引 / 质量项	规模
片段向量 chunk_embeddings(pgvector)	413,971 (2026-08-14, 讯飞增量入库后)
论文级向量 paper_embeddings	164,730 (2026-08-14, 讯飞增量入库后)
主题模型 (LDA + NMF)	40 主题 / 模型
知识图谱 (作者/关键词/主题)	客户端友好 JSON
后端自动化测试	make test-backend 实测 539 passed、1 skipped (2026-08-10) ; make agent-smoke 仅作历史黑盒记录, 不替代当前工程基线

产品化呈现: 智能体运行时采用可观测状态图编排, 向终端客户端输出科研工作流阶段、耗时、会话与重试信息;TUI 据此渲染阶段条、分组时间线、会话保存与错误恢复。最终回答采用” 研究结论 + 证据工具 + 过程入口” 结构, 工具日志不混入主聊天。2026-08-10 已新增两条工程证据: 一是全量 embedding/ANN 运行态关闭了推荐阻塞, 二是真实 OpenCode 已能顺序完成核查 tool 与争议 resource 读取。2026-08-14 讯飞交付包 5,566 篇全链路入库 (GPU 向量化, 总 413,971 块), 演示服务器后端 0.0.0.0:8010 对外服务,mac 本地 TUI 实时连接并通过真实问答验证。全部模型文件仍可由 make agent-build 一键重建, 知识产权清晰、评委可复现。

3.8 开源治理、分发与托管体验

除本地完整流水线外,SciScope 已补齐面向真实用户的交付链路。项目按 Apache License 2.0 开源, 仓库提供贡献指南、安全策略、行为准则、Issue/PR 模板与 GitHub Discussions, 使后续数据治理、后端、TUI、打包发布和文档优化可以以开源协作方式持续迭代。

交付面	当前状态与边界
终端客户端分发	提供 npm、Homebrew 与 Scoop 三条安装路径; 其中 Scoop 是当前 Windows 稳定路径,Homebrew 面向 macOS 用户,npm 面向已有 Node.js 的跨平台开发者。
公开托管后端	公开体验入口采用 Render Web Service + Supabase PostgreSQL/pgvector + DeepSeek API, 用于安装后快速试用和演示视频录制; 与演示服务器 (zjgsu2080 0.0.0.0:8010, 全量 164,730 篇语料) 为两条独立通道。
能力边界	托管后端定位为 demo-lite 子集, 受免费数据库容量与冷启动限制; 完整语义覆盖、全量向量表和长期稳定服务仍以本地/自建 PostgreSQL + pgvector 部署为准。
提交边界	最终提交按” 报告与附件逐文件上传” 组织, 两份 PDF 独立上传; 附件保留源代码、运行说明、评测/图谱/模型小型结果, 不随附大型 data/、models/ 与数据库运行表。

因此, 本项目的产品化状态不是只停留在离线脚本: 评委可通过报告和附件审阅完整方法, 通过本地命令重建全量能力, 也可通过已分发的 TUI 连接公开后端进行轻量体验; 演示期 TUI 亦实时连接演示服务器 (zjgsu2080:8010, 全量库 + DeepSeek 生成层), 现场可直连问答。三者分别服务” 可审阅、可复现、可试用” 三个目标。

4 应用价值

本章讨论系统产品化的**目标价值与情景测算**; 数据来源、字段质量与分析可信边界详见《SciScope 数据分析报告》。真实效率、经济与社会效益仍需合作单位试点和前后对照验证。

4.1 社会效益

- 科研提效与公平:** 把分散在多源、多语言的文献统一为可问答知识底座, 目标是降低文献调研工具的使用门槛; 是否形成可量化的信息可及性改善, 仍需真实用户试点验证。

- **可信与可审计:** 关键可验证回答均附引用论文 (evidence-grounded); **论断核查**输出支持/反驳/证据不足并保留拒答边界, **工具校验门**在调用前拦截模型编造的论文主键——从生成与调用两端共同抑制大模型幻觉与捏造, 支撑**科学决策**与严肃的立项查新、综述撰写, 减少误导性结论传播。该结论是工程能力边界, 不等于临床或监管级判断。
- **知识传承与脉络梳理:** 主题演化、关键词趋势与合作网络帮助新人快速理解领域发展脉络, 促进知识传承。
- **本地部署边界:** 数据、索引和可选本地大模型可留在本地, 减少查询正文外发; 涉密或敏感场景上线前仍须完成单位级安全、权限与合规评审, 本报告不宣称已取得认证。
- **开放与可复用:** 工具经 MCP 协议开放, 接地语料检索与论断核查可被兼容客户端复用, 具备减少重复接口开发的潜力; 实际复用规模仍待外部接入验证。

受益群体	具体行动	可验证支撑
青年研究者 / 研究生	用中文问题直达英文前沿, 快速获得代表论文、趋势和引用证据	固定中文主题样例上的跨语言检索已验证; 回答附证据卡与支持/反驳/证据不足边界
科研管理者	基于热点、生命周期、合作网络制定学科布局 and 指南方向	数据分析报告中的关键词演化、作者社区和质量边界
高校图书馆 / 情报部门	将年度文献巡检沉淀为可复现流程和可复用报告模板	make 流水线、报告 PDF、评测证据包
企业研发 / 技术情报团队	用趋势、推荐和图谱筛选技术路线、竞品方向与潜在合作对象	四路自动多基线表明 ‘current’ 相对 ‘dense’ 在同领域率、共享关键词、多样性和新颖度代理上更高, 但语义相似度略低且延迟更高; 真实用户价值仍待验证
涉密或内网机构	在本地部署语料、索引、嵌入器和生成模型, 减少敏感查询外发	PostgreSQL + pgvector + 本地 7B / 可替换生成层

4.2 经济效益

- **效率目标:** 系统把逐篇检索、初筛和证据整理组织成可复现流程; 实际节省工时和错误降低幅度尚未实测, 须由用户任务前后测确认。
- **成本结构:** 核心能力沉淀在本地索引与模型文件; 本地 7B 可减少云端 API token 可变费用, 但仍产生硬件折旧、电力、运维与人员成本, 不能写成总边际成本为零。
- **决策支持潜力:** 描述性趋势、热点识别和争议证据链可作为研发立项与技术路线讨论的输入; 是否降低试错成本仍待真实项目验证, 且当前趋势不得写成预测能力。
- **合作拓展:** 作者合作网络辅助识别潜在合作者与团队, 促进产学研对接与资源整合。
- **扩展低成本:** 新增能力靠**插入 MCP 服务**或派生专员子智能体获得, 而非重新开发; 能力边界增量扩展, 边际开发成本低。
- **数据要素服务出口:**MCP 与 OpenCode 顺序调用已证明 SciScope 不只是一个终端助手, 还可以作为被其他智能体调用的科研证据服务出口。

4.2.1 经济效益量化 (情景测算)

为便于评委直观判读, 下面给出**情景测算** (基于公开订阅定价与典型科研流程工时假设), 用于说明本地化方案的成本结构差异。

方案	年度可变成本 (以 100 名研究员估)	数据与自主可控
商用文献 AI 订阅	按 \$15/月/人估, 约 12–18 万元/年 , 随人数线性增长	查询与文献记录依赖第三方平台, 数据主权受平台条款约束
通用大模型 API 问答	按重度文献问答用量估, 数万至十余万元/年 , 随调用量增长	查询内容需发送至外部生成服务
SciScope 本地部署	建库与索引可复现; 本地推理无云端 token 费, 但保留硬件、电力、运维与人力成本	数据、索引和可选生成模型可本地部署; 正式安全结论待单位评审

科研环节	传统人工	SciScope 辅助 (情景估计)
立项查新 / 综述前期调研	单次约 40–80 工时 (逐篇检索、去重、筛选)	语义问答 + 证据直达, 估 压缩 30%–50% 前期工时
热点 / 趋势研判	数天人工巡检多个数据库 (情景假设)	脚本可生成描述性榜单; 实际任务耗时待试点计时
相似论文 / 合作者发现	人工滚雪球式查找	推荐与图谱即时给出候选 + 可解释因子

单次问答成本 (基于 token 遥测的核算口径): 本系统在每轮智能体回答中返回估算 token 用量与终止原因; 该数值来自运行时对消息内容的确定性估算, 用于**逐次记录、复盘和成本核算**, 而不是本报告中虚构一组固定成本。若接入云端 DeepSeek 等 OpenAI 兼容模型, 组织可把 token 用量乘以当期公开 API 单价进行**情景估算**; 若使用本地 7B 推理, 则主要成本转为本机算力、电力和运维投入。本项目已经具备成本可观测接口, 但尚未开展正式用户规模化成本实验。

投入产出 / 回本口径: 上述数值按公开订阅区间与典型流程假设做情景估算, 用于说明成本结构变化方向, 不代表实测收益。当前只能确认本地化流程具备标准化检索、初筛和证据整理的工程条件; 效率和回本周期须由真实业务计时与完整运维成本核算验证。

测算边界 (据实声明): 以上为**情景测算**, 依据公开订阅定价区间与典型科研流程工时假设推得, 用于说明成本结构与效率方向; **具体金额、工时与百分比须结合目标机构的真实业务计时或用户实验核对**, 本报告不声称已实测, 亦不夸大未验证的经济数字。

4.3 推广前景

- **高校/科研院所:** 学科情报中心、研究生文献调研、综述与查新服务。
- **企业研发:** 技术情报监测、竞品与专利分析、研发选题。
- **科研管理:** 基金评审辅助、领域态势研判、合作网络分析。
- **可扩展性:** 架构与领域无关, 更换语料即可迁移到任意学科或企业内部文档库; 模型可替换、流水线可复现, 便于产品化与私有化部署。

差异化价值小结

相比”直接问通用大模型”,SciScope 的不可替代之处在于: **基于真实语料、有出处可追溯、本地可复现、领域可迁移、大模型可替换**。它不是又一个聊天机器人, 而是一套把机构自有文献资产转化为可信科研生产力的智能体系统。

15 系统运行与复现说明

5.1 运行环境

- Python 3.11(conda 环境),Go 1.26(终端客户端);PostgreSQL 16 + pgvector 扩展。
- 关键依赖:fastapi、psycopg、pgvector、sentence-transformers、scikit-learn、networkx、pandas。
- 本地大模型 (可选):vLLM-Metal / LM Studio 等 OpenAI 兼容服务; 无则自动用 mock, 检索证据仍真实。

5.2 一键安装

```
make install
```

安装后端 Python 依赖

5.3 构建服务层与模型文件

```
# 1. 服务层 (建库 + 装载语料/片段)
createdb sciscope
make postgres-schema POSTGRES_DSN=postgresql://USER@localhost:5432/sciscope
psql sciscope -f infra/postgres/pgvector.sql
make postgres-load POSTGRES_DSN=...

# 2. 数据治理: 去重 (先 dry-run 再 APPLY)
make dedupe-db # 干跑统计
make dedupe-db APPLY=1 # 实际去重

# 3. 模型层: 嵌入 + 推荐 + 趋势 + 图谱
SCISCOPE_EMBEDDER_PATH=models/embedder_local/multilingual-e5-base make embeddings
make recommend-model trend-model graph-export
# 或一键:make agent-build
```

5.4 启动与体验

```
# 带数据库 + 本地嵌入启动后端
SCISCOPE_DB_DSN=postgresql://USER@localhost:5432/sciscope \
SCISCOPE_EMBEDDER_PATH=models/embedder_local/multilingual-e5-base make dev

# 终端科研智能体 (Go 客户端; 本地开发需后端:8000 与本地大模型:8001,
# 演示服务器固定:8010,SCISCOPE_BACKEND=http://10.21.16.192:8010 直连)
make backend & make llm & make tui

# 接本地大模型生成 (需:8001 上的 OpenAI 兼容服务)
make vllm-serve # 启动本地模型
... make dev # 配 LOCAL_LLM_* 指向该模型
```

使用 `make tui` 进入终端科研智能体; 后端接口文档: 本地 `http://127.0.0.1:8000/docs`, 演示服务器 `http://10.21.16.192:8010/docs`。

5.5 预编译客户端安装

若只体验终端客户端, 可直接安装预编译的 Go TUI, 再连接公开 demo 后端或自建后端:

```
# 跨平台开发者路径 (Node.js)
npm install -g sciscope-tui

# macOS(Homebrew)
brew tap Timcai06/sciscope
brew trust --cask timcai06/sciscope/sciscope-tui
brew install --cask sciscope-tui
```

```
# Windows(Scoop)
scoop bucket add sciscope https://github.com/Timcai06/scoop-sciscope
scoop install sciscope-tui
```

上述安装只分发终端客户端本体;若要体现全量科研智能体能力,仍需连接后端服务。公开后端适合演示和轻量试用,全量语料与长期运行建议按本章前述步骤部署本地或自建后端。

5.6 质量与效果验证

```
make test-backend          # 后端自动化测试 (以当前环境输出为准)
make agent-smoke           # live agent 黑盒验收: 库表规模、skills、工具预算
make eval-retrieval        # 自检索评估: recall@k / MRR / 延迟
```

复现边界 (据实): 本机开发基线与远端 2080 Ti 运行态需要分开看待。2026-08-10 已验证的远端全量运行态包括 chunk_embeddings=367,861/367,861、paper_embeddings=159,164/159,164 与 ANN 索引; 2026-08-14 演示服务器完成讯飞交付包 5,566 篇全链路入库 (papers=164,730、chunk_embeddings=413,971), 后端 0.0.0.0:8010 对外服务。本机报告构建与接口调试可不携带这组全量资产。公开托管后端为 demo-lite 子集, 不能替代本地/自建全量部署的能力证明。

5.7 全量重建 (数据更新后)

持续爬取积累新数据后, 一次性重建并自动并入去重与全部模型:

```
make data-layer-refresh && make rag-chunks && make postgres-refresh && make agent-build
```

5.8 交付物清单

- **代码:**src/(采集/治理/分析/模型)、backend/(API + 智能体编排)、tui/(Go 终端客户端)、infra/(schema)、Makefile(流水线)。
- **模型文件:**pgvector 向量索引、models/(嵌入器/趋势/推荐)、output/graphs/(图谱 JSON)、RAG 片段语料; 均可由 make agent-build 复现。
- **报告:** 本《项目报告书》与同级《数据分析报告》(output/pdf/sciscope_data_report)。
- **演示样例:**docs/examples/golden_verify_claim_session.md 给出一轮跨语言论断核查黄金会话, 评委即使不启动环境也可查看 workflow 阶段、证据时间线与最终结论格式。
- **黑盒验收:**make agent-smoke 调用 live /api/agent, 检查数据库级语料规模、能力边界、论断核查、趋势分析与论文推荐工具链路。
- **基础大模型:** 声明为可替换依赖 (任意 OpenAI 兼容端点), 不绑定特定模型。
- **提交附件边界:** 为满足逐文件上传与单文件大小限制, 正式附件提供源代码、运行说明、评测/图谱/小型模型结果和校验清单; 大型数据目录、嵌入器权重与数据库运行表不随附件上传, 由 Makefile 与运行说明重建。

SciScope · 面向科技文献智能分析的科研智能体 · 大模型可换, 证据可溯, 流水线可复现

6 示例问答与测试用例

下列样例来自**固定验收会话**、**历史运行记录**或**当前工程基线**, 用于直观展示检索、跨语言、推荐与证据接地能力。它们证明”系统如何工作”, 不自动构成更高层的质量主表、人工 Gold 或真实用户成效证明。

6.1 用例一：英文混合检索 (双臂命中)

查询:graph neural network materials discovery

返回 (**lexical**)+(**semantic**) 双臂命中):

1. Accelerated Discovery of Energy Materials via Graph Neural Networks (2025)
2. CTGNN: Crystal Transformer Graph Neural Network for Crystal Materials (2024)
3. DeepCrysTet: A Deep Learning Approach Using Tetrahedral Mesh (2023)

6.2 用例二：中文跨语言检索 (命中英文文献)

查询: 大语言模型的检索增强生成 (中文)

返回 (**semantic**) 语义臂, 跨语言命中英文论文):

1. Retrieval-Augmented Retrieval: Large Language Models are Strong Zero-Shot Retrievers (2024)
2. LExT: Towards Evaluating Trustworthiness of Natural Language Explanations (2025)
3. A Comprehensive Study of Jailbreak Attack versus Defense for LLMs (2024)

6.3 用例三：可解释论文推荐

种子论文:PMC13273979(AI 药物发现方向)

推荐 (每条附可解释因子 semantic / keyword / author / recency):

推荐论文	年份	语义相似	融合因子
Generative AI in drug discovery and development	2024	0.941	sem .56 / kw .10
Editorial: Advancing drug discovery with AI	2025	0.934	sem .56 / kw .10
Advancing Drug Discovery with AI: Machine and Deep Learning	2026	0.915	sem .55 / kw .10

6.4 用例四：趋势热点 (描述性输出)

描述性热点排行 (关键词清洗后): retrieval augmented generation → large language model → gene delivery → ...

与 2022-2026 年科研态势相符; 但根据当前滚动回测, 这类输出只可用于**描述历史方向和候选热点**, 不得写成对下一年度的确定预测。

6.5 用例五：证据接地问答

提问: 图神经网络在材料发现中有哪些应用?

系统流程: 混合检索 → 取 Top 证据 (如 *A review on the applications of GNNs in materials science, crystal graph convolutional neural network*)→ 本地大模型**仅基于证据**生成回答, 并标注引用 [n]。

关键特性: 回答可追溯到具体论文; 证据不足时如实说明, 不臆造。

6.6 用例六：科研智能体自主多步编排 (真实轨迹)

下面是终端智能体处理一个复合问题的**真实执行轨迹** (本地 Qwen2.5-7B; 演示服务器当前为 DeepSeek, 编排行为一致), 展示”规划 → 自主取证 → 多步链式 → 据证作答”:

提问: 推荐几篇关于知识图谱的代表论文并说明趋势

1. 规划 自动生成计划: 先检索代表论文 → 再基于真实论文做推荐 → 最后查询”knowledge graph” 趋势

2. 执行 智能体依计划链式取证:

1. 跨语言检索” 知识图谱”, 命中英文文献并取得真实论文编号;
2. 以检索得到的真实论文为种子做推荐, **不是预设固定结果**;
3. 将中文关键词映射到英文研究术语, 查询年度趋势。

3. 据证作答 综合三个工具的真实结果, 给出代表论文清单 + 趋势判定, 并标注出处。

关键特性: 计划对用户可见; 推荐使用的是**检索得到的真实论文编号而非臆造**; 相同参数调用自动去重防空转; 回答后还会**自评证据是否充分**, 不足则改写重试。

6.7 用例七: 论断核查与跨语言接地

下面展示论断核查能力的真实输出轨迹: 用户给出中文论断, 系统检索英文文献并用同一跨语言 e5 向量空间计算“论断-证据”接地度, 返回支持等级而不是让大模型直接判断。

待核查论断: 检索增强生成能够降低大语言模型回答中的幻觉风险

工具输出 (历史接地样例): 支持等级 = **强支持**, 最高接地相似度 =**0.846**

主要证据:

1. *Retrieval-Augmented Generation and Hallucination in Large Language Models: A Scholarly Overview* 2025, 相似度 0.846
2. *Reinforced Retrieval-Augmented Generation in Large Language Models* 2025, 相似度 0.846
3. *ReRag: A New Architecture for Reducing the Hallucination by Retrieval-Augmented Generation* 2024, 相似度 0.836
4. *Benchmarking Large Language Models in Retrieval-Augmented Generation* 2023, 相似度 0.827

关键特性: 中文论断可由英文论文接地; 工具返回的是**支持 / 反驳 / 证据不足**及其校准边界, 要求模型据证表述, 证据不足时不得强行断言。该样例用于展示证据链, 不等于正式人工 Gold 质量证明。

6.8 用例八:TUI 产品化工作流与黄金会话导出

终端客户端将底层智能体节点翻译为用户可读的科研工作流阶段。用户看到的是研究过程, 而不是内部工具日志; 时间线可按阶段回看证据链, 最终回答固定为” 研究结论 + 证据工具 + 过程入口”。

黄金会话样例:docs/examples/golden_verify_claim_session.md

用户问题:RAG 能否降低科研问答系统中的幻觉风险? 请给出证据和判断边界。

阶段	样例中的可见动作
制定研究计划	将中文论断改写为英文检索表达, 规划证据核查路径
证据检索	调用论断核查与文献检索能力, 返回支持等级和证据卡
自检修正	将结论限定为” 降低风险”, 不夸大为” 完全消除幻觉”
综合回答	输出研究结论、依据、判断边界和可复现入口

输出边界: 结论表述为” 降低幻觉风险并提升可核验性”; 证据工具与时间线入口保留给评委复核。

7 数据来源与参考文献

本系统所用数据均来自公开学术数据源, 算法与模型均为公开方法或开源权重, 知识产权清晰、可追溯、可复现。

7.1 数据来源

- D1. OpenAlex —— 开放学术知识图谱与元数据 API。 <https://openalex.org>
- D2. PubMed / PubMed Central (PMC) —— 美国国立医学图书馆生物医学文献库。 <https://pubmed.ncbi.nlm.nih.gov>
- D3. Crossref —— DOI 注册与文献元数据。 <https://www.crossref.org>
- D4. DOAJ —— 开放获取期刊目录。 <https://doaj.org>
- D5. arXiv —— 计算机/物理/数学等领域预印本库 (含全文 PDF)。 <https://arxiv.org>

7.2 方法与模型来源

- R1. Mann, H. B. (1945). Nonparametric tests against trend. *Econometrica*, 13(3), 245–259.
- R2. Sen, P. K. (1968). Estimates of the regression coefficient based on Kendall's tau. *JASA*, 63(324), 1379–1389.
- R3. Blondel, V. D., et al. (2008). Fast unfolding of communities in large networks (Louvain). *J. Stat. Mech.*
- R4. Page, L., Brin, S., et al. (1999). The PageRank citation ranking: Bringing order to the web.
- R5. Blei, D., Ng, A., Jordan, M. (2003). Latent Dirichlet Allocation (LDA). *JMLR*, 3, 993–1022.
- R6. Lee, D. D., Seung, H. S. (1999). Learning the parts of objects by non-negative matrix factorization (NMF). *Nature*, 401, 788–791.
- R7. Cormack, G. V., Clarke, C. L. A., Büttcher, S. (2009). Reciprocal rank fusion (RRF). *SIGIR*.
- R8. Robertson, S., Zaragoza, H. (2009). The probabilistic relevance framework: BM25 and beyond.
- R9. Wang, L., et al. (2024). Multilingual E5 text embeddings(multilingual-e5-base, 检索与跨语言嵌入)。
- R10. Chen, J., et al. (2024). BGE M3-Embedding / bge-reranker-v2-m3(跨语言重排)。
- R11. Qwen Team (2024). Qwen2.5 Technical Report(本地生成层 Qwen2.5-7B-Instruct)。
- R12. Model Context Protocol documentation. Open-source standard for connecting AI applications to external systems, tools and workflows. <https://modelcontextprotocol.io/docs/getting-started/intro>

合规声明: 数据用于科研分析与方法验证, 遵循各数据源的开放获取与使用条款; 系统不存储或再分发受版权保护的论文全文, 仅保留用于检索的元数据、摘要与开放获取正文片段。