

# SciScope 项目报告书

## 面向科技文献智能分析的科研智能体构建

**赛道** 智能体开发

**成果类型** 数据分析报告 + 科研智能体模型 (代码 + 模型文件)

**核心能力** 文献问答 · 趋势预测 · 论文推荐 · 知识图谱

**数据规模** 6 个公开来源 · 168,447 条分析语料 · 159,187 篇入库论文

**模型资产** 367,773 条片段向量 · 159,135 篇论文级向量

### 一句话定位

SciScope 把约 16 万篇公开科技文献炼成一个**可检索、可问答、可预测趋势、可推荐、可看图谱**的科研智能体。大语言模型仅作生成层、可任意替换；领域智能沉淀在**本地可复现的索引与模型文件**中，且每个回答都附**可追溯证据** (evidence-grounded)。这正是“科研智能体”区别于“直接问通用大模型”的核心价值。

# 目录

|          |                                |           |
|----------|--------------------------------|-----------|
| <b>1</b> | <b>项目概述</b>                    | <b>3</b>  |
| 1.1      | 项目背景                           | 3         |
| 1.2      | 应用行业                           | 3         |
| 1.3      | 主要工作                           | 3         |
| 1.4      | 创新点                            | 3         |
| <b>2</b> | <b>解决方案</b>                    | <b>4</b>  |
| 2.1      | 总体架构设计                         | 4         |
| 2.2      | 核心链路: 证据接地的检索增强问答              | 5         |
| 2.3      | 智能体编排层: 从”固定管线”到”自主 agent”     | 5         |
| 2.4      | 方案功能                           | 6         |
| 2.5      | 关键技术                           | 7         |
| 2.6      | 实现过程                           | 7         |
| 2.7      | 项目结构与分层                        | 7         |
| <b>3</b> | <b>结果分析 (系统效果与效率)</b>          | <b>8</b>  |
| 3.1      | 检索质量与效率 (核心测试)                 | 9         |
| 3.2      | 跨语言检索相关性优化 (技术创新)              | 10        |
| 3.3      | 语义覆盖修复 (消融对比)                  | 10        |
| 3.4      | 差异化能力对比                        | 11        |
| 3.5      | 趋势预测回测与推荐评估 (评测证据包)            | 11        |
| 3.6      | 数据治理成效                         | 12        |
| 3.7      | 模型资产与工程质量                      | 12        |
| <b>4</b> | <b>示例问答与测试用例</b>               | <b>12</b> |
| 4.1      | 用例一: 英文混合检索 (双臂命中)             | 12        |
| 4.2      | 用例二: 中文跨语言检索 (命中英文文献)          | 12        |
| 4.3      | 用例三: 可解释论文推荐                   | 13        |
| 4.4      | 用例四: 趋势热点 (模型输出)               | 13        |
| 4.5      | 用例五: 证据接地问答                    | 13        |
| 4.6      | 用例六: 科研智能体自主多步编排 (真实轨迹)        | 13        |
| 4.7      | 用例七: 论断核查与跨语言接地 (verify_claim) | 14        |
| 4.8      | 用例八:TUI 产品化工作流与黄金会话导出          | 14        |
| <b>5</b> | <b>应用价值</b>                    | <b>14</b> |
| 5.1      | 社会效益                           | 14        |
| 5.2      | 经济效益                           | 15        |
| 5.2.1    | 经济效益量化 (情景测算)                  | 15        |

---

|          |                        |           |
|----------|------------------------|-----------|
| 5.3      | 推广前景 . . . . .         | 16        |
| <b>6</b> | <b>系统运行与复现说明</b>       | <b>16</b> |
| 6.1      | 运行环境 . . . . .         | 16        |
| 6.2      | 一键安装 . . . . .         | 16        |
| 6.3      | 构建服务层与模型文件 . . . . .   | 16        |
| 6.4      | 启动与体验 . . . . .        | 17        |
| 6.5      | 质量与效果验证 . . . . .      | 17        |
| 6.6      | 全量重建 (数据更新后) . . . . . | 17        |
| 6.7      | 交付物清单 . . . . .        | 17        |
| <b>7</b> | <b>数据来源与参考文献</b>       | <b>17</b> |
| 7.1      | 数据来源 . . . . .         | 17        |
| 7.2      | 方法与模型来源 . . . . .      | 18        |

# 1 项目概述

## 1.1 项目背景

在文献更新加速与科研决策压力增大的场景下，核心问题不只是“能不能回答”，而是**可追溯性、可复核性与决策可用性**是否同时成立。传统关键词检索主要依赖字面匹配，难以覆盖跨语言、跨术语和多步骤研究问题；直接使用通用大模型问答又存在**幻觉、无出处、不可复现**等风险。SciScope 的定位不是更强的问答模型，而是将文献资产、检索证据、趋势解释与工具编排形成一条可复用、可验证的科研智能链路，在**每个结论都附可追溯证据**的前提下支撑文献调研、情报监测与科研治理。

## 1.2 应用行业

高校与科研院所、企业研发部门、科技情报与图书馆机构、科研管理与基金评审部门。典型场景：研究热点定位、领域脉络梳理、潜在合作者识别、文献调研提速、立项查新与综述辅助。

## 1.3 主要工作

- **数据底座**：从 arXiv、PubMed、PMC、OpenAlex、Crossref、DOAJ 6 个公开来源采集、清洗、规范化、去重，形成 168,447 条分析语料、159,164 篇处理后语料文件和 159,187 篇运行时入库论文，覆盖计算机/生物医学/材料等多领域、主窗口 2022–2026。
- **数据分析报告** (交付物 1)：文献分布、关键词演化、作者合作网络、主题模型、趋势统计 (见同级交付物 `sciscope_data_report`)。
- **科研智能体模型** (交付物 2)：本地嵌入索引、混合检索、趋势预测、论文推荐、知识图谱五大模型，配套 FastAPI 服务与终端智能体客户端。
- **系统工程**：PostgreSQL + pgvector 服务层、本地大模型 (vLLM/MLX) 生成层、一键复现的 Makefile 流水线与自动化测试。

## 1.4 创新点

### 四个核心创新

1. **大模型无关的证据接地架构 (LLM-agnostic, evidence-grounded)**：大语言模型 (LLM) 只负责“用人话写答案”，领域智能沉淀在本地可复现的索引/模型文件中；换任意大模型系统照常工作，每条回答均附引用论文，降低幻觉风险并便于审计。
2. **字面 + 语义混合检索 (Hybrid Retrieval)**：PostgreSQL 全文检索 (FTS) 与 pgvector 向量检索双路并行，用倒数排名融合 (Reciprocal Rank Fusion, RRF) 合并，兼顾精确匹配与语义/跨语言理解 (中文问句可命中英文文献)。
3. **“模型文件”即可复现资产**：不依赖黑盒训练权重，而是用本项目代码从本项目语料**计算/拟合**出的嵌入索引、趋势模型、推荐向量、知识图谱；`make agent-build` 可一键重建，知识产权清晰、评委可复现。
4. **数据质量工程**：标题优先去重 + 期刊 front-matter 剔除 + PDF 垃圾过滤 + 关键词噪声过滤 (剔除 arXiv 分类码与超泛学科标签)，显著提升检索、趋势与图谱的信噪比。

**数字口径说明**：本报告将数据规模分为四类口径：数据分析报告使用 `data/analysis/summary.json` 的 168,447 条分析语料；处理后语料文件使用 `data/processed/papers_corpus.summary.json` 的 159,164 篇；运行时服务以 PostgreSQL 当前库表为准，即 159,187 篇论文、367,773 个片段、367,773 条片段向量和 159,135 条论文级向量；系统效果以 `output/eval/eval_report.json` 为准。四类口径用途不同，不混写为同一个总数。

## 2 解决方案

### 2.1 总体架构设计

架构以数据资产可复现、证据可追溯、决策可复核为主线。系统分为数据治理与分析资产层、模型与索引层、服务与接口层、智能体编排层四类能力；各层既可独立评估，也共享同一数据口径，便于持续更新与复现。图 1 展示底层数据到智能体交互的完整链路，图 2 则把工程组件收束为评委可快速识别的能力地图。




图 1 SciScope 总体架构: 采集、治理、分析/模型、服务、接口与交互逐层衔接; 交互层以终端智能体自主编排工具, 大模型仅作可替换的生成层。数据来源: 系统实现、Makefile 产物与交付目录映射。

### SciScope capability map

Local-first data intelligence stack: reproducible assets -> grounded agent -> product client




图 2 SciScope 能力地图: 从可复现数据资产到证据接地智能体, 再到终端产品化客户端。数据来源: 系统实现与交付目录映射。

**设计原则:**(1) 离线可复现, 每层产物由 make 目标生成;(2) 大模型可替换, 生成层走 OpenAI 兼容接口;(3) 证据可追溯, 回答必带引用;(4) 本地优先, 数据与索引均在本地, 支持涉密场景。

## 2.2 核心链路: 证据接地的检索增强问答

问答不直接交给大模型臆测, 而是先检索证据、再据证生成, 每条回答都可追溯到具体论文: 见图 3。




图 3 混合检索 + 证据接地生成链路 (中文问句可跨语言命中英文文献)

## 2.3 智能体编排层: 从”固定管线”到”自主 agent”

上节的检索增强生成 (Retrieval-Augmented Generation, RAG) 问答是固定流程。在其之上, 我们构建了自主科研智能体: 大模型不再被动接收检索结果, 而是自己规划步骤、自主选择并调用工具、观察结果后决定下一步, 必要时自我纠错重试。图 4 与图 5 展示了从后端编排到终端可视化的同一条事件链。




图 4 自主智能体循环: 规划 → 选工具 → 并行执行 → 观察 → (循环) → 反思自评 → 据证作答

## Agent trace: from question to grounded answer



图 5 TUI 中可见的智能体执行轨迹: 科研工作流阶段、工具调用、证据卡、reflect 与 final 均通过 SSE 事件流呈现, 便于评委复核系统不是黑盒问答。

### 核心机制:

- **显式规划 (plan):** 复杂问题先生成可执行步骤计划 (仅引用内置工具, 且 recommend/compare 等依赖 paper\_id 的工具会被安排在 search 之后), 再据计划逐步执行; 计划对用户与评委可见。
- **工具自主编排:** 大模型按需调用 9 个工具, 可多步链式 (如先 search 拿到真实 paper\_id 再 recommend\_papers / get\_trends); 只读工具并行执行; 相同参数调用自动去重防止空转。
- **反思与自评 (reflect):** 回答后由模型自评”是否充分、关键论断是否都有证据支撑”, 不足则改写检索重试一次。

- **上下文压缩**: 长会话自动压缩历史工具结果, 避免超出上下文窗口。
- **会话态与错误恢复**: TUI 传入 `session_id`, 后端映射为 `LangGraph thread_id` 并通过 `checkpoint` 保留会话态; `/retry` 在同一线程内携带 `retry=true` 触发恢复。
- **服务/客户端分离**: agent 核心运行于 `/api/agent/stream` (SSE 流式)。事件 `meta` 同时返回运行时、节点、用户可读阶段 (`phase`)、耗时、会话与 `retry` 标记; TUI 与未来 Web 前端共用同一智能体核心。

**当前产品化路线**: Agent 由单一 `LangGraph StateGraph` 编排, 无运行时开关。 `meta.phase` 将底层节点翻译为用户可理解的科研工作流阶段; TUI 在运行中显示阶段条, 并用分组 `/timeline` 回看证据链。 `session_id` 映射为 `thread_id`, `checkpoint` 保存会话态, `/retry` 支持同线程错误恢复。下一阶段聚焦持久化 `checkpoint`、`Human-in-the-Loop`、多 Agent 分工与节点级恢复; 检索、趋势、推荐、图谱和 `verify_claim` 工具保持不变。

| 用户可见阶段  | 对应节点                               | TUI 呈现                 |
|---------|------------------------------------|------------------------|
| 理解问题    | <code>prepare</code>               | 解析问题、装载会话上下文           |
| 制定研究计划  | <code>plan</code>                  | 展示可执行研究步骤              |
| 推理与检索决策 | <code>llm_step</code>              | 选择是否调用工具与下一步动作         |
| 证据检索    | <code>execute_tools</code>         | 调用检索、趋势、推荐、核查等工具       |
| 自检修正    | <code>reflect</code>               | 判断证据是否充分, 必要时重试        |
| 综合回答    | <code>force_synthesis/final</code> | 输出”研究结论 + 证据工具 + 过程入口” |

| 工具                                 | 作用                                                                 |
|------------------------------------|--------------------------------------------------------------------|
| <code>search_literature</code>     | 跨语言混合检索 (FTS + 向量 + 倒数排名融合 RRF + 双语映射 + 重排)                        |
| <code>get_trends</code>            | Mann-Kendall(MK) 趋势判定 + Sen's 斜率 + 下一年预测                           |
| <code>recommend_papers</code>      | 语义 + 关键词 + 作者 + 最大边际相关 (Maximum Marginal Relevance, MMR) 多样性的可解释推荐 |
| <code>get_paper</code>             | 按 <code>paper_id</code> 取论文详情                                      |
| <code>summarize_field</code>       | 检索代表论文作为领域综述素材                                                     |
| <code>compare_papers</code>        | 取两篇论文详情用于多维对比                                                      |
| <code>query_knowledge_graph</code> | 作者/关键词/主题图谱与研究社区主题                                                 |
| <code>export_bibliography</code>   | 导出 BibTeX 引文条目                                                     |
| <code>verify_claim</code>          | <b>跨语言论断核查</b> : 用语义接地度判定支持等级并给出处                                  |

## 2.4 方案功能

- **科研智能体** `/api/agent/stream`: 大模型自主规划并编排上述能力 (9 个工具), 多步推理、自我纠错、据证作答; 终端助手 `make tui` 提供 Claude Code 风格的流式交互。
- **文献问答** `/api/chat:GraphRAG` (查询抽取关键词实体 → 沿共现图扩展邻居 → `query expansion`) + 混合检索证据 → 本地大模型据证生成带引用回答 → **答案可被证据支撑性校验** (低置信明确提示)。
- **混合检索** `/api/search`: FTS + 向量 + RRF 融合, 去重到论文级, 返回命中片段。
- **趋势预测** `/api/trends`: 关键词/主题的增长率、burst、生命周期与下一年线性外推 (含不确定区间)。
- **论文推荐** `/api/recommend`: 语义相似 + 关键词重叠 + 作者关系 + 时近性融合, 输出可解释因子。
- **知识图谱** `/api/graph`: 作者合作图、关键词共现图、论文-主题图; 作者支持实时 ego 子图。

## 2.5 关键技术

- **向量化**: 本地 multilingual-e5-base(768 维, 中英跨语言), fp16 加速、断点续传; 向量入 pgvector。
- **混合检索与 RRF**: 全文索引 (tsvector) + 余弦向量索引 (ivfflat), 两路按  $1/(k + \text{rank})$  融合 ( $k=60$ )。
- **趋势模型**: 逐年归一化词频上最小二乘外推 + 残差不确定带; 主题模型 LDA/NMF 各 40 主题。
- **推荐模型**: 论文级平均向量 (pgvector avg) + 多信号加权, 逐条给出可解释因子。
- **知识图谱**: NetworkX 中心度/社区, 百万级边按中心度剪枝导出 JSON, 作者 ego 图走 SQL 实时查询。
- **生成层**: OpenAI 兼容本地服务, 输出限长防失控, 可平滑切换更大/远程模型。
- **智能体编排**: 基于 LangGraph StateGraph 的科研智能体运行时。prepare / plan / LLM step / tool execution / reflect / final synthesis 被拆为可观察节点; 底层使用本地 Qwen2.5-7B(vLLM, hermes 工具解析), 支持流式选工具、只读工具并行执行、调用去重、plan/reflect 自校验、会话 checkpoint 与多线程 /retry; 事件流通过 phase 字段向用户呈现科研工作流阶段。

## 2.6 实现过程

**数据生成与采集** → 6 源按领域/年份抓取, 落 data/raw\_canonical 分区 JSONL。

**数据组织与治理** → 规范化字段; 标题优先去重 (合并跨源/预印本同篇, 留最全一条) + front-matter 剔除 + PDF 垃圾/ NUL 清洗; 168,447 条分析语料进一步形成 159,164 篇处理后语料文件, 运行时库表当前装载 159,187 篇论文。

**信息汲取与建模** → 切片入库, 计算片段/论文向量, 拟合趋势/推荐/图谱/主题; 关键词统一过滤 arXiv 码与超泛标签。make agent-build 一键重建。

**服务与交互** → FastAPI 暴露检索/问答/趋势/推荐/图谱及智能体流式接口; 终端 AI 助手 make tui 自主编排工具 (Web 前端已预留 SSE 接口); 数据库不可用时自动回退内存检索, 保证演示鲁棒。

## 2.7 项目结构与分层

代码按”数据 → 模型 → 服务/RAG → 智能体 → 接口 → 客户端”六层组织, 职责单一、依赖自底向上: Python 承载全部智能 (从数据到 agent), Go 仅作终端客户端 (经 SSE 消费, 可替换、不绑定)。

```

数据要素 /
├── data_pipeline/ [1] 加载 / 规范化
├── src/
│   ├── harvest, analysis/ [1] 6 源采集 / 分析资产 -> 数据报告
│   └── models/ [2] 嵌入 · 趋势 · 推荐 · 图谱 · 双语 · 重排
├── models/, output/graphs/ [2] 模型文件 / 知识图谱 JSON
├── backend/app/
│   ├── services/ [3] 混合检索 (RAG) · GraphRAG · 证据接地
│   ├── agent/ [4] LangGraph StateGraph(plan-> 执行-> 观察-> 反思, session/retry, 9 工具)
│   └── api/ [5] /api/agent/stream(SSE meta)+ search / chat / trends
├── tui/ [6] Go · Bubble Tea 终端客户端 (消费 SSE)
└── PostgreSQL + pgvector 运行时: papers · chunk_embeddings · ...
  
```



| 分层          | 职责与代码位置                                                                                                                         |
|-------------|---------------------------------------------------------------------------------------------------------------------------------|
| 1. 数据层      | 6 源采集 -> 规范化 / 标题优先去重 -> 分析资产 (data_pipeline、src/harvest、src/analysis)                                                          |
| 2. 模型层      | 片段/论文向量、趋势、推荐、图谱等 <b>模型文件</b> , 入 PostgreSQL + pgvector(src/models、models/, output/graphs/)                                     |
| 3. 服务 / RAG | 混合检索 (FTS + 向量 + RRF + 双语 + 重排)+ GraphRAG + 证据接地 (backend/app/services)                                                         |
| 4. 智能体      | LangGraph StateGraph:prepare -> plan -> 选工具 -> 并行执行 -> 观察 -> 反思自评 -> 据证作答; 支持 session checkpoint 与多线程 /retry(backend/app/agent) |
| 5. 接口       | FastAPI; 智能体经 /api/agent/stream 以 SSE 流式输出, 并在 meta 中暴露 runtime / node / phase / elapsed / session / retry(backend/app/api)     |
| 6. 客户端      | Go / Bubble Tea 终端 (tui/main.go), 纯 SSE 消费; 将 phase 渲染为科研工作流阶段条与分组 /timeline,Web 前端复用同一接口                                       |

### 3 结果分析 (系统效果与效率)

**说明:** 本章给出三组可复核证据: 检索有效性 (recall/MRR 与延迟)、跨语言相关性 (relevance@5) 与工程稳健性 (自动化测试与资产口径)。指标以脚本生成的评测报告和运行时库表为准; 若与具体业务场景不一致, 应以场景化验证补充, 避免确定性外推。

| 核心指标一览 |                                                                               |
|--------|-------------------------------------------------------------------------------|
| 检索质量   | 标题自检索 recall@10= <b>0.985</b> ,MRR@10= <b>0.9583</b> , 平均延迟 <b>141.6 ms</b> 。 |
| 跨语言相关性 | 中文主题查询 relevance@5= <b>1.0</b> (15/15), 优化前为 0.667。                           |
| 趋势预测   | 2022-2024 拟合预测 2025, 关键词活跃度排序 Pearson= <b>0.9756</b> 。                        |
| 论文推荐   | top-5 平均语义相似 <b>0.8918</b> , 同领域率 0.6733, 共享关键词率 0.6013。                      |
| 工程质量   | 后端测试基线按当前验收记录为 <b>108 项</b> ; 运行时库表含 367,773 条片段向量和 159,135 条论文级向量。           |




图 6 核心评测指标图形化总览。数据来源:output/eval/eval\_report.json 与当前验收记录; 中文相关性为固定主题查询评测口径, 测试项为后端测试基线。

## Data-to-agent asset funnel



Counts are file-asset counts, not inflated claims; runtime DB/vector counts are reported separately in tables.

图 7 数据到智能体的资产漏斗。数据来源:data/analysis/summary.json、data/processed/\*.summary.json 与 output/eval/eval\_report.json; 图中为文件资产口径, 运行时数据库/向量表口径在本章表格中另列。

图 6 将核心效果指标集中展示, 图 7 则说明这些指标背后的文件资产链路。二者分别对应”系统效果”与”可复现资产”两个评审入口。

### 3.1 检索质量与效率 (核心测试)

采用**自检索协议**(以论文自身标题/关键词为查询, 检验能否检回该文) 评测混合检索。评测结果固化于 output/eval/eval\_report.json。运行时库表当前包含 159,187 篇论文:

| 查询方式           | recall@1 | recall@10    | MRR@10 | 平均延迟     |
|----------------|----------|--------------|--------|----------|
| 按标题 (字面 + 语义臂) | 0.94     | <b>0.985</b> | 0.9583 | 141.6 ms |
| 按关键词           | 0.6913   | 0.745        | 0.7045 | 84.2 ms  |

标题查询 recall@10 达 **0.985**(目标论文几乎总在前 10), 平均延迟 141.6 ms, 体现混合检索”效果与效率”兼顾。关键词查询由于同义词、缩写和领域词复用更强, 指标低于标题查询, 但仍保持 recall@10=0.745 和 MRR@10=0.7045;

本报告保留该差异, 不把关键词检索夸大成标题级精确命中。

3.2 跨语言检索相关性优化 (技术创新)

针对真实用户的**中文短查询**, 初版多语言嵌入存在” 按语言而非主题召回” 的偏差 (如查” 扩散模型” 却召回到无关的中文医学论文)。我们用 15 个主题查询构建 **relevance@5** 指标 (top-5 是否含主题相关论文,make 可复现), 针对性实施了一组优化:

| 优化         | 作用                                           |
|------------|----------------------------------------------|
| 中英术语映射     | 中文查询自动替换/补充英文等价词, 把召回锚定到 (以英文为主的) 语料主题       |
| 混合字面臂      | <b>websearch</b> 精确短语优先 + OR 兜底, 兼顾精确命中与多词召回 |
| 语义跨语言答案校验  | 用 e5 余弦度量” 答案 ↔ 证据” 接地度, 中文答案据英文文献不再被误判低置信   |
| ” 最新” 意图识别 | 识别” 最新/近期” 等意图, 在相关结果中优先近年论文                 |
| 多轮对话记忆     | 指代型追问 (” 它的局限呢”) 自动承接上文主题再检索                 |

效果:**relevance@5** 从 **0.667 提升至 1.0**(15/15 全部命中主题), ” 扩散模型” ” 强化学习” ” 量子计算” ” 推荐系统” 等此前跑偏的中文查询**全部修复**。

3.3 语义覆盖修复 (消融对比)

初版仅对” 有全文” 论文嵌入, 导致语义检索严重偏向生物医学、对最大领域**计算机科学近乎失明** (论文级向量仅 87 篇); 经**全量标题摘要嵌入**修复后, 论文级向量 17,913 → 159,164, 各领域覆盖如下 (消融前后对比):




图 8 语义检索领域覆盖: 修复前 (空心)vs 修复后 (实心)。计算机科学从 87 跃升至 58,038, 偏科消除。数据来源: 论文级向量覆盖统计与全量标题摘要嵌入修复记录。

修复后语义检索与推荐覆盖运行时全领域论文库, 中文问句可跨语言命中英文文献。

### 3.4 差异化能力对比

#### verify\_claim grounding flow




图 9 verify\_claim 论断接地流程：中文论断经跨语言检索连接到英文证据，再用语义相似度给出支持等级与出处；该图展示真实功能边界，不是逻辑证明器。

图 9 对应差异化矩阵中的“据实接地/可验证”能力：系统给出支持等级与出处，但不把语义相似度包装为形式逻辑证明。

| 能力维度        | SciScope                      | 通用大模型   | 商用文献工具  | 普通检索   |
|-------------|-------------------------------|---------|---------|--------|
| 据实接地 / 可验证  | verify_claim + 引用证据           | 易幻觉     | 部分支持    | 不支持    |
| 跨语言中 → 英检索  | relevance@5=1.0               | 依模型能力波动 | 通常较弱    | 不支持    |
| 本地部署 / 数据主权 | 数据、索引、模型本地                    | 查询上传第三方 | 查询上传第三方 | 仅检索外部库 |
| 自主多步编排      | LangGraph plan/reflect + 9 工具 | 非工具化问答  | 固定流程为主  | 不支持    |
| 可复现 / IP 清晰 | make 重建资产                     | 黑盒调用    | 平台黑盒    | 无模型资产  |

差异化不来自“又接了一个大模型”，而来自本地语料资产、可复现模型文件、证据接地检验和自主工具编排共同形成的科研智能体闭环。

### 3.5 趋势预测回测与推荐评估（评测证据包）

完整评测可由 `make eval-all` 复现，结果固化于 `output/eval/eval_report.{json,md}`。

**趋势预测回测**（拟合 2022–2024 → 预测 2025, 1,998 个关键词）：预测与真实的 Pearson 相关 **0.9756**，说明模型能较好排序哪些关键词更活跃；但方向性与点预测不应被解释为确定预测，归一化词频存在年际噪声和近均值回归。本报告仅把趋势模型作为排序、动量和 burst 的候选信号。

**推荐离线评估**（150 篇种子, top-5）：同领域率 **0.6733**、共享关键词率 **0.6013**、平均语义相似 **0.8918**——远高于随机基线，且每条附可解释因子。

### 3.6 数据治理成效

| 治理项                      | 处理              | 效果                      |
|--------------------------|-----------------|-------------------------|
| 标题优先去重 + front-matter 剔除 | 分析层与处理后语料分层治理   | 残留长标题重复组归零              |
| PDF 垃圾正文过滤               | 清 83 篇 / 46 片段  | 显著减少回答混入 PDF 乱码的风险      |
| 关键词噪声过滤                  | arXiv 码/泛标签/期刊名 | 趋势 top 回归真实主题           |
| 摘要覆盖治理                   | 140,183 篇有摘要    | 摘要覆盖率 83.22%, 支撑主题和检索解释 |
| 全文片段治理                   | 15,144 篇有正文字段   | 正文覆盖率 8.99%, 用于深读补充证据   |

关键词清洗后, 趋势热点回归真实研究主题:retrieval augmented generation、large language model 位居新兴前列; 主题模型 (40 主题) 清晰区分 LLM、RAG、图神经网络、锂电池、蛋白结构、催化等方向。

### 3.7 模型资产与工程质量

| 模型文件 / 索引 / 质量项                 | 规模                                 |
|---------------------------------|------------------------------------|
| 片段向量 chunk_embeddings(pgvector) | 367,773                            |
| 论文级向量 paper_embeddings          | 159,135                            |
| 主题模型 (LDA + NMF)                | 40 主题 / 模型                         |
| 知识图谱 (作者/关键词/主题)                | 前端友好 JSON                          |
| 后端自动化测试                         | 当前验收基线 108 项; 最终以 make test 实测输出为准 |

产品化呈现: 智能体运行时已默认切到 LangGraph StateGraph。SSE meta 暴露 runtime/node/phase/elapsed\_ms/session\_id/retry;TUI 据此渲染科研工作流阶段条、分组 /timeline、会话保存与 /retry 错误恢复。最终回答采用”研究结论 + 证据工具 + 过程入口”结构, 工具日志不混入主聊天。全部模型文件仍可由 make agent-build 一键重建, 知识产权清晰、评委可复现。

## 4 示例问答与测试用例

下列为系统在真实 16 万篇语料上的**实际输出** (非示意), 用于直观展示检索、跨语言、推荐与证据接地能力。

#### 4.1 用例一: 英文混合检索 (双臂命中)

查询:graph neural network materials discovery  
返回 (**lexical**)+(**semantic**) 双臂命中):  
1. Accelerated Discovery of Energy Materials via Graph Neural Networks (2025)  
2. CTGNN: Crystal Transformer Graph Neural Network for Crystal Materials (2024)  
3. DeepCrysTet: A Deep Learning Approach Using Tetrahedral Mesh (2023)

#### 4.2 用例二: 中文跨语言检索 (命中英文文献)

查询: 大语言模型的检索增强生成 (中文)  
返回 (**semantic**) 语义臂, 跨语言命中英文论文):  
1. Retrieval-Augmented Retrieval: Large Language Models are Strong Zero-Shot Retrievers (2024)

|                                                                              |        |
|------------------------------------------------------------------------------|--------|
| 2. LExT: Towards Evaluating Trustworthiness of Natural Language Explanations | (2025) |
| 3. A Comprehensive Study of Jailbreak Attack versus Defense for LLMs         | (2024) |

4.3 用例三：可解释论文推荐

种子论文:PMC13273979(AI 药物发现方向)

推荐 (每条附可解释因子 semantic / keyword / author / recency):

| 推荐论文                                                        | 年份   | 语义相似  | 融合因子             |
|-------------------------------------------------------------|------|-------|------------------|
| Generative AI in drug discovery and development             | 2024 | 0.941 | sem .56 / kw .10 |
| Editorial: Advancing drug discovery with AI                 | 2025 | 0.934 | sem .56 / kw .10 |
| Advancing Drug Discovery with AI: Machine and Deep Learning | 2026 | 0.915 | sem .55 / kw .10 |

4.4 用例四：趋势热点 (模型输出)

/api/trends 新兴热点排行 (关键词清洗后): retrieval augmented generation → large language model  
→ gene delivery → ...  
与 2022-2026 年科研态势吻合,RAG 与大语言模型领跑。

4.5 用例五：证据接地问答

提问: 图神经网络在材料发现中有哪些应用?

系统流程: 混合检索 → 取 Top 证据 (如 *A review on the applications of GNNs in materials science、crystal graph convolutional neural network*)→ 本地大模型**仅基于证据**生成回答, 并标注引用 [n]。

关键特性: 回答可追溯到具体论文; 证据不足时如实说明, 不臆造。

4.6 用例六：科研智能体自主多步编排 (真实轨迹)

下面是终端智能体 make tui 处理一个复合问题的**真实执行轨迹** (本地 Qwen2.5-7B), 展示” 规划 → 自主选工具 → 多步链式 → 据证作答”:

提问: 推荐几篇关于知识图谱的代表论文并说明趋势

1. plan

自动生成计划:search\_literature(知识图谱) → recommend\_papers → get\_trends

2. 执行

智能体依计划链式调用:

1. search\_literature{query:" 知识图谱"} —— 跨语言命中英文文献, 取得真实 paper\_id

2. recommend\_papers{paper\_id:"W2789524213"} —— 把上一步得到的 id 喂入推荐 (多步链式, 非固定管线)

3. get\_trends{keyword:"knowledge graph"} —— 中文关键词**自动转英文**查趋势

3. 据证作答

综合三个工具的真实结果, 给出代表论文清单 + 趋势判定, 并标注出处。

关键特性: 计划对用户可见;recommend 用的是**检索得到的真实 id 而非臆造**; 相同参数调用自动去重防空转; 回答后还会**自评证据是否充分**, 不足则改写重试。

## 4.7 用例七: 论断核查与跨语言接地 (verify\_claim)

下面展示第 9 个智能体工具 `verify_claim` 的真实输出轨迹: 用户给出中文论断, 系统检索英文文献并用同一跨语言 e5 向量空间计算“论断-证据”接地度, 返回支持等级而不是让大模型直接判断。

**待核查论断:** 检索增强生成能够降低大语言模型回答中的幻觉风险

**工具输出:** 支持等级 = **强支持**, 最高接地相似度 = **0.846**

**主要证据:**

1. *Retrieval-Augmented Generation and Hallucination in Large Language Models: A Scholarly Overview* 2025, 相似度 0.846
2. *Reinforced Retrieval-Augmented Generation in Large Language Models* 2025, 相似度 0.846
3. *ReRag: A New Architecture for Reducing the Hallucination by Retrieval-Augmented Generation* 2024, 相似度 0.836
4. *Benchmarking Large Language Models in Retrieval-Augmented Generation* 2023, 相似度 0.827

**关键特性:** 中文论断可由英文论文接地; 工具返回的是**强支持** / **部分支持** / **证据不足**的校准信号, 要求模型据证表述, 证据不足时不得强行断言。

## 4.8 用例八:TUI 产品化 workflows 与黄金会话导出

终端客户端将底层 LangGraph 节点翻译为用户可读的科研工作流阶段。用户看到的是研究过程, 而不是内部工具日志: `/timeline` 按阶段回看证据链, 最终回答固定为“研究结论 + 证据工具 + 过程入口”。

**黄金会话样例:** docs/examples/golden\_verify\_claim\_session.md

**用户问题:** RAG 能否降低科研问答系统中的幻觉风险? 请给出证据和判断边界。

| 阶段     | 样例中的可见动作                                       |
|--------|------------------------------------------------|
| 制定研究计划 | 将中文论断改写为英文检索表达, 规划证据核查路径                       |
| 证据检索   | 调用 <code>verify_claim</code> 与文献检索, 返回支持等级和证据卡 |
| 自检修正   | 将结论限定为“降低风险”, 不夸大为“完全消除幻觉”                     |
| 综合回答   | 输出研究结论、依据、判断边界和可复现入口                           |

**输出边界:** 结论表述为“降低幻觉风险并提升可核验性”; 证据工具与 `/timeline` 入口保留给评委复核。

# 5 应用价值

本章只讨论系统产品化带来的组织层价值; 数据来源、字段质量与分析可信边界详见《SciScope 数据分析报告》。价值主线是从**效率提升**走向**决策质量提升**, 再沉淀为机构可复用的**科研情报治理能力**。

## 5.1 社会效益

- **科研提效与公平:** 把分散在多源、多语言的文献统一为可问答知识底座, 让中小机构、欠发达地区科研人员以更门槛获得高质量文献调研能力, 缩小科研信息鸿沟。
- **可信与可审计:** 每条回答均附引用论文 (evidence-grounded), 从源头抑制大模型幻觉, 支撑**科学决策**与严肃的立项查新、综述撰写, 减少误导性结论传播。
- **知识传承与脉络梳理:** 主题演化、关键词趋势与合作网络帮助新人快速理解领域发展脉络, 促进知识传承。
- **数据安全友好:** 本地优先架构 (数据、索引、可选本地大模型均在本地), 适配涉密/敏感科研场景, 符合数据安全

与自主可控要求。

| 受益群体          | 具体行动                          | 可验证支撑                                  |
|---------------|-------------------------------|----------------------------------------|
| 青年研究者 / 研究生   | 用中文问题直达英文前沿, 快速获得代表论文、趋势和引用证据 | 跨语言 relevance@5=1.0; 回答附证据卡与支持等级       |
| 科研管理者         | 基于热点、生命周期、合作网络制定学科布局 and 指南方向 | 数据分析报告中的关键词演化、作者社区和质量边界                |
| 高校图书馆 / 情报部门  | 将年度文献巡检沉淀为可复现流程和可复用报告模板       | make 流水线、报告 PDF、评测证据包                  |
| 企业研发 / 技术情报团队 | 用趋势、推荐和图谱筛选技术路线、竞品方向与潜在合作对象   | 推荐同领域率 0.6733、语义相似 0.8918、图谱导出         |
| 涉密或内网机构       | 在本地部署语料、索引、嵌入器和生成模型, 减少敏感查询外发 | PostgreSQL + pgvector + 本地 7B / 可替换生成层 |

5.2 经济效益

- **效率提升:** 文献调研、热点定位、综述梳理等高耗时环节由”人工逐篇”转为”语义问答 + 证据直达”, 显著压缩科研前期投入工时。
- **成本优化:** 核心智能沉淀在**本地可复现的索引与模型文件**, 大模型仅作可替换的生成层——可用小模型本地推理、按需切换更强模型, 避免高昂的纯大模型 API 调用成本。
- **创新驱动与决策支持:** 趋势预测与热点识别为研发立项、技术路线选择、专利布局提供数据支撑, 降低试错成本。
- **合作拓展:** 作者合作网络辅助识别潜在合作者与团队, 促进产学研对接与资源整合。

5.2.1 经济效益量化 (情景测算)

为便于评委直观判读, 下面给出**情景测算** (基于公开订阅定价与典型科研流程工时假设), 用于说明本地化方案的成本结构差异。

| 方案            | 年度可变成本 (以 100 名研究员估)                              | 数据与自主可控                     |
|---------------|---------------------------------------------------|-----------------------------|
| 商用文献 AI 订阅    | 按 \$15/月/人估, 约 <b>12–18 万元/年</b> , 随人数线性增长        | 查询与文献记录依赖第三方平台, 数据主权受平台条款约束 |
| 通用大模型 API 问答  | 按重度文献问答用量估, <b>数万至十余万元/年</b> , 随调用量增长             | 查询内容需发送至外部生成服务              |
| SciScope 本地部署 | 建库与索引为 <b>一次性可复现投入</b> , 边际推理成本 <b>近 0</b> (单卡本地) | 数据、索引、模型 <b>全本地</b> , 自主可控  |

| 科研环节          | 传统人工                      | SciScope 辅助 (情景估计)                    |
|---------------|---------------------------|---------------------------------------|
| 立项查新 / 综述前期调研 | 单次约 40–80 工时 (逐篇检索、去重、筛选) | 语义问答 + 证据直达, 估 <b>压缩 30%–50%</b> 前期工时 |
| 热点 / 趋势研判     | 数天人工巡检多个数据库               | 趋势模型一键产出可解释榜单, <b>分钟级</b>             |
| 相似论文 / 合作者发现  | 人工滚雪球式查找                  | 推荐与图谱即时给出候选 + 可解释因子                   |



**投入产出 / 回本口径:** 上述数值按公开订阅区间与典型流程假设做情景估算, 用于说明成本结构变化方向, 不代表实测收益。更稳妥的结论是: 在有持续更新需求的组织中, 本地化流程可将检索、初筛和证据整理从重复劳动转为标准化输入, 提高决策准备效率并降低外部工具依赖风险。

**测算边界 (据实声明):** 以上为情景测算, 依据公开订阅定价区间与典型科研流程工时假设推得, 用于说明成本结构与效率方向; **具体金额、工时与百分比须结合目标机构的真实业务计时或用户实验核对**, 本报告不声称已实测, 亦不夸大未验证的经济数字。

### 5.3 推广前景

- **高校/科研院所:** 学科情报中心、研究生文献调研、综述与查新服务。
- **企业研发:** 技术情报监测、竞品与专利分析、研发选题。
- **科研管理:** 基金评审辅助、领域态势研判、合作网络分析。
- **可扩展性:** 架构与领域无关, 更换语料即可迁移到任意学科或企业内部文档库; 模型可替换、流水线可复现, 便于产品化与私有化部署。

#### 差异化价值小结

相比”直接问通用大模型”, SciScope 的不可替代之处在于: **基于真实语料、有出处可追溯、本地可复现、领域可迁移、大模型可替换**。它不是又一个聊天机器人, 而是一套把机构自有文献资产转化为可信科研生产力的智能体系统。

## 6 系统运行与复现说明

### 6.1 运行环境

- Python 3.11(conda 环境), Go 1.26(终端客户端), Node.js(规划中的前端); PostgreSQL 15 + pgvector 扩展。
- 关键依赖: fastapi、psycopg、pgvector、sentence-transformers、scikit-learn、networkx、pandas。
- 本地大模型 (可选): vLLM-Metal / LM Studio 等 OpenAI 兼容服务; 无则自动用 mock, 检索证据仍真实。

### 6.2 一键安装

```
make install
```

# 安装后端 Python 依赖与前端 npm 依赖

### 6.3 构建服务层与模型文件

```
# 1. 服务层 (建库 + 装载语料/片段)
createdb sciscope
make postgres-schema POSTGRES_DSN=postgresql://USER@localhost:5432/sciscope
psql sciscope -f infra/postgres/pgvector.sql
make postgres-load POSTGRES_DSN=...

# 2. 数据治理: 去重 (先 dry-run 再 APPLY)
make dedupe-db # 干跑统计
make dedupe-db APPLY=1 # 实际去重

# 3. 模型层: 嵌入 + 推荐 + 趋势 + 图谱
SCISCOPE_EMBEDDER_PATH=models/embedder_local/multilingual-e5-base make embeddings
make recommend-model trend-model graph-export
```

```
# 或一键:make agent-build
```

## 6.4 启动与体验

```
# 带数据库 + 本地嵌入启动前后端
SCISCOPE_DB_DSN=postgresql://USER@localhost:5432/sciscope \
SCISCOPE_EMBEDDER_PATH=models/embedder_local/multilingual-e5-base make dev

# 终端科研智能体 (Go 客户端, 需后端:8000 与本地大模型:8001)
make backend & make llm & make tui

# 接本地大模型生成 (需:8001 上的 OpenAI 兼容服务)
make vllm-serve                                     # 启动本地模型
... make dev                                         # 配 LOCAL_LLM_* 指向该模型
```

打开 <http://localhost:3000> 使用工作台; 后端接口文档见 <http://127.0.0.1:8000/docs>。

## 6.5 质量与效果验证

```
make test                                     # 后端测试 + 前端类型检查 + 构建 (以当前环境输出为准)
make eval-retrieval                           # 自检索评估:recall@k / MRR / 延迟
```

## 6.6 全量重建 (数据更新后)

持续爬取积累新数据后, 一次性重建并自动并入去重与全部模型:

```
make data-layer-refresh && make rag-chunks && make postgres-refresh && make agent-build
```

## 6.7 交付物清单

- **代码:**src/(采集/治理/分析/模型)、backend/(API + 智能体编排)、tui/(Go 终端客户端)、infra/(schema)、Makefile(流水线)。
- **模型文件:**pgvector 向量索引、models/(嵌入器/趋势/推荐)、output/graphs/(图谱 JSON)、RAG 片段语料; 均可由 make agent-build 复现。
- **报告:**本《项目报告书》与同级《数据分析报告》(output/pdf/sciscope\_data\_report)。
- **演示样例:**docs/examples/golden\_verify\_claim\_session.md 给出一轮跨语言论断核查黄金会话, 评委即使不启动环境也可查看 workflow 阶段、证据时间线与最终结论格式。
- **基础大模型:**声明为可替换依赖 (任意 OpenAI 兼容端点), 不绑定特定模型。

SciScope · 面向科技文献智能分析的科研智能体 · 大模型可换, 证据可溯, 流水线可复现

# 7 数据来源与参考文献

本系统所用数据均来自**公开学术数据源**, 算法与模型均为公开方法或开源权重, 知识产权清晰、可追溯、可复现。

## 7.1 数据来源

D1. OpenAlex —— 开放学术知识图谱与元数据 API。 <https://openalex.org>

- D2. PubMed / PubMed Central (PMC) ——美国国立医学图书馆生物医学文献库。<https://pubmed.ncbi.nlm.nih.gov>
- D3. Crossref ——DOI 注册与文献元数据。<https://www.crossref.org>
- D4. DOAJ ——开放获取期刊目录。<https://doaj.org>
- D5. arXiv ——计算机/物理/数学等领域预印本库 (含全文 PDF)。<https://arxiv.org>

## 7.2 方法与模型来源

- R1. Mann, H. B. (1945). Nonparametric tests against trend. *Econometrica*, 13(3), 245–259.
- R2. Sen, P. K. (1968). Estimates of the regression coefficient based on Kendall's tau. *JASA*, 63(324), 1379–1389.
- R3. Blondel, V. D., et al. (2008). Fast unfolding of communities in large networks (Louvain). *J. Stat. Mech.*
- R4. Page, L., Brin, S., et al. (1999). The PageRank citation ranking: Bringing order to the web.
- R5. Blei, D., Ng, A., Jordan, M. (2003). Latent Dirichlet Allocation (LDA). *JMLR*, 3, 993–1022.
- R6. Lee, D. D., Seung, H. S. (1999). Learning the parts of objects by non-negative matrix factorization (NMF). *Nature*, 401, 788–791.
- R7. Cormack, G. V., Clarke, C. L. A., Büttcher, S. (2009). Reciprocal rank fusion (RRF). *SIGIR*.
- R8. Robertson, S., Zaragoza, H. (2009). The probabilistic relevance framework: BM25 and beyond.
- R9. Wang, L., et al. (2024). Multilingual E5 text embeddings(`multilingual-e5-base`, 检索与跨语言嵌入)。
- R10. Chen, J., et al. (2024). BGE M3-Embedding / `bge-reranker-v2-m3`(跨语言重排)。
- R11. Qwen Team (2024). Qwen2.5 Technical Report(本地生成层 `Qwen2.5-7B-Instruct`)。

**合规声明:** 数据用于科研分析与方法验证, 遵循各数据源的开放获取与使用条款; 系统不存储或再分发受版权保护的论文全文, 仅保留用于检索的元数据、摘要与开放获取正文片段。