

# SciScope 项目报告书

## 面向科技文献智能分析的科研智能体构建

**赛道** 智能体开发

**成果类型** 数据分析报告 + 科研智能体模型 (代码 + 模型文件)

**核心能力** 文献问答 · 趋势预测 · 论文推荐 · 知识图谱

**数据规模** 6 个公开来源 · 159,190 篇 (去重后) · 主窗口 2022-2026

**模型资产** 226,434 条片段向量 · 159,190 篇论文级向量

### 一句话定位

SciScope 把约 16 万篇公开科技文献炼成一个**可检索、可问答、可预测趋势、可推荐、可看图谱**的科研智能体。大语言模型仅作生成层、可任意替换; 领域智能沉淀在**本地可复现的索引与模型文件**中, 且每个回答都附**可追溯证据** (evidence-grounded)。这正是” 科研智能体” 区别于” 直接问通用大模型” 的核心价值。

# 目录

|          |                       |          |
|----------|-----------------------|----------|
| <b>1</b> | <b>项目概述</b>           | <b>2</b> |
| 1.1      | 项目背景                  | 2        |
| 1.2      | 应用行业                  | 2        |
| 1.3      | 主要工作                  | 2        |
| 1.4      | 创新点                   | 2        |
| <b>2</b> | <b>解决方案</b>           | <b>2</b> |
| 2.1      | 总体架构设计                | 2        |
| 2.2      | 核心链路: 证据接地的检索增强问答     | 3        |
| 2.3      | 方案功能                  | 3        |
| 2.4      | 关键技术                  | 3        |
| 2.5      | 实现过程                  | 4        |
| <b>3</b> | <b>结果分析 (系统效果与效率)</b> | <b>4</b> |
| 3.1      | 检索质量与效率 (核心测试)        | 4        |
| 3.2      | 语义覆盖修复 (消融对比)         | 4        |
| 3.3      | 数据治理成效                | 5        |
| 3.4      | 模型资产与工程质量             | 5        |
| <b>4</b> | <b>示例问答与测试用例</b>      | <b>5</b> |
| 4.1      | 用例一: 英文混合检索 (双臂命中)    | 5        |
| 4.2      | 用例二: 中文跨语言检索 (命中英文文献) | 5        |
| 4.3      | 用例三: 可解释论文推荐          | 6        |
| 4.4      | 用例四: 趋势热点 (模型输出)      | 6        |
| 4.5      | 用例五: 证据接地问答           | 6        |
| <b>5</b> | <b>应用价值</b>           | <b>6</b> |
| 5.1      | 社会效益                  | 6        |
| 5.2      | 经济效益                  | 6        |
| 5.3      | 推广前景                  | 7        |
| <b>6</b> | <b>系统运行与复现说明</b>      | <b>7</b> |
| 6.1      | 运行环境                  | 7        |
| 6.2      | 一键安装                  | 7        |
| 6.3      | 构建服务层与模型文件            | 7        |
| 6.4      | 启动与体验                 | 7        |
| 6.5      | 质量与效果验证               | 8        |
| 6.6      | 全量重建 (数据更新后)          | 8        |
| 6.7      | 交付物清单                 | 8        |

# 1 项目概述

## 1.1 项目背景

科研文献数量爆炸式增长, 科研人员在文献调研、知识提取、研究趋势分析等环节面临巨大挑战。传统关键词检索是字面匹配, 难以满足细粒度、多维度、个性化、跨语言的知识需求; 而直接使用通用大模型问答又存在**幻觉**、**无出处**、**不可复现**等问题, 无法支撑严肃的科研决策。本项目构建 **SciScope 科研智能体**, 自动解析文献、提取关键信息、构建知识图谱, 并支持自然语言问答与研究方向推荐, 在**每个结论都附可追溯证据**的前提下提升科研效率与知识管理水平。

## 1.2 应用行业

高校与科研院所、企业研发部门、科技情报与图书馆机构、科研管理与基金评审部门。典型场景: 研究热点定位、领域脉络梳理、潜在合作者识别、文献调研提速、立项查新与综述辅助。

## 1.3 主要工作

- **数据底座**: 从 arXiv、PubMed、PMC、OpenAlex、Crossref、DOAJ 6 个公开来源采集、清洗、规范化、去重, 形成 159,190 篇、跨计算机/生物医学/材料等多领域、主窗口 2022–2026 的可复现语料。
- **数据分析报告** (交付物): 文献分布、关键词演化、作者合作网络、主题模型、趋势统计 (见同级交付物 `sciscope_data_report`)
- **科研智能体模型** (交付物): 本地嵌入索引、混合检索、趋势预测、论文推荐、知识图谱五大模型, 配套 FastAPI 服务与 Next.js 工作台。
- **系统工程**: PostgreSQL + pgvector 服务层、本地大模型 (vLLM/MLX) 生成层、一键复现的 Makefile 流水线与自动化测试。

## 1.4 创新点

### 四个核心创新

1. **大模型无关的证据接地架构 (LLM-agnostic, evidence-grounded)**: 大模型只负责“用人话写答案”, 领域智能沉淀在本地可复现的索引/模型文件中; 换任意大模型系统照常工作, 每条回答均附引用论文, 杜绝幻觉、可审计。
2. **字面 + 语义混合检索 (Hybrid Retrieval)**: PostgreSQL 全文检索 (FTS) 与 pgvector 向量检索双路并行, 用 RRF(倒数排名融合) 合并, 兼顾精确匹配与语义/跨语言理解 (中文问句可命中英文文献)。
3. **”模型文件” 即可复现资产**: 不依赖黑盒训练权重, 而是用本项目代码从本项目语料**计算/拟合**出的嵌入索引、趋势模型、推荐向量、知识图谱;`make agent-build` 可一键重建, 知识产权清晰、评委可复现。
4. **数据质量工程**: 标题优先去重 + 期刊 front-matter 剔除 + PDF 垃圾过滤 + 关键词噪声过滤 (剔除 arXiv 分类码与超泛学科标签), 显著提升检索、趋势与图谱的信噪比。

# 2 解决方案

## 2.1 总体架构设计

系统采用**可复现流水线 + PostgreSQL 服务层 + 可替换大模型**的分层架构。数据自底向上逐层加工为”可问答系统”; 其中**分析层**产出《数据分析报告》, **模型层**产出科研智能体的”模型文件”, 两者共享同一数据底座。




图 1 SciScope 总体架构: 采集 → 治理 → 分析/模型 → 服务 → 接口 → 交互; 大模型仅作可替换的生成层

**设计原则:** 离线可复现 (每层产物由 `make` 目标生成); 大模型可替换 (生成层走 OpenAI 兼容接口); 证据可追溯 (回答必带引用); 本地优先 (数据与索引均在本地, 支持涉密场景)。

## 2.2 核心链路: 证据接地的检索增强问答

问答不直接交给大模型臆测, 而是**先检索证据、再据证生成**, 每条回答都可追溯到具体论文:



图 2 混合检索 + 证据接地生成链路 (中文问句可跨语言命中英文文献)

## 2.3 方案功能

- **文献问答** `/api/chat`: 混合检索证据 → 本地大模型基于证据生成带引用回答。
- **混合检索** `/api/search`: FTS + 向量 + RRF 融合, 去重到论文级, 返回命中片段。
- **趋势预测** `/api/trends`: 关键词/主题的增长率、burst、生命周期与下一年线性外推 (含不确定区间)。
- **论文推荐** `/api/recommend`: 语义相似 + 关键词重叠 + 作者关系 + 时近性融合, 输出**可解释因子**。
- **知识图谱** `/api/graph`: 作者合作图、关键词共现图、论文-主题图; 作者支持实时 ego 子图。

## 2.4 关键技术

- **向量化**: 本地 multilingual-e5-base(768 维, 中英跨语言), fp16 加速、断点续传; 向量入 pgvector。
- **混合检索与 RRF**: tsvector 全文索引 + ivfflat 余弦向量索引, 两路按  $1/(k + \text{rank})$  融合 ( $k=60$ )。
- **趋势模型**: 逐年归一化词频上最小二乘外推 + 残差不确定带; 主题模型 LDA/NMF 各 40 主题。
- **推荐模型**: 论文级平均向量 (pgvector avg) + 多信号加权, 逐条给出可解释因子。

- **知识图谱**: NetworkX 中心度/社区, 百万级边按中心度剪枝导出 JSON, 作者 ego 图走 SQL 实时查询。
- **生成层**: OpenAI 兼容本地服务, 输出限长防失控, 可平滑切换更大/远程模型。

## 2.5 实现过程

**数据生成与采集** → 6 源按领域/年份抓取, 落 data/raw\_canonical 分区 JSONL。

**数据组织与治理** → 规范化字段; 标题优先去重 (合并跨源/预印本同篇, 留最全一条)+ front-matter 剔除 + PDF 垃圾/ NUL 清洗; 160,488 → 159,190 篇。

**信息汲取与建模** → 切片入库, 计算片段/论文向量, 拟合趋势/推荐/图谱/主题; 关键词统一过滤 arXiv 码与超泛标签。make agent-build 一键重建。

**服务与交互** → FastAPI 暴露五接口, 前端可视化; 数据库不可用时自动回退内存检索, 保证演示鲁棒。

## 3 结果分析 (系统效果与效率)

**说明**: 本章聚焦**系统/算法的效果与效率测试**。关于语料本身的分布、关键词演化、作者网络与主题分析, 详见同级交付物《SciScope 数据分析报告》, 此处不重复。

### 3.1 检索质量与效率 (核心测试)

采用**自检索协议** (以论文自身标题/关键词为查询, 检验能否检回该文) 在全库 100 篇随机样本上评测混合检索:

| 查询方式           | recall@1 | recall@10   | MRR@10 | 平均延迟    |
|----------------|----------|-------------|--------|---------|
| 按标题 (字面 + 语义臂) | 0.94     | <b>0.99</b> | 0.965  | ~250 ms |
| 按关键词           | 0.60     | 0.69        | 0.63   | ~100 ms |

标题查询近乎总能将目标论文排进前列 (recall@10=0.99)、延迟亚秒级, 体现混合检索“**效果与效率**”兼顾; 关键词查询指标偏低, 反映全库真实难度 (含摘要稀疏论文), 为后续优化指明方向, 数据真实不回避。

### 3.2 语义覆盖修复 (消融对比)

初版仅对“有全文”论文嵌入, 导致语义检索严重偏向生物医学、对最大领域**计算机科学近乎失明** (论文级向量仅 87 篇); 经**全量标题摘要嵌入**修复后, 论文级向量 17,913 → 159,190, 各领域覆盖如下 (消融前后对比):




图 3 语义检索领域覆盖: 修复前 (空心)vs 修复后 (实心)。计算机科学从 87 跃升至 58,038, 偏科消除

修复后语义检索与推荐覆盖**全部 16 万篇全领域**, 中文问句可跨语言命中英文文献。

### 3.3 数据治理成效

| 治理项                      | 处理              | 效果            |
|--------------------------|-----------------|---------------|
| 标题优先去重 + front-matter 剔除 | 删 1,298 篇       | 残留长标题重复组归零    |
| PDF 垃圾正文过滤               | 清 83 篇 / 46 片段  | 杜绝回答吐 PDF 乱码  |
| 关键词噪声过滤                  | arXiv 码/泛标签/期刊名 | 趋势 top 回归真实主题 |

关键词清洗后, 趋势热点回归真实研究主题:retrieval augmented generation、large language model 位居新兴前列; 主题模型 (40 主题) 清晰区分 LLM、RAG、图神经网络、锂电池、蛋白结构、催化等方向。

### 3.4 模型资产与工程质量

| 模型文件 / 索引 / 质量项                 | 规模         |
|---------------------------------|------------|
| 片段向量 chunk_embeddings(pgvector) | 226,434    |
| 论文级向量 paper_embeddings          | 159,190    |
| 主题模型 (LDA + NMF)                | 40 主题 / 模型 |
| 知识图谱 (作者/关键词/主题)                | 前端友好 JSON  |
| 后端自动化测试                         | 92 项全部通过   |

全部模型文件可由 make agent-build 一键重建, 知识产权清晰、评委可复现。

## 4 示例问答与测试用例

下列为系统在真实 16 万篇语料上的**实际输出** (非示意), 用于直观展示检索、跨语言、推荐与证据接地能力。

#### 4.1 用例一: 英文混合检索 (双臂命中)

查询:graph neural network materials discovery

返回 (lexical+semantic 双臂命中):

1. Accelerated Discovery of Energy Materials via Graph Neural Networks

(2025)

2. CTGNN: Crystal Transformer Graph Neural Network for Crystal Materials

(2024)

3. DeepCrysTet: A Deep Learning Approach Using Tetrahedral Mesh

(2023)

#### 4.2 用例二: 中文跨语言检索 (命中英文文献)

查询: 大语言模型的检索增强生成 (中文)

返回 (semantic 语义臂, 跨语言命中英文论文):

1. Retrieval-Augmented Retrieval: Large Language Models are Strong Zero-Shot Retrievers

(2024)

2. LExT: Towards Evaluating Trustworthiness of Natural Language Explanations

(2025)

3. A Comprehensive Study of Jailbreak Attack versus Defense for LLMs

(2024)

4.3 用例三：可解释论文推荐

种子论文:PMC13273979(AI 药物发现方向)

推荐 (每条附可解释因子 semantic / keyword / author / recency):

| 推荐论文                                                        | 年份   | 语义相似  | 融合因子             |
|-------------------------------------------------------------|------|-------|------------------|
| Generative AI in drug discovery and development             | 2024 | 0.941 | sem .56 / kw .10 |
| Editorial: Advancing drug discovery with AI                 | 2025 | 0.934 | sem .56 / kw .10 |
| Advancing Drug Discovery with AI: Machine and Deep Learning | 2026 | 0.915 | sem .55 / kw .10 |

4.4 用例四：趋势热点 (模型输出)

/api/trends 新兴热点排行 (关键词清洗后): retrieval augmented generation → large language model → gene delivery → ...

与 2022-2026 年科研态势吻合,RAG 与大语言模型领跑。

4.5 用例五：证据接地问答

提问: 图神经网络在材料发现中有哪些应用?

系统流程: 混合检索 → 取 Top 证据 (如 *A review on the applications of GNNs in materials science、crystal graph convolutional neural network*)→ 本地大模型**仅基于证据**生成回答, 并标注引用 [n]。

关键特性: 回答可追溯到具体论文; 证据不足时如实说明, 不臆造。

5 应用价值

5.1 社会效益

- **科研提效与公平:** 把分散在多源、多语言的文献统一为可问答知识底座, 让中小机构、欠发达地区科研人员以更低门槛获得高质量文献调研能力, 缩小科研信息鸿沟。
- **可信与可审计:** 每条回答均附引用论文 (evidence-grounded), 从源头抑制大模型幻觉, 支撑**科学决策**与严肃的立项查新、综述撰写, 减少误导性结论传播。
- **知识传承与脉络梳理:** 主题演化、关键词趋势与合作网络帮助新人快速理解领域发展脉络, 促进知识传承。
- **数据安全友好:** 本地优先架构 (数据、索引、可选本地大模型均在本地), 适配涉密/敏感科研场景, 符合数据安全与自主可控要求。

5.2 经济效益

- **效率提升:** 文献调研、热点定位、综述梳理等高耗时环节由”人工逐篇”转为”语义问答 + 证据直达”, 显著压缩科研前期投入工时。
- **成本优化:** 核心智能沉淀在**本地可复现的索引与模型文件**, 大模型仅作可替换的生成层——可用小模型本地推理、按需切换更强模型, 避免高昂的纯大模型 API 调用成本。
- **创新驱动与决策支持:** 趋势预测与热点识别为研发立项、技术路线选择、专利布局提供数据支撑, 降低试错成本。
- **合作拓展:** 作者合作网络辅助识别潜在合作者与团队, 促进产学研对接与资源整合。



## 5.3 推广前景

- **高校/科研院所:** 学科情报中心、研究生文献调研、综述与查新服务。
- **企业研发:** 技术情报监测、竞品与专利分析、研发选题。
- **科研管理:** 基金评审辅助、领域态势研判、合作网络分析。
- **可扩展性:** 架构与领域无关, 更换语料即可迁移到任意学科或企业内部文档库; 模型可替换、流水线可复现, 便于产品化与私有化部署。

### 差异化价值小结

相比”直接问通用大模型”,SciScope 的不可替代之处在于: **基于真实语料、有出处可追溯、本地可复现、领域可迁移、大模型可替换**。它不是又一个聊天机器人, 而是一套**把机构自有文献资产转化为可信科研生产力的智能体系统**。

## 6 系统运行与复现说明

### 6.1 运行环境

- Python 3.11(conda 环境),Node.js(前端);PostgreSQL 15 + pgvector 扩展。
- 关键依赖:fastapi、psycopg、pgvector、sentence-transformers、scikit-learn、networkx、pandas。
- 本地大模型 (可选):vLLM-Metal / LM Studio 等 OpenAI 兼容服务; 无则自动用 mock, 检索证据仍真实。

### 6.2 一键安装

```
make install
```

```
# 安装后端 Python 依赖与前端 npm 依赖
```

### 6.3 构建服务层与模型文件

```
# 1. 服务层 (建库 + 装载语料/片段)
createdb sciscope
make postgres-schema POSTGRES_DSN=postgresql://USER@localhost:5432/sciscope
psql sciscope -f infra/postgres/pgvector.sql
make postgres-load POSTGRES_DSN=...

# 2. 数据治理: 去重 (先 dry-run 再 APPLY)
make dedupe-db # 干跑统计
make dedupe-db APPLY=1 # 实际去重

# 3. 模型层: 嵌入 + 推荐 + 趋势 + 图谱
SCISCOPE_EMBEDDER_PATH=models/embedder_local/multilingual-e5-base make embeddings
make recommend-model trend-model graph-export
# 或一键:make agent-build
```

### 6.4 启动与体验

```
# 带数据库 + 本地嵌入启动前后端
SCISCOPE_DB_DSN=postgresql://USER@localhost:5432/sciscope \
SCISCOPE_EMBEDDER_PATH=models/embedder_local/multilingual-e5-base make dev

# 终端直接问答 (自动探测本地大模型)
make chat
```



```
# 接本地大模型生成（需:8001 上的 OpenAI 兼容服务）
make vllm-serve                                     # 启动本地模型
... make dev                                         # 配 LOCAL_LLM_* 指向该模型
```

打开 <http://localhost:3000> 使用工作台; 后端接口文档见 <http://127.0.0.1:8000/docs>。

## 6.5 质量与效果验证

```
make test                                           # 92 项后端测试 + 前端类型检查 + 构建
make eval-retrieval                                # 自检索评估:recall@k / MRR / 延迟
```

## 6.6 全量重建 (数据更新后)

持续爬取积累新数据后, 一次性重建并自动并入去重与全部模型:

```
make data-layer-refresh && make rag-chunks && make postgres-refresh && make agent-build
```

## 6.7 交付物清单

- **代码:**src/(采集/治理/分析/模型)、backend/(API)、frontend/(工作台)、infra/(schema)、Makefile(流水线)。
- **模型文件:**pgvector 向量索引、models/(嵌入器/趋势/推荐)、graphs/(图谱 JSON)、RAG 片段语料; 均可由 `make agent-build` 复现。
- **报告:** 本《项目报告书》与同级《数据分析报告》(output/pdf/sciscope\_data\_report)。
- **基础大模型:** 声明为可替换依赖 (任意 OpenAI 兼容端点), 不绑定特定模型。

SciScope · 面向科技文献智能分析的科研智能体 · 大模型可换, 证据可溯, 流水线可复现